Proyecto Data Science (G30)

Hito 3

Tema: Otorgar Nuevos Créditos

Alumnos : Claudia Villegas - Isabel Pilar - Barbara Herrera - Miguel Peña - Alexis Tapia

1. Objetivo

¿Cómo predecir el comportamiento de futuros buenos pagadores?

Este proyecto se enmarca en un caso práctico, para dar conformidad al plan de estudios de la carrera de Data Science.

Los datos de estudio para la elaboración de esta propuesta fueron suministrados por Desafío Latam.

El caso de estudio seleccionado se enmarca en la industria bancaria, en particular en el análisis del comportamiento del pago de los clientes del banco International referente a la cartera de consumo para predecir el comportamiento de futuros buenos pagadores.

La motivación de este proyecto nace a partir de la necesidad de los bancos de disminuir los riesgos de crédito al facilitar préstamos a clientes que sean mejores pagadores, donde cada día las técnicas de Machine Learning se vuelven imprescindibles para trabajar con una alta cantidad de datos.

El vector objetivo es obtener un modelo capaz de predecir si el cliente presenta dificultades para pagar.

Respecto de la implementación y pre procesamiento, en esta etapa, se tomarán las siguientes consideraciones:

1.- Eliminar columnas: las columnas que no generen un valor significativo al modelo o columnas repetidas, serán eliminadas.

2.- Valores nulos o perdidos: si se presentan demasiados nulos en los atributos que superen cierto umbral que se definirá posteriormente, se eliminarán las columnas respectivas.

3.- Valores atipicos: la variable será analizada, y si esta aporta valor al modelo, los valores outliers se reemplazarán por la media o mediana según corresponda.

4.- Transformación del tipo de dato: si las variables no corresponden con el tipo de dato indicado, este será transformado a su tipo de dato correspondiente.

5.- Recodificación de variables: se analizará la variable, para recodificar o transformar la variable según corresponda.

2. Análisis Exploratorio

2.1 Importar librerías necesarias

In [1]:
```
#!pip install imblearn
#!pip install pygam
```

In [2]:
```
#%matplotlib inline

# Manipulación y limpieza de datos
# ==============================================================================
import pandas as pd

# Análisis de datos
# ==============================================================================
import numpy as np

# Visualizacion de gráficos
# ==============================================================================
import matplotlib.pyplot as plt
from matplotlib import style
import matplotlib.ticker as mtick
import seaborn as sns
```

```
# Procesamiento
# ==============================================================================
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler, Normalizer, LabelEncoder, LabelBinarizer
from sklearn.model_selection import GridSearchCV
from sklearn.pipeline import Pipeline

# Desbalanceo de clases
# ==============================================================================
from imblearn.over_sampling import SMOTE
from imblearn.under_sampling import RandomUnderSampler

# Modelos Econometricos
# ==============================================================================
import statsmodels.api as sm
import statsmodels.formula.api as smf

# Machine Learning
# ==============================================================================
from pygam import LogisticGAM
from sklearn.discriminant_analysis import LinearDiscriminantAnalysis
from sklearn.linear_model import LogisticRegression
from sklearn.ensemble import RandomForestClassifier
from sklearn.ensemble import AdaBoostClassifier
from sklearn.ensemble import GradientBoostingClassifier
#from sklearn import tree
#from sklearn.tree import DecisionTreeClassifier

# Funciones de estadística matemática
# ==============================================================================
from statistics import quantiles

# Metricas
# ==============================================================================
from sklearn.metrics import plot_roc_curve, confusion_matrix, make_scorer
from sklearn.metrics import accuracy_score,recall_score,accuracy_score,f1_score,precision_score
from sklearn.metrics import roc_auc_score, roc_curve, classification_report, cohen_kappa_score
from scipy.stats import ks_2samp
from sklearn.metrics import ConfusionMatrixDisplay

# Funciones propias
# ==============================================================================
import funciones_auxiliares as hlp

# Utilitarios
# ==============================================================================
from math import ceil
from itertools import zip_longest

# Sistema
# ==============================================================================
import pickle
```

In [3]:

```
#Configuracion de warnings
# ==============================================================================
import warnings
import sys

if not sys.warnoptions:
    warnings.simplefilter("ignore")

# Configuración matplotlib
# ==============================================================================
plt.style.use('ggplot')
sns.set_style("darkgrid")
plt.rcParams['image.cmap'] = "bwr"
plt.rcParams["figure.figsize"] = ( 6, 4 )
plt.rcParams["figure.dpi"] = 100
```

2.2 Ingesta de Datos

In [4]:

```
%%time
# Lectura de la data train
df_train = pd.read_csv('data/training_new_credits.csv')
data = df_train.copy()
```

```
Wall time: 4.66 s
```

In [5]:

```
# Visualización de los primeros 5 registros de la data train
pd.options.display.max_columns = None
df_train.head()
```

Out[5]:

	SK_ID_CURR	TARGET	NAME_CONTRACT_TYPE	CODE_GENDER	FLAG_OWN_CAR	FLAG_OWN_REALTY	CNT_CHILDREN	AMT_INCOME_TOTAL	AMT_CREDIT	AM
0	100002	1	Cash loans	M	N	Y	0	202500.0	406597.5	
1	100003	0	Cash loans	F	N	N	0	270000.0	1293502.5	
2	100004	0	Revolving loans	M	Y	Y	0	67500.0	135000.0	
3	100006	0	Cash loans	F	N	Y	0	135000.0	312682.5	
4	100007	0	Cash loans	M	N	Y	0	121500.0	513000.0	

In [6]:

```
# Visualización de los últimos 5 registros de la data train
df_train.tail()
```

Out[6]:

	SK_ID_CURR	TARGET	NAME_CONTRACT_TYPE	CODE_GENDER	FLAG_OWN_CAR	FLAG_OWN_REALTY	CNT_CHILDREN	AMT_INCOME_TOTAL	AMT_CREDIT
307506	456251	0	Cash loans	M	N	N	0	157500.0	254700.0
307507	456252	0	Cash loans	F	N	Y	0	72000.0	269550.0
307508	456253	0	Cash loans	F	N	Y	0	153000.0	677664.0
307509	456254	1	Cash loans	F	N	Y	0	171000.0	370107.0
307510	456255	0	Cash loans	F	N	N	0	157500.0	675000.0

2.3 Comprobación de dimensión y tipo de datos

In [7]:

```
# Número de observaciones totales iniciales
print ("Train data shape:", df_train.shape)
```

```
Train data shape: (307511, 122)
```

In [8]:

```
# Tipo de datos de data train
df_train.dtypes.value_counts()
```

Out[8]:

```
float64    65
int64      41
object     16
dtype: int64
```

- El total de registros del dataset es de 307511 filas, con un total de 106 columnas definidas como tipo numérico y 16 columnas definidas como tipo `object` o categóricas. Existen varias columnas con valores ausentes `NaN`, otras con valores negativos, los que serán analizados posteriormente, antes de crear los modelos.

2.4 Cartera de observaciones a seleccionar

In [9]:

```
# Atributo NAME_CONTRACT_TYPE, identificación si el préstamo es en efectivo o crédito revolving
df_train['NAME_CONTRACT_TYPE'].value_counts().plot(kind='bar');
plt.xticks(rotation=0);
```

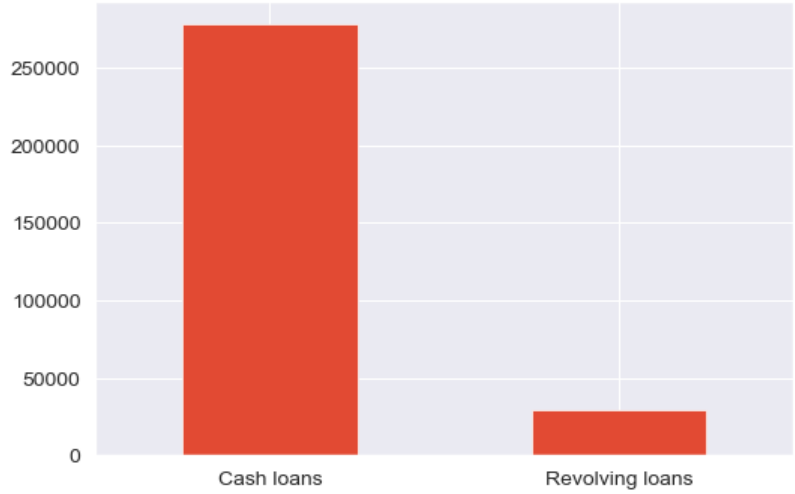

Se modelará solamente créditos del tipo `Cash Loans`, referidos a préstamos en efectivo, ya que se visualizan un mayor número de observaciones.

In [10]:
```
# Selección de observaciones "Cash loans", que será cartera a modelar ya que existen un mayor número de ellas
#=============================================================================================
df_train = df_train[df_train['NAME_CONTRACT_TYPE'] == 'Cash loans']
df_train.sample()
```

Out[10]:

	SK_ID_CURR	TARGET	NAME_CONTRACT_TYPE	CODE_GENDER	FLAG_OWN_CAR	FLAG_OWN_REALTY	CNT_CHILDREN	AMT_INCOME_TOTAL	AMT_CREDIT
260060	400945	1	Cash loans	F	N	N	0	90000.0	373941.0

In [11]:
```
# Eliminación de columna NAME_CONTRACT_TYPE por seleccion de cartera de prestamo en Efectivo.
#=============================================================================================
df_train = df_train.drop('NAME_CONTRACT_TYPE', axis=1)
```

2.5 Dimensión de cartera seleccionada

In [12]:
```
# Número de observaciones a considerar para análisis
print('Número de filas   :{}'.format(df_train.shape[0]))
print('Número de columnas:{}'.format(df_train.shape[1]))
```

```
Número de filas   :278232
Número de columnas:121
```

2.6 Información general de los datos

In [13]:
```
# Información general de los datos
df_train.info(verbose=True, show_counts=True)
```

```
<class 'pandas.core.frame.DataFrame'>
Int64Index: 278232 entries, 0 to 307510
Data columns (total 121 columns):
 #    Column                       Non-Null Count   Dtype
---   ------                       --------------   -----
 0    SK_ID_CURR                   278232 non-null  int64
 1    TARGET                       278232 non-null  int64
 2    CODE_GENDER                  278232 non-null  object
 3    FLAG_OWN_CAR                 278232 non-null  object
 4    FLAG_OWN_REALTY              278232 non-null  object
 5    CNT_CHILDREN                 278232 non-null  int64
 6    AMT_INCOME_TOTAL             278232 non-null  float64
 7    AMT_CREDIT                   278232 non-null  float64
 8    AMT_ANNUITY                  278220 non-null  float64
 9    AMT_GOODS_PRICE              278232 non-null  float64
 10   NAME_TYPE_SUITE              277225 non-null  object
 11   NAME_INCOME_TYPE             278232 non-null  object
 12   NAME_EDUCATION_TYPE          278232 non-null  object
 13   NAME_FAMILY_STATUS           278232 non-null  object
 14   NAME_HOUSING_TYPE            278232 non-null  object
 15   REGION_POPULATION_RELATIVE   278232 non-null  float64
 16   DAYS_BIRTH                   278232 non-null  int64
 17   DAYS_EMPLOYED                278232 non-null  int64
 18   DAYS_REGISTRATION            278232 non-null  float64
 19   DAYS_ID_PUBLISH              278232 non-null  int64
 20   OWN_CAR_AGE                  94452 non-null   float64
```

```
21   FLAG_MOBIL                   278232 non-null  int64
22   FLAG_EMP_PHONE               278232 non-null  int64
23   FLAG_WORK_PHONE              278232 non-null  int64
24   FLAG_CONT_MOBILE             278232 non-null  int64
25   FLAG_PHONE                   278232 non-null  int64
26   FLAG_EMAIL                   278232 non-null  int64
27   OCCUPATION_TYPE              189432 non-null  object
28   CNT_FAM_MEMBERS              278232 non-null  float64
29   REGION_RATING_CLIENT         278232 non-null  int64
30   REGION_RATING_CLIENT_W_CITY  278232 non-null  int64
31   WEEKDAY_APPR_PROCESS_START   278232 non-null  object
32   HOUR_APPR_PROCESS_START      278232 non-null  int64
33   REG_REGION_NOT_LIVE_REGION   278232 non-null  int64
34   REG_REGION_NOT_WORK_REGION   278232 non-null  int64
35   LIVE_REGION_NOT_WORK_REGION  278232 non-null  int64
36   REG_CITY_NOT_LIVE_CITY       278232 non-null  int64
37   REG_CITY_NOT_WORK_CITY       278232 non-null  int64
38   LIVE_CITY_NOT_WORK_CITY      278232 non-null  int64
39   ORGANIZATION_TYPE            278232 non-null  object
40   EXT_SOURCE_1                 120217 non-null  float64
41   EXT_SOURCE_2                 277633 non-null  float64
42   EXT_SOURCE_3                 223574 non-null  float64
43   APARTMENTS_AVG               135824 non-null  float64
44   BASEMENTAREA_AVG             114278 non-null  float64
45   YEARS_BEGINEXPLUATATION_AVG  141294 non-null  float64
46   YEARS_BUILD_AVG              92241 non-null   float64
47   COMMONAREA_AVG               82996 non-null   float64
48   ELEVATORS_AVG                128741 non-null  float64
49   ENTRANCES_AVG                136910 non-null  float64
50   FLOORSMAX_AVG                138563 non-null  float64
51   FLOORSMIN_AVG                88518 non-null   float64
52   LANDAREA_AVG                 111900 non-null  float64
53   LIVINGAPARTMENTS_AVG         87169 non-null   float64
54   LIVINGAREA_AVG               137415 non-null  float64
55   NONLIVINGAPARTMENTS_AVG      84178 non-null   float64
56   NONLIVINGAREA_AVG            123530 non-null  float64
57   APARTMENTS_MODE              135824 non-null  float64
58   BASEMENTAREA_MODE            114278 non-null  float64
59   YEARS_BEGINEXPLUATATION_MODE 141294 non-null  float64
60   YEARS_BUILD_MODE             92241 non-null   float64
61   COMMONAREA_MODE              82996 non-null   float64
62   ELEVATORS_MODE               128741 non-null  float64
63   ENTRANCES_MODE               136910 non-null  float64
64   FLOORSMAX_MODE               138563 non-null  float64
65   FLOORSMIN_MODE               88518 non-null   float64
66   LANDAREA_MODE                111900 non-null  float64
67   LIVINGAPARTMENTS_MODE        87169 non-null   float64
68   LIVINGAREA_MODE              137415 non-null  float64
69   NONLIVINGAPARTMENTS_MODE     84178 non-null   float64
70   NONLIVINGAREA_MODE           123530 non-null  float64
71   APARTMENTS_MEDI              135824 non-null  float64
72   BASEMENTAREA_MEDI            114278 non-null  float64
73   YEARS_BEGINEXPLUATATION_MEDI 141294 non-null  float64
74   YEARS_BUILD_MEDI             92241 non-null   float64
75   COMMONAREA_MEDI              82996 non-null   float64
76   ELEVATORS_MEDI               128741 non-null  float64
77   ENTRANCES_MEDI               136910 non-null  float64
78   FLOORSMAX_MEDI               138563 non-null  float64
79   FLOORSMIN_MEDI               88518 non-null   float64
80   LANDAREA_MEDI                111900 non-null  float64
81   LIVINGAPARTMENTS_MEDI        87169 non-null   float64
82   LIVINGAREA_MEDI              137415 non-null  float64
83   NONLIVINGAPARTMENTS_MEDI     84178 non-null   float64
84   NONLIVINGAREA_MEDI           123530 non-null  float64
85   FONDKAPREMONT_MODE           87022 non-null   object
86   HOUSETYPE_MODE               137401 non-null  object
87   TOTALAREA_MODE               142718 non-null  float64
88   WALLSMATERIAL_MODE           135590 non-null  object
89   EMERGENCYSTATE_MODE          145123 non-null  object
90   OBS_30_CNT_SOCIAL_CIRCLE     278231 non-null  float64
91   DEF_30_CNT_SOCIAL_CIRCLE     278231 non-null  float64
92   OBS_60_CNT_SOCIAL_CIRCLE     278231 non-null  float64
93   DEF_60_CNT_SOCIAL_CIRCLE     278231 non-null  float64
94   DAYS_LAST_PHONE_CHANGE       278231 non-null  float64
95   FLAG_DOCUMENT_2              278232 non-null  int64
96   FLAG_DOCUMENT_3              278232 non-null  int64
97   FLAG_DOCUMENT_4              278232 non-null  int64
98   FLAG_DOCUMENT_5              278232 non-null  int64
99   FLAG_DOCUMENT_6              278232 non-null  int64
100  FLAG_DOCUMENT_7              278232 non-null  int64
101  FLAG_DOCUMENT_8              278232 non-null  int64
102  FLAG_DOCUMENT_9              278232 non-null  int64
103  FLAG_DOCUMENT_10             278232 non-null  int64
104  FLAG_DOCUMENT_11             278232 non-null  int64
105  FLAG_DOCUMENT_12             278232 non-null  int64
106  FLAG_DOCUMENT_13             278232 non-null  int64
```

```
 107  FLAG_DOCUMENT_14              278232 non-null  int64
 108  FLAG_DOCUMENT_15              278232 non-null  int64
 109  FLAG_DOCUMENT_16              278232 non-null  int64
 110  FLAG_DOCUMENT_17              278232 non-null  int64
 111  FLAG_DOCUMENT_18              278232 non-null  int64
 112  FLAG_DOCUMENT_19              278232 non-null  int64
 113  FLAG_DOCUMENT_20              278232 non-null  int64
 114  FLAG_DOCUMENT_21              278232 non-null  int64
 115  AMT_REQ_CREDIT_BUREAU_HOUR    240993 non-null  float64
 116  AMT_REQ_CREDIT_BUREAU_DAY     240993 non-null  float64
 117  AMT_REQ_CREDIT_BUREAU_WEEK    240993 non-null  float64
 118  AMT_REQ_CREDIT_BUREAU_MON     240993 non-null  float64
 119  AMT_REQ_CREDIT_BUREAU_QRT     240993 non-null  float64
 120  AMT_REQ_CREDIT_BUREAU_YEAR    240993 non-null  float64
dtypes: float64(65), int64(41), object(15)
memory usage: 259.0+ MB
```

- La base de datos a trabajar cuenta con 278232 observaciones y 121 atributos.

2.7. Distribución de variable objetivo TARGET

In [14]:

```
plt.figure(figsize = (5,4))
# 1: Mal pagador
# 0: Buen pagador
target = df_train['TARGET']
print(target.value_counts())
sns.countplot(x = 'TARGET', data=df_train);
```

```
0    255011
1     23221
Name: TARGET, dtype: int64
```

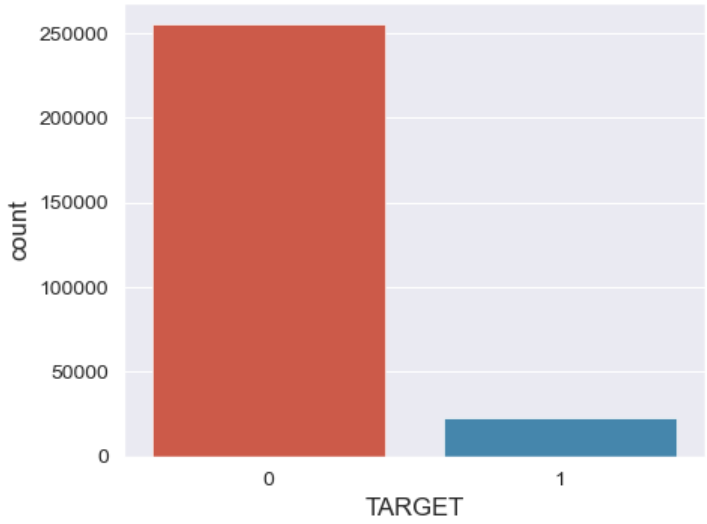

- Se aprecia que este es un problema de clase desbalanceada.Hay muchos más clientes que son buenos pagadores al solicitar un préstamo en efectivo que los que tuvieron dificultades para pagar. Es de especial cuidado este desbalanceo para las métricas de los modelos que se definirán en etapas posteriores para este tipo de clasificación.

2.8 Análisis descriptivo preliminar

Se separán los datos por tipo de dato, para realizar un análisis mas individualizado de las variables del dataset.

2.8.1 Estadística básica

In [15]:

```
df_train.describe()
```

Out[15]:

	SK_ID_CURR	TARGET	CNT_CHILDREN	AMT_INCOME_TOTAL	AMT_CREDIT	AMT_ANNUITY	AMT_GOODS_PRICE	REGION_POPULATION_RELATIVE
count	278232.000000	278232.000000	278232.000000	2.782320e+05	2.782320e+05	278220.000000	2.782320e+05	278232.000000
mean	278125.362338	0.083459	0.410025	1.690695e+05	6.279657e+05	28244.263958	5.605637e+05	0.020748
std	102760.412749	0.276575	0.719522	2.459110e+05	4.054070e+05	14167.189802	3.736466e+05	0.013734
min	100002.000000	0.000000	0.000000	2.565000e+04	4.500000e+04	1615.500000	4.050000e+04	0.000533
25%	189087.250000	0.000000	0.000000	1.125000e+05	2.970000e+05	18103.500000	2.475000e+05	0.010006
50%	278161.500000	0.000000	0.000000	1.530000e+05	5.400000e+05	26086.500000	4.545000e+05	0.018850
75%	367054.250000	0.000000	1.000000	2.025000e+05	8.353800e+05	35694.000000	7.020000e+05	0.028663

	SK_ID_CURR	TARGET	CNT_CHILDREN	AMT_INCOME_TOTAL	AMT_CREDIT	AMT_ANNUITY	AMT_GOODS_PRICE	REGION_POPULATION_RELATIVE
max	456255.000000	1.000000	19.000000	1.170000e+08	4.050000e+06	258025.500000	4.050000e+06	0.072508

2.8.2 Estadística básica datos continuos

In [16]:
```
# Análisis estadistico datos continuos
df_train.select_dtypes(include=['float64']).describe()
```

Out[16]:

	AMT_INCOME_TOTAL	AMT_CREDIT	AMT_ANNUITY	AMT_GOODS_PRICE	REGION_POPULATION_RELATIVE	DAYS_REGISTRATION	OWN_CAR_AGE	CNT_FAM
count	2.782320e+05	2.782320e+05	278220.000000	2.782320e+05	278232.000000	278232.000000	94452.000000	278
mean	1.690695e+05	6.279657e+05	28244.263958	5.605637e+05	0.020748	-5009.613488	12.019618	
std	2.459110e+05	4.054070e+05	14167.189802	3.736466e+05	0.013734	3535.561853	11.648180	
min	2.565000e+04	4.500000e+04	1615.500000	4.050000e+04	0.000533	-24672.000000	0.000000	
25%	1.125000e+05	2.970000e+05	18103.500000	2.475000e+05	0.010006	-7509.000000	5.000000	
50%	1.530000e+05	5.400000e+05	26086.500000	4.545000e+05	0.018850	-4522.000000	9.000000	
75%	2.025000e+05	8.353800e+05	35694.000000	7.020000e+05	0.028663	-2028.000000	15.000000	
max	1.170000e+08	4.050000e+06	258025.500000	4.050000e+06	0.072508	0.000000	91.000000	

- Se observa que el monto del crédito `AMT_CREDIT` se ajusta a los montos en los que será utilizado el préstamo y que la mitad de los clientes solicitaron cifras superiores a 540000, y se tiene una media de 627966, también se puede inferir que estan variables estas muy correlacionadas.
- Existes variables que continen los sufijos `AVG` , `MODE` y `MEDI` que cuentan con una gran cantidad de valores nulos.

2.8.3 Estadística básica datos discretos

In [17]:
```
# Análisis estadistico datos discretos
df_train.select_dtypes(include=['int']).describe()
```

Out[17]:

	SK_ID_CURR	TARGET	CNT_CHILDREN	DAYS_BIRTH	DAYS_EMPLOYED	DAYS_ID_PUBLISH	FLAG_MOBIL	FLAG_EMP_PHONE	FLAG_WORK_PHONI
count	278232.000000	278232.000000	278232.000000	278232.000000	278232.000000	278232.000000	278232.000000	278232.000000	278232.00000(
mean	278125.362338	0.083459	0.410025	-16159.256060	66310.442020	-3020.079240	0.999996	0.813041	0.20372
std	102760.412749	0.276575	0.719522	4343.738866	143346.548212	1501.233328	0.001896	0.389879	0.40277
min	100002.000000	0.000000	0.000000	-25201.000000	-17912.000000	-7197.000000	0.000000	0.000000	0.00000(
25%	189087.250000	0.000000	0.000000	-19791.000000	-2779.000000	-4310.000000	1.000000	1.000000	0.00000(
50%	278161.500000	0.000000	0.000000	-15874.000000	-1220.000000	-3294.000000	1.000000	1.000000	0.00000(
75%	367054.250000	0.000000	1.000000	-12552.000000	-271.000000	-1768.000000	1.000000	1.000000	0.00000(
max	456255.000000	1.000000	19.000000	-7489.000000	365243.000000	0.000000	1.000000	1.000000	1.00000(

- Se puede inferir que existen atributos que definen características que corresponden a categorías y se identifican como variables del tipo `int` , por lo que se realizará la transformación del tipo de dato a tipo `object` para proceder correctamente con los análisis posterires.
- Respecto del `TARGET` , se aprecia que existe más del 75% de los clientes son buenos pagadores, esto infiere que los clientes que tiene un mal comportamiento de pago no son la mayoría, además de indicar que el dataset se encuentra desbalanceado.
- La variable `DAYS_EMPLOYED` , cuenta con un valor máximo de 365243, lo que podria indicar un valor referencial asociado a cliente no presenta dias trabajados previos a la postulación, en los atributos `DAYS_REGISTRATION` y `DAYS_ID_PUBLISH` el valor máximo es 0.

2.8.4 Estadística básica datos categóricos

In [18]:
```
# Analisis estadistico datos categóricos
df_train.describe(include = 'object').T
```

Out[18]:

	count	unique	top	freq
CODE_GENDER	278232	2	F	182800
FLAG_OWN_CAR	278232	2	N	183775
FLAG_OWN_REALTY	278232	2	Y	190207
NAME_TYPE_SUITE	277225	7	Unaccompanied	224541

	count	unique	top	freq
NAME_INCOME_TYPE	278232	7	Working	142719
NAME_EDUCATION_TYPE	278232	5	Secondary / secondary special	200125
NAME_FAMILY_STATUS	278232	5	Married	178711
NAME_HOUSING_TYPE	278232	6	House / apartment	247389
OCCUPATION_TYPE	189432	18	Laborers	50131
WEEKDAY_APPR_PROCESS_START	278232	7	TUESDAY	49110
ORGANIZATION_TYPE	278232	58	Business Entity Type 3	60755
FONDKAPREMONT_MODE	87022	4	reg oper account	66104
HOUSETYPE_MODE	137401	3	block of flats	134949
WALLSMATERIAL_MODE	135590	7	Panel	59340
EMERGENCYSTATE_MODE	145123	2	No	143014

- Del análisis, existen varias categorías clasificadas en varios grupos, como el atributo `ORGANIZATION_TYPE` que tiene más de 58 niveles por lo que los atributos serán analizados y recodificados posteriormente.
- La mayoría de los clientes son mujeres que solicitaron el préstamo.
- Muchos de los clientes no tiene automovil, pero si son propietarios de una casa o departamento.
- Los clientes prefieren no ir acompañados y la mayoría trabajan.

2.9 Inspección de Valores Nulos

2.9.1 Porcentaje de valores nulos

In [19]:
```
# Porcentaje de atributos nulos por atributo del dataset
#==============================================================================================
pd.options.display.max_columns = None
missing_df = hlp.missing_values(df_train)
missing_df.T
```

Out[19]:

	COMMONAREA_AVG	COMMONAREA_MODE	COMMONAREA_MEDI	NONLIVINGAPARTMENTS_AVG	NONLIVINGAPARTMENTS_MODE	NONLIVINGAPART
Total Nulos	195236.000000	195236.000000	195236.000000	194054.000000	194054.000000	
Porcentaje	70.170218	70.170218	70.170218	69.745392	69.745392	

2.9.2 Atributos que superan umbral 45% de valores nulos

In [20]:
```
# Lista de atributos nulos que superan el porcentaje definido como umbral mayor a 45%
#==============================================================================================
columns_nulls = list(missing_df[missing_df["Porcentaje"] > 45].T.columns)
print(f'Lista de atributos que serán eliminados: \n\n{columns_nulls}\n')
print(f'Cantidad de columnas que serán eliminadas por superar umbral de datos nulos: {len(columns_nulls)} columnas.')
```

```
Lista de atributos que serán eliminados:

['COMMONAREA_AVG', 'COMMONAREA_MODE', 'COMMONAREA_MEDI', 'NONLIVINGAPARTMENTS_AVG', 'NONLIVINGAPARTMENTS_MODE', 'NONLIVINGAPARTMENTS_MED
I', 'FONDKAPREMONT_MODE', 'LIVINGAPARTMENTS_MEDI', 'LIVINGAPARTMENTS_AVG', 'LIVINGAPARTMENTS_MODE', 'FLOORSMIN_AVG', 'FLOORSMIN_MODE',
'FLOORSMIN_MEDI', 'YEARS_BUILD_AVG', 'YEARS_BUILD_MEDI', 'YEARS_BUILD_MODE', 'OWN_CAR_AGE', 'LANDAREA_MEDI', 'LANDAREA_AVG', 'LANDAREA_M
ODE', 'BASEMENTAREA_MEDI', 'BASEMENTAREA_AVG', 'BASEMENTAREA_MODE', 'EXT_SOURCE_1', 'NONLIVINGAREA_AVG', 'NONLIVINGAREA_MODE', 'NONLIVIN
GAREA_MEDI', 'ELEVATORS_MODE', 'ELEVATORS_AVG', 'ELEVATORS_MEDI', 'WALLSMATERIAL_MODE', 'APARTMENTS_AVG', 'APARTMENTS_MEDI', 'APARTMENTS
_MODE', 'ENTRANCES_AVG', 'ENTRANCES_MEDI', 'ENTRANCES_MODE', 'HOUSETYPE_MODE', 'LIVINGAREA_MEDI', 'LIVINGAREA_MODE', 'LIVINGAREA_AVG',
'FLOORSMAX_MEDI', 'FLOORSMAX_MODE', 'FLOORSMAX_AVG', 'YEARS_BEGINEXPLUATATION_MEDI', 'YEARS_BEGINEXPLUATATION_MODE', 'YEARS_BEGINEXPLUAT
ATION_AVG', 'TOTALAREA_MODE', 'EMERGENCYSTATE_MODE']

Cantidad de columnas que serán eliminadas por superar umbral de datos nulos: 49 columnas.
```

- Existe 49 atributos con más de 45% de valores nulos y que contienen los sufijos `AVG` (Promedio), `MODE` (Moda), `MEDI` (Mediana) que corresponden a las características del lugar donde vive el cliente. Estos datos serán eliminados ya que superan el umbral de porcentaje nulos definido, y además se encuentran normalizados. Como se desconoce los atributos originales desde donde se obtuvieron estos valores se eliminan porque no aportan información relevante para el caso de estudio.

2.9.3 Eliminación de valores nulos que superan umbral

In [21]:
```
# Eliminación de 49 Atributos que superan umbral de 45% de nulos
#==============================================================================================
```

```
columns_nulls_drop = ['COMMONAREA_AVG', 'COMMONAREA_MODE', 'COMMONAREA_MEDI', 'NONLIVINGAPARTMENTS_AVG', 'NONLIVINGAPARTMENTS_MODE', 'NO
df_train = df_train.drop(columns=columns_nulls_drop)
```

In [22]:
```
# Dimensión de la data posterior a la eliminación de atributos que superan umbral
df_train.shape
```

Out[22]:
```
(278232, 72)
```

2.9.4 Imputación de valores Nulos

- Se analiza el porcentaje de valores nulos de los atributos restantes para imputar los valores `NaN` por `Unknown` como reemplazo a los atributos categóricos o por imputar por la mediana o reemplazar por valor 0, según sea el caso para variables numéricas o eliminar el atributo.

In [23]:
```
# Nulos de variables categoricas
df_obj = df_train.select_dtypes(include=['object'])
missing_df_obj = hlp.missing_values(df_obj)
missing_df_obj.head(2)
```

Out[23]:

	Total Nulos	Porcentaje
OCCUPATION_TYPE	88800	31.915811
NAME_TYPE_SUITE	1007	0.361928

In [24]:
```
# Atributo OCCUPATION_TYPE - Profesion del cliente
#=================================================================================================
df_train['OCCUPATION_TYPE'] = df_train['OCCUPATION_TYPE'].replace(np.nan,'Unknown')
```

In [25]:
```
# Atributo NAME_TYPE_SUITE - Quien acompana al cliente cuando solicta el préstamo
#=================================================================================================
df_train['NAME_TYPE_SUITE'] = df_train['NAME_TYPE_SUITE'].replace(np.nan,'Unknown')
```

In [26]:
```
# Nulos de variables continuas
df_num = df_train.select_dtypes(include=['float64', 'int'])
missing_df_num = hlp.missing_values(df_num)
missing_df_num.head(14)
```

Out[26]:

	Total Nulos	Porcentaje
EXT_SOURCE_3	54658	19.644757
AMT_REQ_CREDIT_BUREAU_YEAR	37239	13.384154
AMT_REQ_CREDIT_BUREAU_QRT	37239	13.384154
AMT_REQ_CREDIT_BUREAU_MON	37239	13.384154
AMT_REQ_CREDIT_BUREAU_WEEK	37239	13.384154
AMT_REQ_CREDIT_BUREAU_DAY	37239	13.384154
AMT_REQ_CREDIT_BUREAU_HOUR	37239	13.384154
EXT_SOURCE_2	599	0.215288
AMT_ANNUITY	12	0.004313
DAYS_LAST_PHONE_CHANGE	1	0.000359
DEF_60_CNT_SOCIAL_CIRCLE	1	0.000359
OBS_60_CNT_SOCIAL_CIRCLE	1	0.000359
DEF_30_CNT_SOCIAL_CIRCLE	1	0.000359
OBS_30_CNT_SOCIAL_CIRCLE	1	0.000359

In [27]:
```
# Distribucion de EXT_SOURCE_3 y EXT_SOURCE_2 con valores nulos
plt.figure(figsize = (20,5))

# Atributo EXT_SOURCE_3 - Puntaje normalizado de fuente externa 3
plt.subplot(1,2,1)
plt.title('Distribución de atributo EXT_SOURCE_3',  fontsize=12);
sns.histplot(x="EXT_SOURCE_3",  data=df_train, kde=True, line_kws={'linewidth':1}, alpha=0.4);
plt.xlabel('Puntaje normalizado dado al cliente de fuente externa 3', fontsize = 10);

# Atributo EXT_SOURCE_2 - Puntaje normalizado de fuente externa 2
plt.subplot(1,2,2)
plt.title('Distribución de atributo EXT_SOURCE_2',  fontsize=12);
```

```
sns.histplot(x="EXT_SOURCE_2",  data=df_train, kde=True, line_kws={'linewidth':1}, alpha=0.4);
plt.xlabel('Puntaje normalizado dado al cliente de fuente externa 2', fontsize = 10);
```

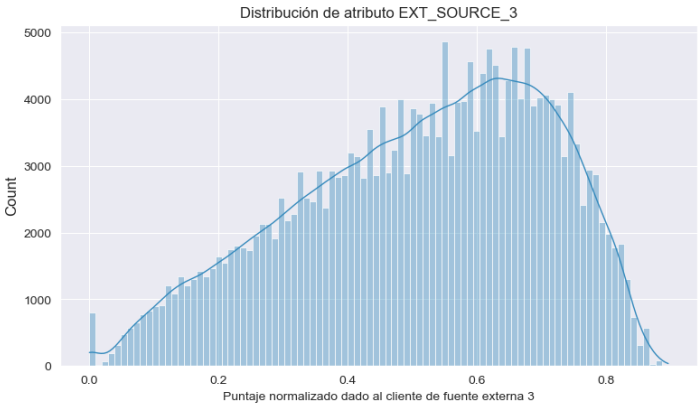

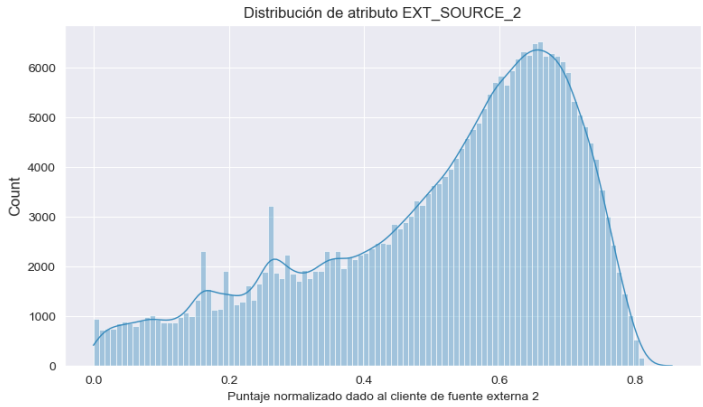

In [28]:

```
# Imputar por la mediana variable EXT_SOURCE_3
median_ext_source_3 = df_train['EXT_SOURCE_3'].median()

# Mediana de fuente externa 3 serializada
#=============================================================================================
pickle.dump(median_ext_source_3, open('median_ext_source_3.pkl', 'wb'))

# EXT_SOURCE_3 se reemplazan los valores NaN por la mediana
#=============================================================================================
df_train['EXT_SOURCE_3'] = df_train['EXT_SOURCE_3'].replace(np.nan, df_train['EXT_SOURCE_3'].median())
```

In [29]:

```
# Imputar por la mediana variable EXT_SOURCE_2, ya que cuenta con menos observaciones nulas
median_ext_source_2 = df_train['EXT_SOURCE_2'].median()

# Mediana de fuente externa 2 serializada
#=============================================================================================
pickle.dump(median_ext_source_2, open('median_ext_source_2.pkl', 'wb'))

# EXT_SOURCE_2 se reemplazan los valores NaN por la mediana
#=============================================================================================
df_train['EXT_SOURCE_2'] = df_train['EXT_SOURCE_2'].replace(np.nan, df_train['EXT_SOURCE_2'].median())
```

In [30]:

```
# Distribucion de EXT_SOURCE_3 y EXT_SOURCE_2 sin valores nulos
plt.figure(figsize = (20,5))

# Atributo EXT_SOURCE_3 - Puntaje normalizado de fuente externa 3
plt.subplot(1,2,1)
plt.title('Distribución de atributo EXT_SOURCE_3  Mediana:'+str(round(median_ext_source_3, 3)), fontsize=12);
sns.histplot(x="EXT_SOURCE_3",  data=df_train, kde=True, line_kws={'linewidth':1}, alpha=0.4);
plt.axvline(median_ext_source_3 ,  color = 'g', linestyle='--', lw = 3, label = 'Mediana' )
plt.xlabel('Puntaje normalizado dado al cliente de fuente externa 3', fontsize = 10);

# Atributo EXT_SOURCE_2 - Puntaje normalizado de fuente externa 2
plt.subplot(1,2,2)
plt.title('Distribución de atributo EXT_SOURCE_2  Mediana:'+str(round(median_ext_source_2, 3)), fontsize=12);
sns.histplot(x="EXT_SOURCE_2",  data=df_train, kde=True, line_kws={'linewidth':1}, alpha=0.4);
plt.axvline(median_ext_source_2 ,  color = 'g', linestyle='--', lw = 3, label = 'Mediana' )
plt.xlabel('Puntaje normalizado dado al cliente de fuente externa 2', fontsize = 10);
```

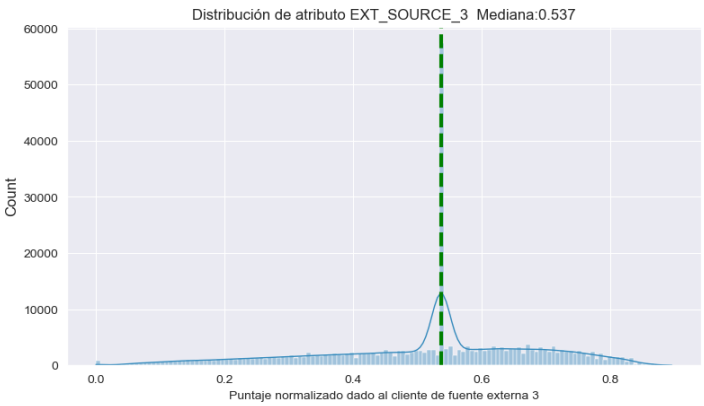

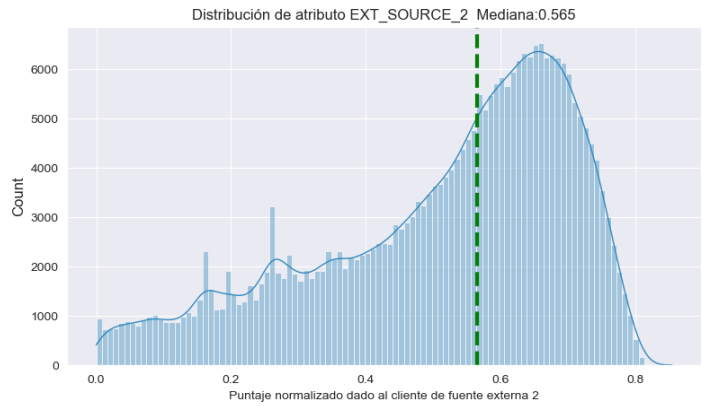

In [31]:

```
# Distribucion de atributos con valores nulos
plt.figure(figsize = (16,3))
df_amt_req_credit_bureau = df_train.loc[:, ['AMT_REQ_CREDIT_BUREAU_YEAR', 'AMT_REQ_CREDIT_BUREAU_QRT',
                                            'AMT_REQ_CREDIT_BUREAU_MON', 'AMT_REQ_CREDIT_BUREAU_WEEK',
```

```
                                        'AMT_REQ_CREDIT_BUREAU_DAY','AMT_REQ_CREDIT_BUREAU_HOUR']]
cols_amt_req = len(df_amt_req_credit_bureau.columns)
hlp.grid_plot_batch(df_amt_req_credit_bureau, cols_amt_req)
```

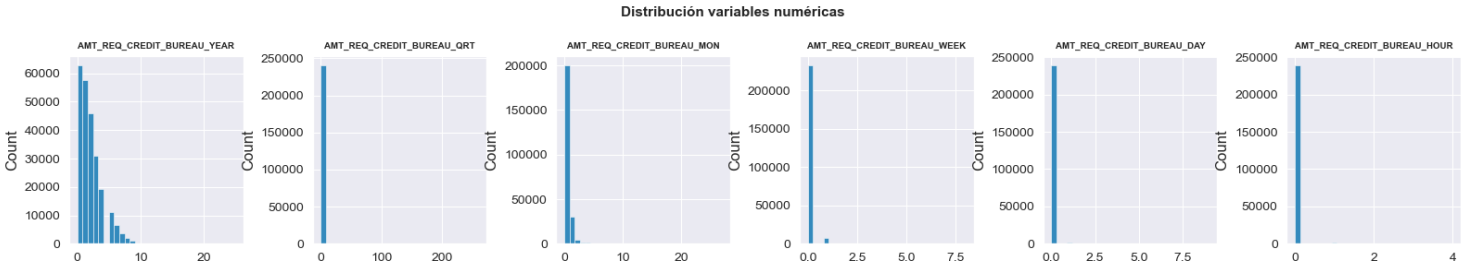

In [32]:

```
# Imputacion de nulos por valor 0 a los siguientes atributos:

# Atributo AMT_REQ_CREDIT_BUREAU_YEAR - Cantidad de consultas sobre el cliente al buró de credito. Una year antes de la postulacion
# AMT_REQ_CREDIT_BUREAU_YEAR se reemplazan los valores NaN por 0
#=============================================================================================
df_train['AMT_REQ_CREDIT_BUREAU_YEAR'] = df_train['AMT_REQ_CREDIT_BUREAU_YEAR'].replace(np.nan,0)

# AMT_REQ_CREDIT_BUREAU_QRT se reemplazan los valores NaN por 0
#=============================================================================================
df_train['AMT_REQ_CREDIT_BUREAU_QRT'] = df_train['AMT_REQ_CREDIT_BUREAU_QRT'].replace(np.nan,0)

# AMT_REQ_CREDIT_BUREAU_MON se reemplazan los valores NaN por 0
#=============================================================================================
df_train['AMT_REQ_CREDIT_BUREAU_MON'] = df_train['AMT_REQ_CREDIT_BUREAU_MON'].replace(np.nan,0)

# AMT_REQ_CREDIT_BUREAU_WEEK se reemplazan los valores NaN por 0
#=============================================================================================
df_train['AMT_REQ_CREDIT_BUREAU_WEEK'] = df_train['AMT_REQ_CREDIT_BUREAU_WEEK'].replace(np.nan,0)

# AMT_REQ_CREDIT_BUREAU_YEAR se reemplazan los valores NaN por 0
#=============================================================================================
df_train['AMT_REQ_CREDIT_BUREAU_DAY'] = df_train['AMT_REQ_CREDIT_BUREAU_DAY'].replace(np.nan,0)

# AMT_REQ_CREDIT_BUREAU_HOUR se reemplazan los valores NaN por 0
#=============================================================================================
df_train['AMT_REQ_CREDIT_BUREAU_HOUR'] = df_train['AMT_REQ_CREDIT_BUREAU_HOUR'].replace(np.nan,0)
```

In [33]:

```
# Distribucion de atributos con 1 valor nulo
plt.figure(figsize = (16,3))
df_annuity_def_obs_dayslastphone = df_train.loc[:, ['AMT_ANNUITY', 'DAYS_LAST_PHONE_CHANGE', 'DEF_60_CNT_SOCIAL_CIRCLE',
                                                    'OBS_60_CNT_SOCIAL_CIRCLE', 'DEF_30_CNT_SOCIAL_CIRCLE', 'OBS_30_CNT_SOCIAL_CIRCLE']]
cols = len(df_annuity_def_obs_dayslastphone.columns)
hlp.grid_plot_batch(df_annuity_def_obs_dayslastphone, cols)
```

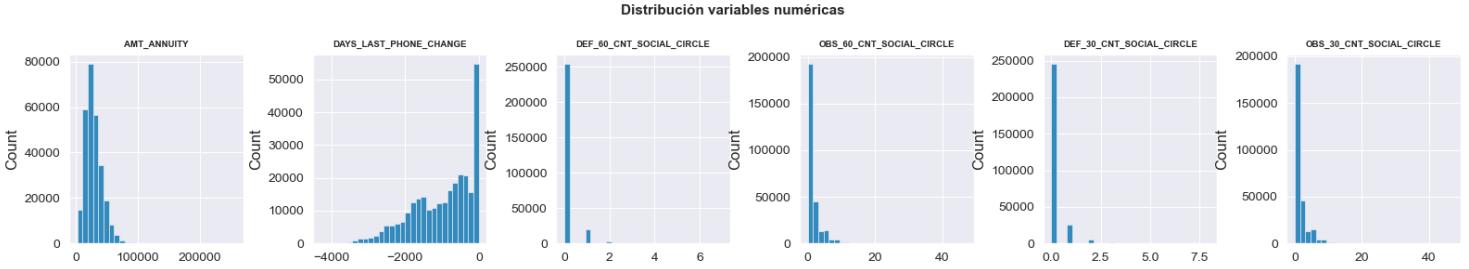

In [34]:

```
# Imputacion de nulos por valor 0 a los siguientes atributos:

# AMT_ANNUITY se reemplazan los valores NaN por 0
#=============================================================================================
df_train['AMT_ANNUITY'] = df_train['AMT_ANNUITY'].replace(np.nan,0)

# DAYS_LAST_PHONE_CHANGE se reemplazan los valores NaN por 0
#=============================================================================================
df_train['DAYS_LAST_PHONE_CHANGE'] = df_train['DAYS_LAST_PHONE_CHANGE'].replace(np.nan,0)

# DEF_60_CNT_SOCIAL_CIRCLE se reemplazan los valores NaN por 0
#=============================================================================================
df_train['DEF_60_CNT_SOCIAL_CIRCLE'] = df_train['DEF_60_CNT_SOCIAL_CIRCLE'].replace(np.nan,0)

# OBS_60_CNT_SOCIAL_CIRCLE se reemplazan los valores NaN por 0
#=============================================================================================
df_train['OBS_60_CNT_SOCIAL_CIRCLE'] = df_train['OBS_60_CNT_SOCIAL_CIRCLE'].replace(np.nan,0)

# DEF_30_CNT_SOCIAL_CIRCLE se reemplazan los valores NaN por 0
#=============================================================================================
```

```
df_train['DEF_30_CNT_SOCIAL_CIRCLE'] = df_train['DEF_30_CNT_SOCIAL_CIRCLE'].replace(np.nan,0)

# OBS_30_CNT_SOCIAL_CIRCLE se reemplazan los valores NaN por 0
#=============================================================================================
df_train['OBS_30_CNT_SOCIAL_CIRCLE'] = df_train['OBS_30_CNT_SOCIAL_CIRCLE'].replace(np.nan,0)
```

In [35]:
```
# Resultado sin nulos en las variables
hlp.missing_values(df_train)
```

Out[35]:

	Total Nulos	Porcentaje
SK_ID_CURR	0	0.0
TARGET	0	0.0
FLAG_DOCUMENT_8	0	0.0
FLAG_DOCUMENT_7	0	0.0
FLAG_DOCUMENT_6	0	0.0
...	...	...
FLAG_CONT_MOBILE	0	0.0
FLAG_WORK_PHONE	0	0.0
FLAG_EMP_PHONE	0	0.0
FLAG_MOBIL	0	0.0
AMT_REQ_CREDIT_BUREAU_YEAR	0	0.0

72 rows × 2 columns

- Para proceder con el análisis univariado de los atributos restantes, se procederá con la transformación del tipo de dato, para posteriormente separar por tipo de datos y la visualización con gráficos para continuar con el análisis de posibles atributos a ser eliminados, transformación o la recodificación según sea el caso.

2.10 Transformación de tipo de datos

In [36]:
```
# Columnas numéricas a modificar su tipo de dato
#=============================================================================================
columns_a_type_object = [ 'FLAG_MOBIL', 'FLAG_CONT_MOBILE',
                          'FLAG_EMAIL', 'REGION_RATING_CLIENT_W_CITY',
                          'HOUR_APPR_PROCESS_START', 'REG_REGION_NOT_LIVE_REGION',
                          'REG_REGION_NOT_WORK_REGION', 'LIVE_REGION_NOT_WORK_REGION',
                          'FLAG_DOCUMENT_2','FLAG_DOCUMENT_3','FLAG_DOCUMENT_4','FLAG_DOCUMENT_5','FLAG_DOCUMENT_6',
                          'FLAG_DOCUMENT_7','FLAG_DOCUMENT_8','FLAG_DOCUMENT_9','FLAG_DOCUMENT_10','FLAG_DOCUMENT_11',
                          'FLAG_DOCUMENT_12','FLAG_DOCUMENT_13','FLAG_DOCUMENT_14','FLAG_DOCUMENT_15','FLAG_DOCUMENT_16',
                          'FLAG_DOCUMENT_17','FLAG_DOCUMENT_18','FLAG_DOCUMENT_19','FLAG_DOCUMENT_20','FLAG_DOCUMENT_21'
                          ]
```

In [37]:
```
# Modificación del tipo de dato
#=============================================================================================
df_train[columns_a_type_object] = df_train[columns_a_type_object].astype('object')
```

In [38]:
```
# Tipo de datos
df_train.dtypes.value_counts()
```

Out[38]:
```
object     39
float64    20
int64      13
dtype: int64
```

In [39]:
```
df_obj = df_train.select_dtypes(include=['object'])
df_obj.columns
```

Out[39]:
```
Index(['CODE_GENDER', 'FLAG_OWN_CAR', 'FLAG_OWN_REALTY', 'NAME_TYPE_SUITE',
       'NAME_INCOME_TYPE', 'NAME_EDUCATION_TYPE', 'NAME_FAMILY_STATUS',
       'NAME_HOUSING_TYPE', 'FLAG_MOBIL', 'FLAG_CONT_MOBILE', 'FLAG_EMAIL',
       'OCCUPATION_TYPE', 'REGION_RATING_CLIENT_W_CITY',
       'WEEKDAY_APPR_PROCESS_START', 'HOUR_APPR_PROCESS_START',
       'REG_REGION_NOT_LIVE_REGION', 'REG_REGION_NOT_WORK_REGION',
       'LIVE_REGION_NOT_WORK_REGION', 'ORGANIZATION_TYPE', 'FLAG_DOCUMENT_2',
       'FLAG_DOCUMENT_3', 'FLAG_DOCUMENT_4', 'FLAG_DOCUMENT_5',
       'FLAG_DOCUMENT_6', 'FLAG_DOCUMENT_7', 'FLAG_DOCUMENT_8',
       'FLAG_DOCUMENT_9', 'FLAG_DOCUMENT_10', 'FLAG_DOCUMENT_11',
       'FLAG_DOCUMENT_12', 'FLAG_DOCUMENT_13', 'FLAG_DOCUMENT_14',
       'FLAG_DOCUMENT_15', 'FLAG_DOCUMENT_16', 'FLAG_DOCUMENT_17',
```

```
       'FLAG_DOCUMENT_18', 'FLAG_DOCUMENT_19', 'FLAG_DOCUMENT_20',
       'FLAG_DOCUMENT_21'],
      dtype='object')
```

In [40]:
```
df_num = df_train.select_dtypes(include=['float64', 'int'])
df_num.columns
```

Out[40]:
```
Index(['SK_ID_CURR', 'TARGET', 'CNT_CHILDREN', 'AMT_INCOME_TOTAL',
       'AMT_CREDIT', 'AMT_ANNUITY', 'AMT_GOODS_PRICE',
       'REGION_POPULATION_RELATIVE', 'DAYS_BIRTH', 'DAYS_EMPLOYED',
       'DAYS_REGISTRATION', 'DAYS_ID_PUBLISH', 'FLAG_EMP_PHONE',
       'FLAG_WORK_PHONE', 'FLAG_PHONE', 'CNT_FAM_MEMBERS',
       'REGION_RATING_CLIENT', 'REG_CITY_NOT_LIVE_CITY',
       'REG_CITY_NOT_WORK_CITY', 'LIVE_CITY_NOT_WORK_CITY', 'EXT_SOURCE_2',
       'EXT_SOURCE_3', 'OBS_30_CNT_SOCIAL_CIRCLE', 'DEF_30_CNT_SOCIAL_CIRCLE',
       'OBS_60_CNT_SOCIAL_CIRCLE', 'DEF_60_CNT_SOCIAL_CIRCLE',
       'DAYS_LAST_PHONE_CHANGE', 'AMT_REQ_CREDIT_BUREAU_HOUR',
       'AMT_REQ_CREDIT_BUREAU_DAY', 'AMT_REQ_CREDIT_BUREAU_WEEK',
       'AMT_REQ_CREDIT_BUREAU_MON', 'AMT_REQ_CREDIT_BUREAU_QRT',
       'AMT_REQ_CREDIT_BUREAU_YEAR'],
      dtype='object')
```

2.11 Análisis univariable de atributos con Gráficos

- Del análisis en la estadística descriptiva, se observa que los valores en varias de las observaciones vienen dados en días negativos, en los atributos `DAYS_BIRTH`, `DAYS_EMPLOYED`, `DAYS_REGISTRATION`, `DAYS_ID_PUBLISH` y `DAYS_LAST_PHONE_CHANGE`, los que serán transformados a valores positivos, para dar claridad y mejor entendimiento de la variable a analizar.

Se separan los datos por tipo de datos para analizarlos, limpiarlos, recodificarlos o transformarlos, según corresponda.

2.11.1 Descripción de datos continuos y discretos

Atributos :

- `SK_ID_CURR` : Id préstamo realizado.
- `CNT_CHILDREN` : Cantidad de hijos por parte del cliente.
- `AMT_INCOME_TOTAL` : Ingreso total del cliente.
- `AMT_CREDIT` : Cantidad total del préstamo realizado.
- `AMT_ANNUITY` : Anualidad del préstamo.
- `AMT_GOODS_PRICE` : Para préstamos de consumo representa el precio de los bienes que se comprara con el préstamo.
- `REGION_POPULATION_RELATIVE` : Población donde vive el cliente.
- `DAYS_BIRTH` : Edad del cliente cuando solicitó el préstamo.
- `DAYS_EMPLOYED` : Cantidad de días trabajados previos a la postulación.
- `DAYS_REGISTRATION` : Cantidad de días previos a la última modificación de los registros del cliente previos a la postulación.
- `DAYS_ID_PUBLISH` : Cantidad de días previos a la modificaciòn de su documento de identificaciòn con el cual postulación al préstamo.
- `FLAG_EMP_PHONE` : Da un teléfono de trabajo de contacto.
- `FLAG_WORK_PHONE` : Da un teléfono de hogar de contacto.
- `FLAG_PHONE` : Da un teléfono contacto el cliente.
- `CNT_FAM_MEMBERS` : Cuántos miembros familiares tiene el cliente.
- `REGION_RATING_CLIENT` : Evaluación interna (de Home Credit Group) sobre la región donde vive el cliente.
- `REG_CITY_NOT_LIVE_CITY` : Identificador booleano si es que la dirección permanente no concuerda con la dirección de contacto.
- `REG_CITY_NOT_WORK_CITY` : Identificador booleano si es que la dirección permanente no concuerda con la dirección del trabajo.
- `LIVE_CITY_NOT_WORK_CITY` : Identificador booleano si es que la dirección de contacto del cliente no concuerda con la dirección del trabajo.
- `EXT_SOURCE_2` : Puntaje normalizado de fuente externa.
- `EXT_SOURCE_3` : Puntaje normalizado de fuente externa.
- `OBS_30_CNT_SOCIAL_CIRCLE` : Cuántas veces ha registrado mora más de 30 días su entorno.
- `DEF_30_CNT_SOCIAL_CIRCLE` : Cuántas veces ha registrado mora más de 30 días su entorno.
- `OBS_60_CNT_SOCIAL_CIRCLE` : Cuántas veces ha registrado mora más de 60 días su entorno.
- `DEF_60_CNT_SOCIAL_CIRCLE` : Cuántas veces ha registrado mora más de 60 días su entorno.
- `DAYS_LAST_PHONE_CHANGE` : Hace cuántos días antes de la postulación cambia número de teléfono.
- `AMT_REQ_CREDIT_BUREAU_HOUR` : Cantidad de consultas sobre el cliente al buró de crédito. Una hora antes de la postulación.
- `AMT_REQ_CREDIT_BUREAU_DAY` : Cantidad de consultas sobre el cliente al buró de crédito. Un día antes de la postulación
- `AMT_REQ_CREDIT_BUREAU_WEEK` : Cantidad de consultas sobre el cliente al buró de crédito. Una semana antes de la postulación.
- `AMT_REQ_CREDIT_BUREAU_MON` : Cantidad de consultas sobre el cliente al buró de crédito. Un mes antes de la postulación.
- `AMT_REQ_CREDIT_BUREAU_QRT` : Cantidad de consultas sobre el cliente al buró de crédito. Tres meses antes de la postulación.
- `AMT_REQ_CREDIT_BUREAU_YEAR` : Cantidad de consultas sobre el cliente al buró de crédito. Un año antes de la postulación.

2.11.2 Creación y transformación de atributos

In [41]:
```
# Transformar la edad en años del atributo DAYS_BIRTH a valores positivos
#=============================================================================================
df_train['AGE'] = (df_train['DAYS_BIRTH'] * -1 ) /365
```

In [42]:
```
# Creación de variable RATIO_CREDIT_INCOME indica la proporcion ingreso-prestamo
#=============================================================================================
df_train["RATIO_CREDIT_INCOME"] = df_train["AMT_INCOME_TOTAL"] / df_train["AMT_CREDIT"]
```

In [43]:
```
# Selección de datos continuos para realizar graficos
#=============================================================================================
df_train_num = df_train.select_dtypes(include=['float64', 'int'])
df_train_num.columns
```

Out[43]:
```
Index(['SK_ID_CURR', 'TARGET', 'CNT_CHILDREN', 'AMT_INCOME_TOTAL',
       'AMT_CREDIT', 'AMT_ANNUITY', 'AMT_GOODS_PRICE',
       'REGION_POPULATION_RELATIVE', 'DAYS_BIRTH', 'DAYS_EMPLOYED',
       'DAYS_REGISTRATION', 'DAYS_ID_PUBLISH', 'FLAG_EMP_PHONE',
       'FLAG_WORK_PHONE', 'FLAG_PHONE', 'CNT_FAM_MEMBERS',
       'REGION_RATING_CLIENT', 'REG_CITY_NOT_LIVE_CITY',
       'REG_CITY_NOT_WORK_CITY', 'LIVE_CITY_NOT_WORK_CITY', 'EXT_SOURCE_2',
       'EXT_SOURCE_3', 'OBS_30_CNT_SOCIAL_CIRCLE', 'DEF_30_CNT_SOCIAL_CIRCLE',
       'OBS_60_CNT_SOCIAL_CIRCLE', 'DEF_60_CNT_SOCIAL_CIRCLE',
       'DAYS_LAST_PHONE_CHANGE', 'AMT_REQ_CREDIT_BUREAU_HOUR',
       'AMT_REQ_CREDIT_BUREAU_DAY', 'AMT_REQ_CREDIT_BUREAU_WEEK',
       'AMT_REQ_CREDIT_BUREAU_MON', 'AMT_REQ_CREDIT_BUREAU_QRT',
       'AMT_REQ_CREDIT_BUREAU_YEAR', 'AGE', 'RATIO_CREDIT_INCOME'],
      dtype='object')
```

2.11.3 Gráficos variables continuas

Gráfico de los atributos:

- `AMT_INCOME_TOTAL` : Ingreso total del cliente.
- `AMT_CREDIT` : Cantidad total del préstamo realizado.
- `AMT_ANNUITY` : Anualidad del préstamo.

In [44]:
```
# Graficos boxplot de atributos
data_graf_num1 = df_train_num.loc[:, [ 'AMT_INCOME_TOTAL', 'AMT_CREDIT', 'AMT_ANNUITY']]
hlp.grafico_boxplot(data_graf_num1)
```

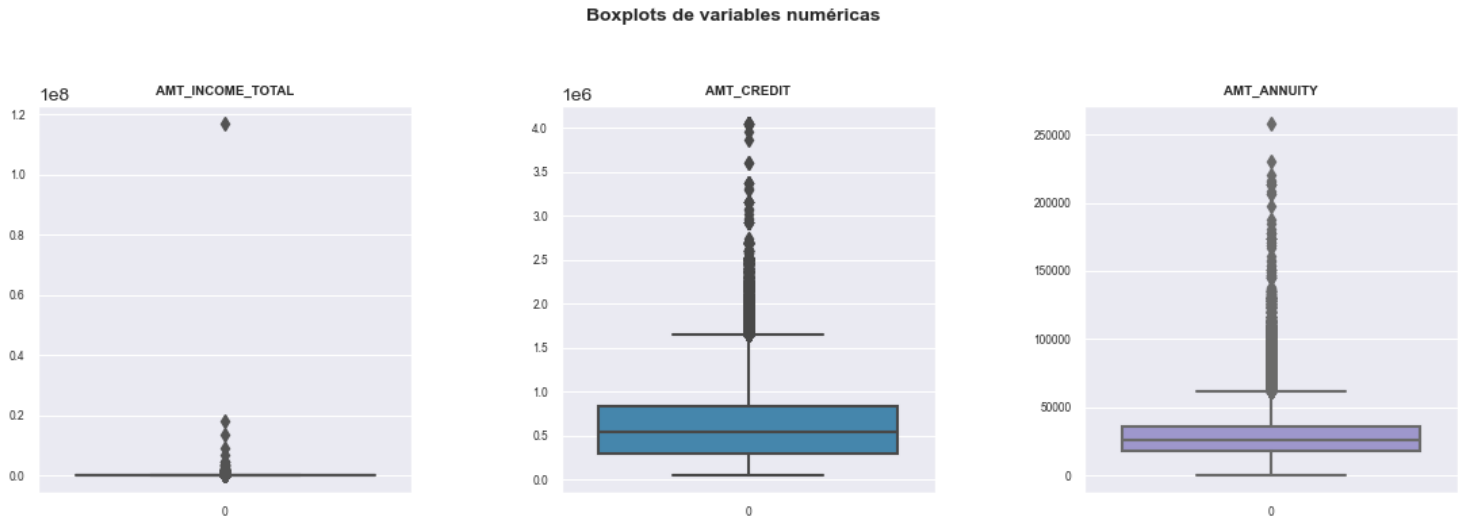

- Los atributos `AMT_INCOME_TOTAL` , `AMT_CREDIT` y `AMT_ANNUITY` , se transformarán utilizando logaritmo para visualizar si presentan una distribución más cercana a la distribución normal.

In [45]:
```
# Analisis con histograma variable AMT_INCOME_TOTAL - Ingreso total del cliente #
hlp.histograma(df_train_num, 'AMT_INCOME_TOTAL', 'Ingreso total del cliente')
```

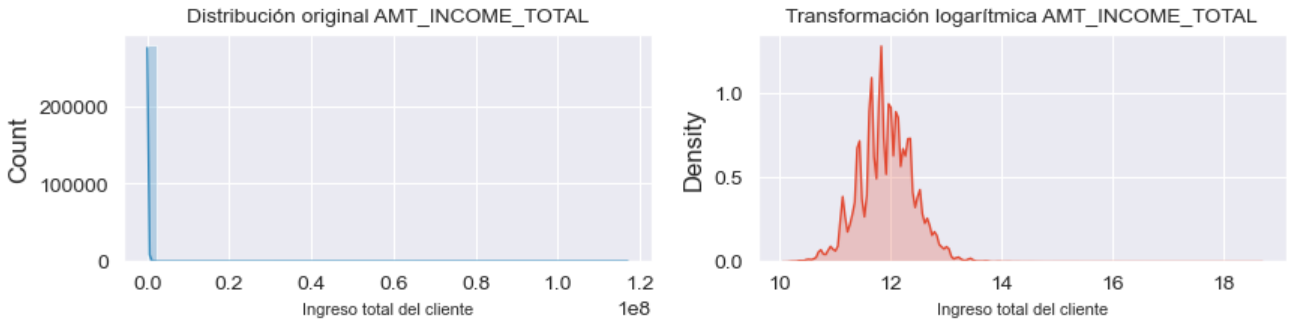

- Al transformar la variable `AMT_INCOME_TOTAL`, ésta mejora y presenta una distribución más cercana a la distribución normal, por lo que la variable original será eliminada para ser reprocesada.

In [46]:
```
# Reprocesar AMT_INCOME_TOTAL - Ingreso total del cliente
#=============================================================================================
df_train['LOG_AMT_INCOME_TOTAL'] = np.log(df_train['AMT_INCOME_TOTAL'])
```

In [47]:
```
# Analisis con histograma variable AMT_CREDIT - Cantidad total del préstamo realizado #
hlp.histograma(df_train_num, 'AMT_CREDIT', 'Cantidad total del préstamo realizado')
```

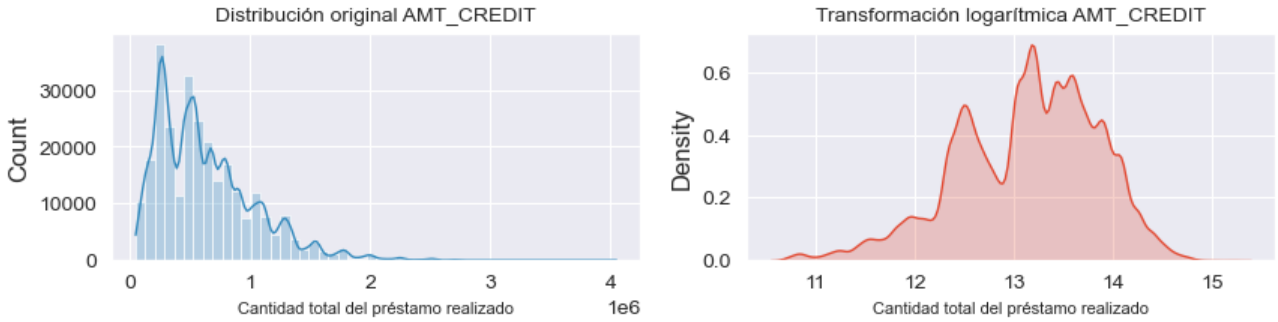

- Al transformar la variable `AMT_CREDIT`, ésta mejora y presenta una distribución más cercana a la distribución normal, por lo que la variable original será eliminada para ser reprocesada.

In [48]:
```
# Reprocesar AMT_CREDIT - Cantidad total del préstamo realizado
#=============================================================================================
df_train['LOG_AMT_CREDIT'] = np.log(df_train['AMT_CREDIT'])
```

In [49]:
```
# Analisis con histograma de variable RATIO_CREDIT_INCOME
hlp.histograma(df_train_num, 'RATIO_CREDIT_INCOME', 'Proporción Ingreso-Préstamo')
```

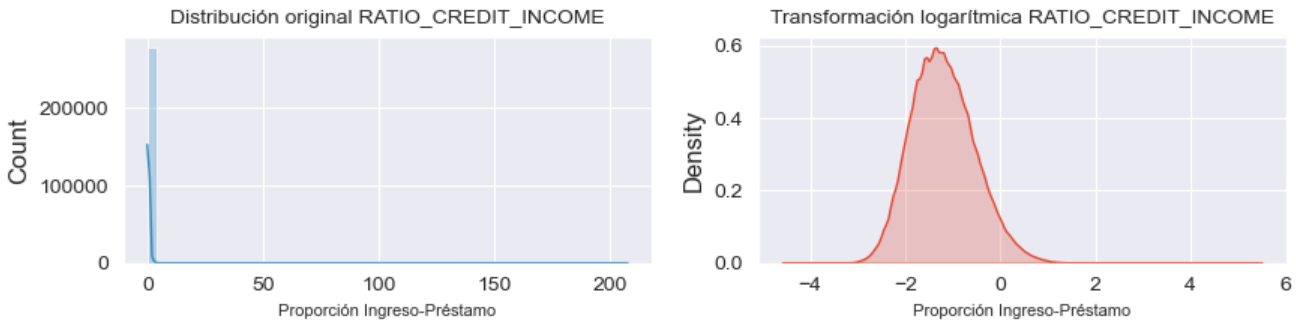

In [50]:
```
# Analisis con histograma de variable AMT_ANNUITY - Anualidad del préstamo #
hlp.histograma(df_train_num, 'AMT_ANNUITY', 'Anualidad del préstamo')
```

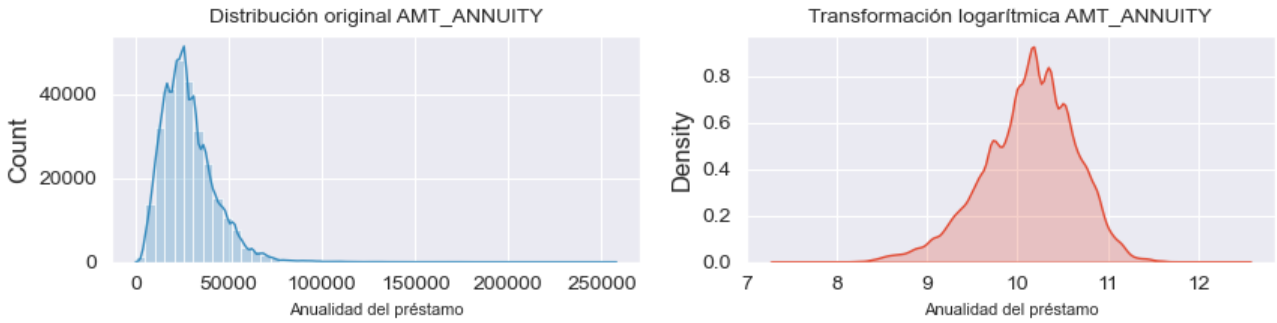

- Al transformar la variable `AMT_ANNUITY`, ésta mejora y presenta una distribución más cercana a la distribución normal, por lo que la variable original será eliminada para ser reprocesada.

In [51]:
```
# Reprocesar AMT_ANNUITY - Anualidad del préstamo
#=============================================================================================
df_train['LOG_AMT_ANNUITY'] = np.log(df_train['AMT_ANNUITY'])
```

Gráficos de los atributos :

- `AMT_GOODS_PRICE` : Representa el precio de los bienes que se comprará con el préstamo.
- `REGION_POPULATION_RELATIVE` : Población donde vive el cliente (la variable está normalizada, donde valores más altos significan que el cliente vive en una región más poblada).
- `AGE` : Edad del cliente cuando solicitó el préstamo.

In [52]:
```
# Graficos boxplot de atributos
data_graf_num2 = df_train_num.loc[:, [ 'AMT_GOODS_PRICE', 'REGION_POPULATION_RELATIVE', 'AGE']]
hlp.grafico_boxplot(data_graf_num2)
```

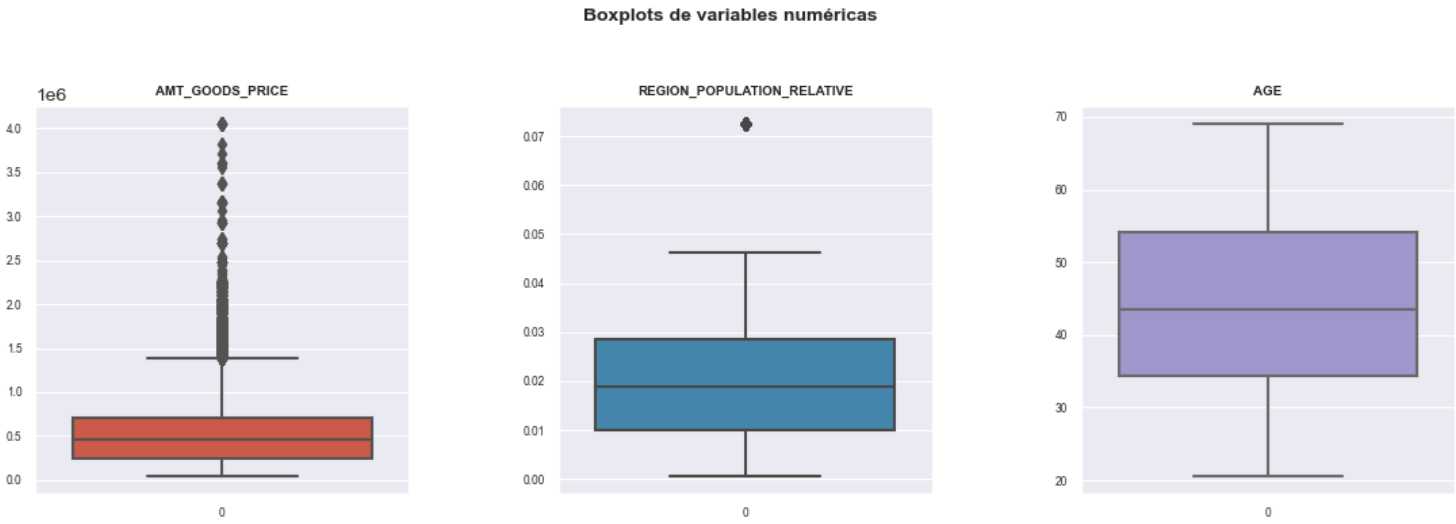

- El atributo `AMT_GOODS_PRICE`, se transformará utilizando logaritmo para visualizar si presenta una distribución más cercana a la distribución normal.
- Los atributos `REGION_POPULATION_RELATIVE` y `AGE`, serán analizados y comparados con el vector objetivo.

In [53]:
```
# Analisis con histograma de variable AMT_GOODS_PRICE - Precio de los bienes que se comprará con el préstamo #
hlp.histograma(df_train_num, 'AMT_GOODS_PRICE', 'Precio de los bienes que se comprará con el préstamo')
```

- Al transformar la variable `AMT_GOODS_PRICE`, esta mejora y presenta una distribución mas cercana a la distribución normal, por lo que la variable original será eliminada para ser reprocesada.

In [54]:
```
# Reprocesar AMT_GOODS_PRICE - Precio de los bienes que se comprara con el préstamo
#=================================================================================================
df_train['LOG_AMT_GOODS_PRICE'] = np.log(df_train['AMT_GOODS_PRICE'])
```

In [55]:
```
# Analisis con histograma de variable REGION_POPULATION_RELATIVE - Población donde vive el cliente #
plt.figure(figsize=(15, 3));
plt.subplot(1,2,1)
sns.histplot(df_train['REGION_POPULATION_RELATIVE'], kde=True, bins=50,  line_kws={'linewidth':1}, alpha = 0.3);
plt.title('Distribución de la población donde vive el cliente',  fontsize=8);
```

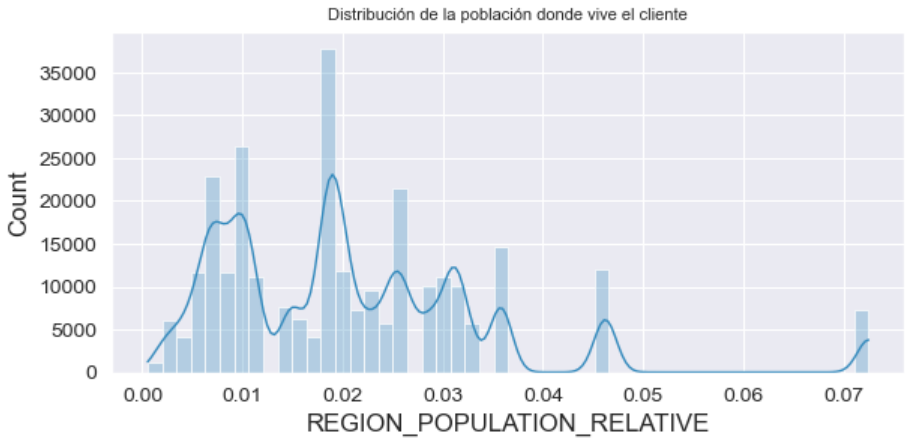

- Valores más altos indican que el cliente vive en una región más poblada

In [56]:
```
# Analisis con histograma de variable AGE - Edad del cliente #
plt.figure(figsize=(15, 3));
plt.subplot(1,2,1)
mu = round(np.mean(df_train['AGE']))
print(f'Media: {mu}')
plt.title('Distribución de la edad del cliente',  fontsize=10);
sns.histplot(df_train['AGE'], kde=True, bins=50,  line_kws={'linewidth':1}, alpha = 0.3);
plt.axvline(mu , color='b', linestyle='--' , lw='3', label = 'Media')
plt.xlabel('Edad');
```

```
Media: 44
```

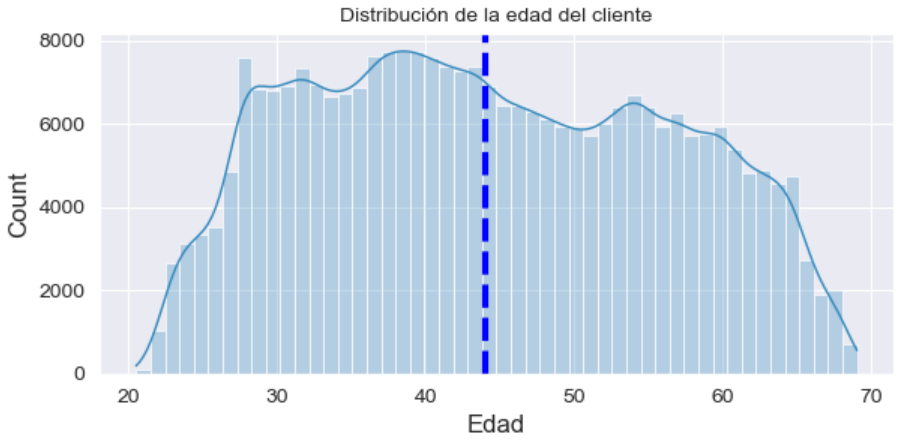

- La distribución de la edad indica que los clientes que solicitan crédito en efectivo, ya sea buenos o malos pagadores fluctúa entre los 20 y 70 años, con un promedio de edad de 44 años.

Gráfico de los atributos :

- `DAYS_EMPLOYED` : Cantidad de días trabajados previos a la postulación.
- `DAYS_REGISTRATION` : Cantidad de días previos a la última modificación de los registros del cliente previos a la postulación.
- `DAYS_ID_PUBLISH` : Cantidad de días previos a la modificación de su documento de identificación con el cual realizo la postulación al préstamo.

In [57]:
```
# Graficos boxplot de atributos
data_graf_num3 = df_train_num.loc[:, [ 'DAYS_EMPLOYED', 'DAYS_REGISTRATION', 'DAYS_ID_PUBLISH']]
hlp.grafico_boxplot(data_graf_num3)
```

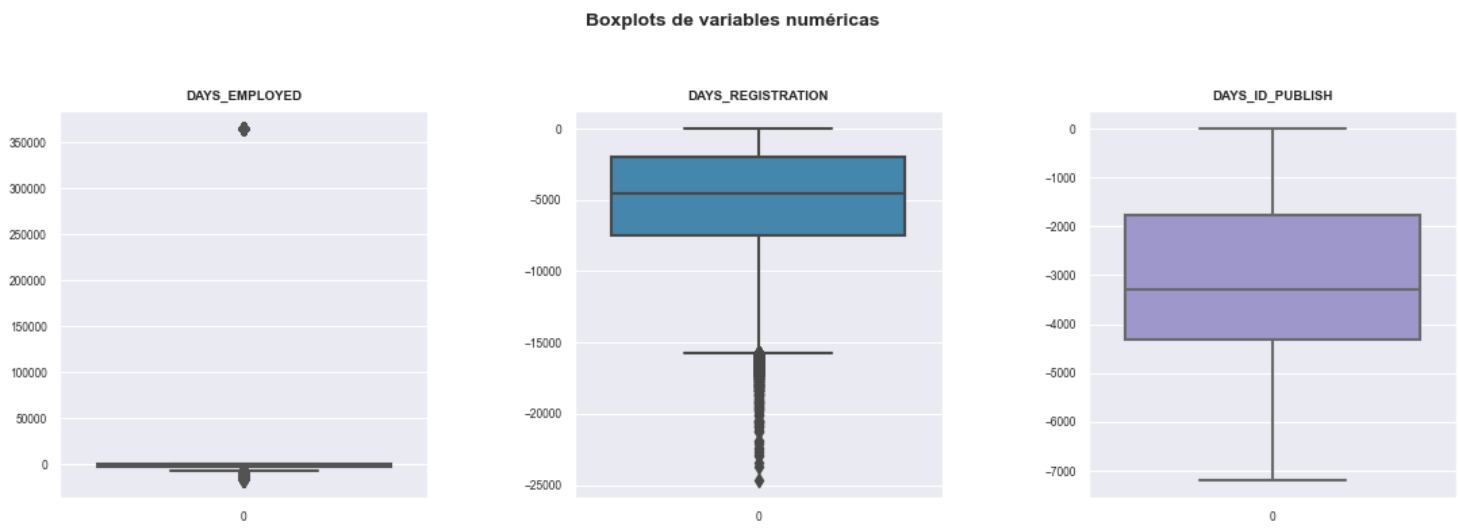

- La distribución de las observaciones para la variable `DAYS_EMPLOYED` , `DAYS_REGISTRATION` y `DAYS_ID_PUBLISH` presentan valores negativos, por lo que serán transformados a valores positvos, y transformadas a logarítmicas o categóricas según sea el caso.

In [58]:
```
# Estadistica de variable DAYS_EMPLOYED, DAYS_REGISTRATION y DAYS_ID_PUBLISH
df_train_num.loc[:, ['DAYS_EMPLOYED', 'DAYS_REGISTRATION' ,'DAYS_ID_PUBLISH']].describe()
```

Out[58]:

	DAYS_EMPLOYED	DAYS_REGISTRATION	DAYS_ID_PUBLISH
count	278232.000000	278232.000000	278232.000000
mean	66310.442020	-5009.613488	-3020.079240
std	143346.548212	3535.561853	1501.233328
min	-17912.000000	-24672.000000	-7197.000000
25%	-2779.000000	-7509.000000	-4310.000000
50%	-1220.000000	-4522.000000	-3294.000000
75%	-271.000000	-2028.000000	-1768.000000
max	365243.000000	0.000000	0.000000

- La variable `DAYS_EMPLOYED` , cuenta con un valor máximo de 365243, lo que podria indicar un valor referencial asociado a cliente no presenta dias trabajados previos a la postulación, en los atributos `DAYS_REGISTRATION` y `DAYS_ID_PUBLISH` el valor máximo es 0.

In [59]:
```
# Analisis con histograma de variable DAYS_EMPLOYED - Cantidad de días trabajados previos a la postulación #
hlp.histograma(df_train_num, 'DAYS_EMPLOYED', 'Cantidad de días trabajados previos a la postulación')
```

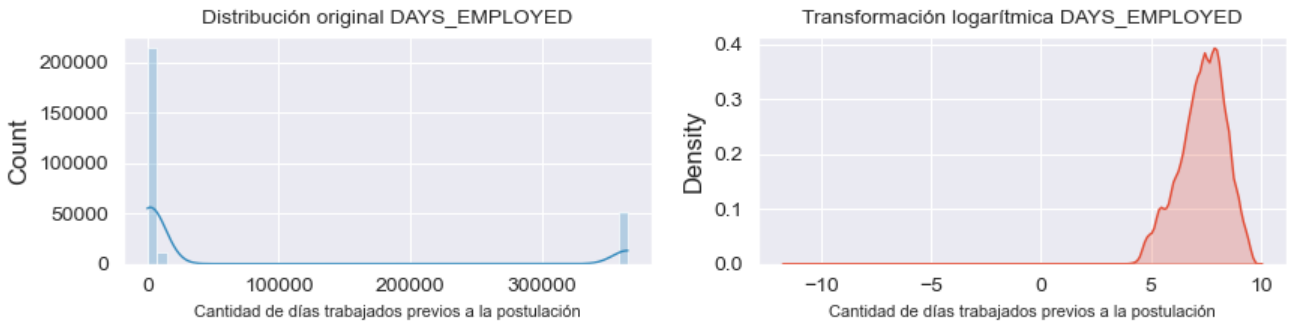

- En esta gráfica el atributo `DAYS_EMPLOYED` , apenas toma unos pocos valores y la gran mayoría de las observaciones pertenecen a solo dos de ellos, por lo que el atributo será transformado, en los que las observaciones serán condicionadas a valores menores a 0 en los que tomará el valor 1, para los casos en que el cliente presenta días trabajados y tomará el valor 0 en caso contrario.

In [60]:
```
# Transformar DAYS_EMPLOYED - Cantidad de días trabajados previos a la postulación
#=================================================================================================
df_train['WITH_DAYS_WORKED'] = np.where(df_train['DAYS_EMPLOYED'] < 0, 1 , 0)

df_train['WITH_DAYS_WORKED'] = df_train['WITH_DAYS_WORKED'].astype('int')
```

In [61]:
```
# Analisis con histograma variable DAYS_REGISTRATION - Cantidad de días previos a la última modificación de los registros del cliente pr
hlp.histograma(df_train_num, 'DAYS_REGISTRATION', 'Cantidad de días trabajados previos a la última modificación')
```

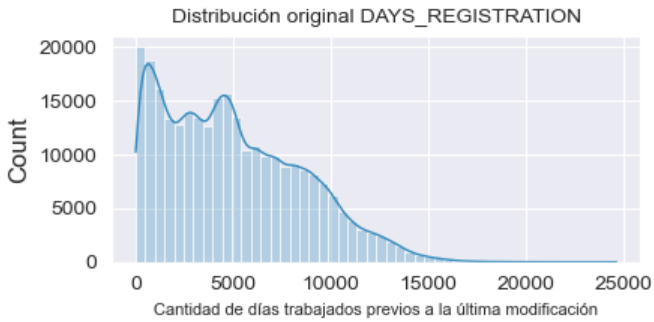

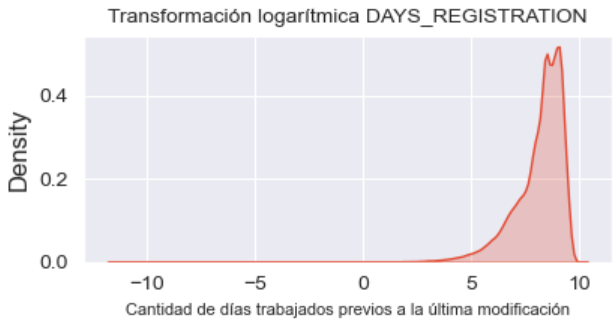

- Al transformar la variable `DAYS_REGISTRATION`, esta mejora y presenta una distribución mas cercana a la distribución normal, por lo que la variable original será eliminada para ser reprocesada.

In [62]:
```
# Transformar DAYS_REGISTRATION - Cantidad de días previos a la última modificación de sus registros
#=================================================================================================
df_train['LOG_DAYS_REGISTRATION'] = np.log(df_train['DAYS_REGISTRATION']*-1 + 0.00001)
```

In [63]:
```
# Analisis con histograma variable DAYS_REGISTRATION - Cantidad de días previos a la modificación de su CI con el cual realizo la postul
hlp.histograma(df_train_num, 'DAYS_ID_PUBLISH', 'Cantidad de días trabajados previos a la modificación de su CI')
```

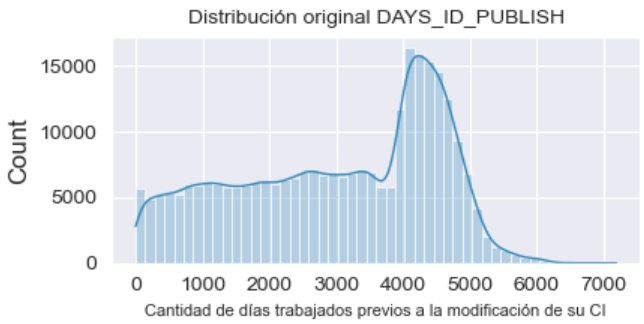

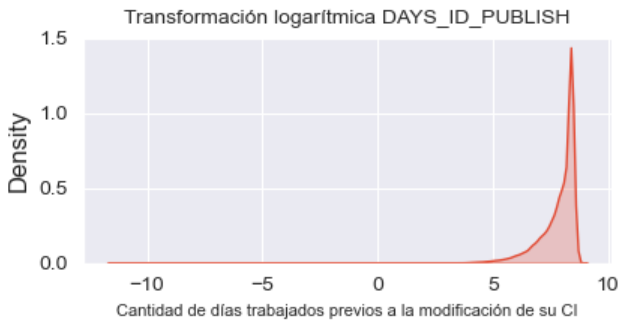

- Al transformar la variable `DAYS_ID_PUBLISH`, ésta mejora y presenta una distribución más cercana a la distribución normal, por lo que la variable original será eliminada para ser reprocesada.

In [64]:
```
# Transformar DAYS_ID_PUBLISH - Cantidad de días previos a la modificación de su CI con el cual realizo la postulación
#=====================================================================================================
df_train['LOG_DAYS_ID_PUBLISH'] = np.log(df_train['DAYS_ID_PUBLISH']*-1 + 0.00001)
```

Gráfico de los atributos:

- `EXT_SOURCE_2` : Puntaje normalizado de fuente externa.
- `EXT_SOURCE_3` : Puntaje normalizado de fuente externa.
- `DAYS_LAST_PHONE_CHANGE` : Hace cuantos días antes de la postulación cambia número de teléfono.
- `FLAG_PHONE` : Da un teléfono contacto el cliente.

In [65]:
```
# Graficos boxplots de atributos
data_graf_num4 = df_train_num.loc[:, [ 'DAYS_LAST_PHONE_CHANGE','EXT_SOURCE_2', 'EXT_SOURCE_3', ]]
hlp.grafico_boxplot(data_graf_num4)
```

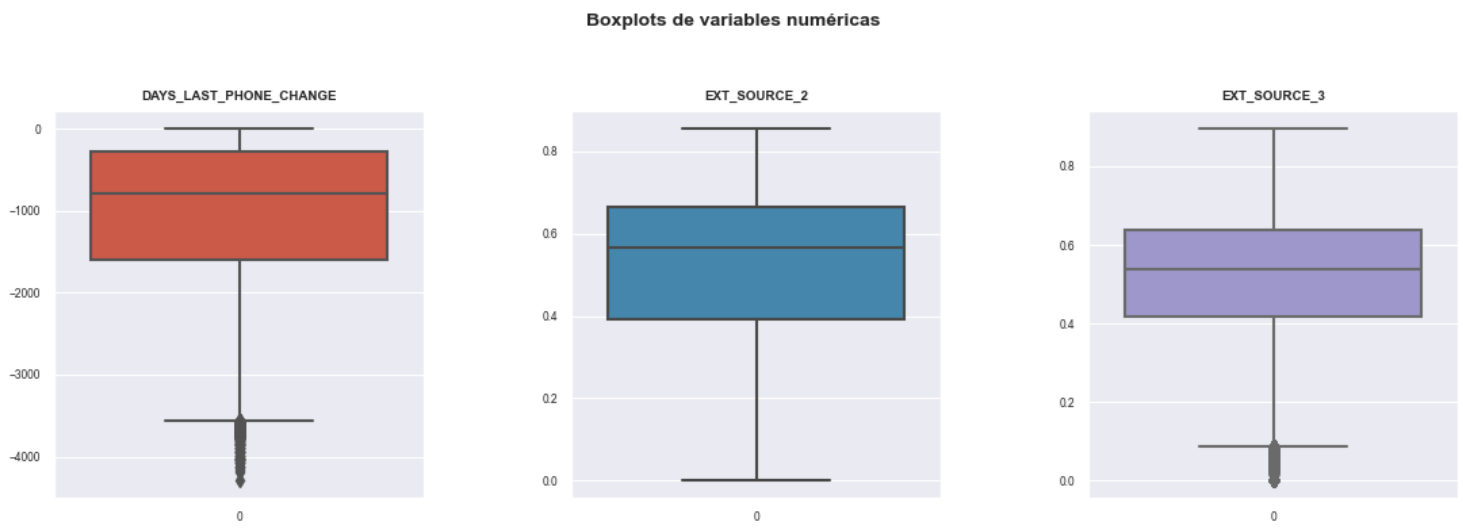

- La distribución de las observaciones para la variable `DAYS_LAST_PHONE_CHANGE` presenta valores negativos, por lo que será transformada a valores positivos, y reprocesada a logarítmica o se cambiara a tipo categórica según sea el caso analizado.
- Los atributos `EXT_SOURCE_2` , `EXT_SOURCE_2` , serán analizados y comparados con el vector objetivo.

In [66]:
```
# Estadistica DAYS_LAST_PHONE_CHANGE
df_train_num.loc[:, ['DAYS_LAST_PHONE_CHANGE']].describe()
```

Out[66]:

	DAYS_LAST_PHONE_CHANGE
count	278232.00000
mean	-979.43885
std	833.81689
min	-4292.00000
25%	-1592.00000
50%	-785.00000
75%	-279.00000
max	0.00000

In [67]:
```
# Analisis con histograma de variable DAYS_LAST_PHONE_CHANGE - Hace cuantos días antes de la postulación cambia número de teléfono #
hlp.histograma(df_train_num, 'DAYS_LAST_PHONE_CHANGE', 'Hace cuantos días antes de la postulación cambia número de teléfono')
```

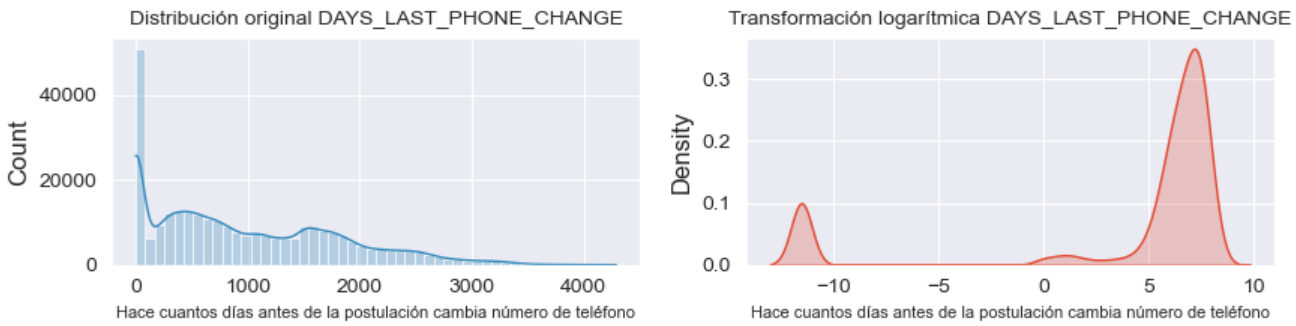

- En esta gráfica el atributo `DAYS_LAST_PHONE_CHANGE` , ciertos valores y la gran mayoría de las observaciones pertenecen a un solo valor, por lo que el atributo será condicionado a valores menores a 0 (toma el valor 1) en los casos en que el cliente cambia de teléfono y 0 en el caso que no cambia de teléfono.

In [68]:
```
# Transformar DAYS_LAST_PHONE_CHANGE - Hace cuantos días antes de la postulación cambia número de teléfono
#=============================================================================================================
df_train['PHONE_CHANGE'] = np.where(df_train['DAYS_LAST_PHONE_CHANGE'] < 0, 1, 0)

df_train['PHONE_CHANGE'] = df_train['PHONE_CHANGE'].astype('int')
```

In [69]:
```
# Analisis de variables  EXT_SOURCE_2 , EXT_SOURCE_3, FLAG_PHONE
# Puntaje normalizado de fuentes externas y cliente entrega telefono de contacto#
```

```
plt.figure(figsize=(15, 3));

plt.subplot(1,3,1)
sns.histplot(df_train['EXT_SOURCE_2'], kde=True, bins=50, line_kws={'linewidth':1}, alpha=0.3);
plt.title('Distribución original EXT_SOURCE_2',  fontsize=10);
plt.xlabel('Puntaje normalizado de fuente externa 2', fontsize = 8);

plt.subplot(1,3,2)
sns.histplot(df_train['EXT_SOURCE_3'], kde=True, bins=50, line_kws={'linewidth':1}, alpha=0.3);
plt.title('Distribución original EXT_SOURCE_3',  fontsize=10);
plt.xlabel('Puntaje normalizado de fuente externa 3', fontsize = 8);

# Conversion de tipo de dato para realizacion de grafico
df_train_num['FLAG_PHONE_'] = df_train['FLAG_PHONE'].astype('object')
tmp_flag_phone = df_train_num['FLAG_PHONE_']
df_train_num['FLAG_PHONE_'] = np.where(tmp_flag_phone == 1, 'YES', 'NO')

plt.subplot(1,3,3)
sns.countplot(df_train_num['FLAG_PHONE_']);
plt.title('Distribución cliente entrega teléfono de contacto',  fontsize=10);
plt.xlabel('');
```

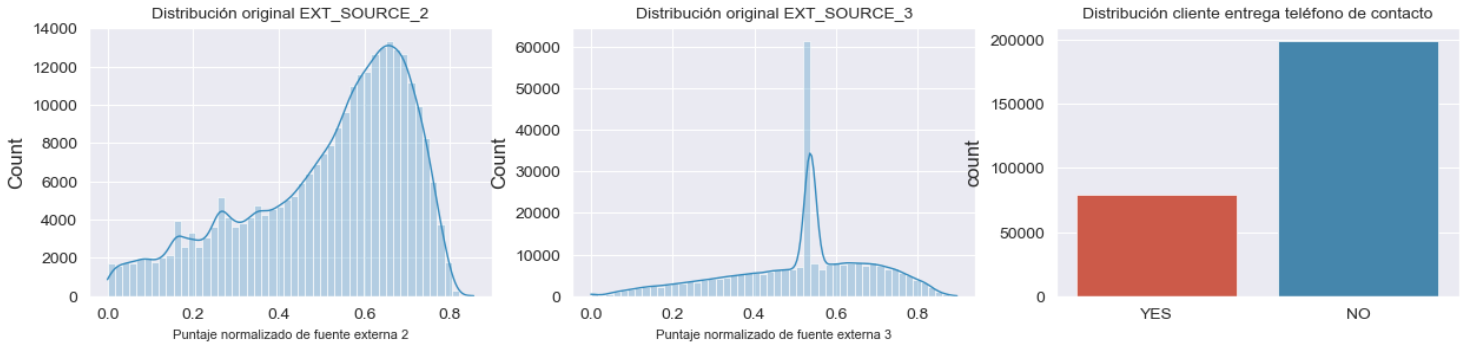

- La distribución de las observaciones para ambas fuentes externas se acercan más a una distribución normal.

Gráficos de los atributos :

- `FLAG_EMP_PHONE` : Da un teléfono de trabajo de contacto.
- `FLAG_WORK_PHONE` : Da un teléfono de hogar de contacto.
- `LIVE_CITY_NOT_WORK_CITY` : Identificador booleano si es que la dirección de contacto del cliente no concuerda con la dirección del trabajo.

In [70]:

```
# Graficos countplot de atributos
plt.figure(figsize=(15, 3));

# Conversion de tipo de dato para realizacion de grafico
df_train_num['FLAG_EMP_PHONE_'] = df_train['FLAG_EMP_PHONE'].astype('object')
tmp_flag_emp_phone = df_train_num['FLAG_EMP_PHONE_']

df_train_num['FLAG_WORK_PHONE_'] = df_train['FLAG_WORK_PHONE'].astype('object')
tmp_flag_work_phone = df_train_num['FLAG_WORK_PHONE_']

df_train_num['LIVE_CITY_NOT_WORK_CITY_'] = df_train['LIVE_CITY_NOT_WORK_CITY'].astype('object')
tmp_live_city_not_work_city = df_train_num['LIVE_CITY_NOT_WORK_CITY_']

plt.subplot(1,3,1)
df_train_num['FLAG_EMP_PHONE_'] = np.where(tmp_flag_emp_phone == 1, 'YES', 'NO')
hlp.countplot2(df_train_num, 'FLAG_EMP_PHONE_', etiqueta='Clientes que dan un teléfono de trabajo de contacto')
plt.xlabel('');

plt.subplot(1,3,2)
df_train_num['FLAG_WORK_PHONE_'] = np.where(tmp_flag_work_phone == 1, 'YES', 'NO')
hlp.countplot2(df_train_num, 'FLAG_WORK_PHONE_', etiqueta='Clientes que dan un teléfono de hogar de contacto')
plt.xlabel('');

plt.subplot(1,3,3)
df_train_num['LIVE_CITY_NOT_WORK_CITY_'] = np.where(tmp_live_city_not_work_city == 1, 'different', 'same, at city level')
hlp.countplot2(df_train_num, 'LIVE_CITY_NOT_WORK_CITY_', etiqueta='Dirección de contacto del cliente no concuerda con la dirección del t
plt.xlabel('');
```

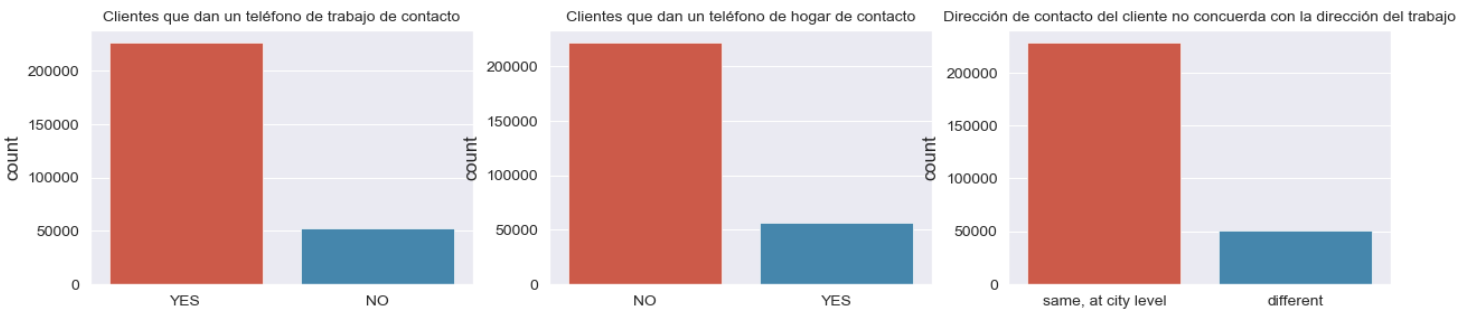

- La mayoría de los clientes dan un télefono de trabajo como contacto, pero no dan contacto de casa.
- La dirección de contacto del cliente en su mayoría concuerda con la dirección del trabajo y en un menor cantidad de casos es diferente.

Gráficos de los atributos :

- `REGION_RATING_CLIENT` : Evaluación interna (de Home Credit Group) sobre la región donde vive el cliente.
- `REG_CITY_NOT_LIVE_CITY` : Identificador booleano si es que la dirección permanente no concuerda con la dirección de contacto.
- `REG_CITY_NOT_WORK_CITY` : Identificador booleano si es que la dirección permanente no concuerda con la dirección del trabajo.

In [71]:

```
# Graficos countplot de atributos
plt.figure(figsize=(15, 3));

# Conversion de tipo de dato para realizacion de grafico
df_train_num['REGION_RATING_CLIENT_'] = df_train['REGION_RATING_CLIENT'].astype('object')
tmp_region_rating_client = df_train_num['REGION_RATING_CLIENT_']

df_train_num['REG_CITY_NOT_LIVE_CITY_'] = df_train['REG_CITY_NOT_LIVE_CITY'].astype('object')
tmp_reg_city_not_live_city = df_train_num['REG_CITY_NOT_LIVE_CITY_']

df_train_num['REG_CITY_NOT_WORK_CITY_'] = df_train['REG_CITY_NOT_WORK_CITY'].astype('object')
tmp_reg_city_not_work_city = df_train_num['REG_CITY_NOT_WORK_CITY_']

plt.subplot(1,3,1)
hlp.countplot2(df_train_num, 'REGION_RATING_CLIENT', etiqueta='Evaluación interna sobre la ciudad donde vive el cliente')
plt.xlabel('');

plt.subplot(1,3,2)
df_train_num['REG_CITY_NOT_LIVE_CITY_'] = np.where(tmp_reg_city_not_live_city == 1,'different', 'same, at city level')
hlp.countplot2(df_train_num, 'REG_CITY_NOT_LIVE_CITY_', etiqueta='Dirección permanente no concuerda con la dirección de contacto')
plt.xlabel('');

plt.subplot(1,3,3)
df_train_num['REG_CITY_NOT_WORK_CITY_'] = np.where(tmp_reg_city_not_work_city == 1, 'different', 'same, at city level')
hlp.countplot2(df_train_num, 'REG_CITY_NOT_WORK_CITY_', etiqueta='Dirección permanente no concuerda con la dirección del trabajo')
plt.xlabel('');
```

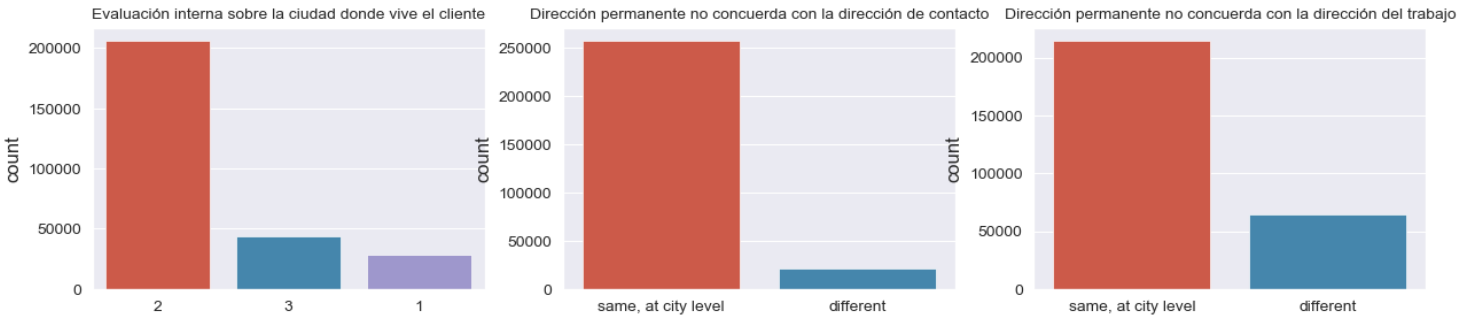

- Los clientes indican que la dirección permanente es la misma que la dirección de contacto y la misma para dirección de trabajo.
- Se entrega un puntaje 2 a la mayoría de los clientes, lo que podría indicar que la mayoría radica en esa ciudad.

Gráficos de los atributos :

- `OBS_30_CNT_SOCIAL_CIRCLE` : Cuántas veces ha registrado mora más de 30 días su entorno.
- `DEF_30_CNT_SOCIAL_CIRCLE` : Cuántas veces ha registrado mora más de 30 días su entorno.
- `OBS_60_CNT_SOCIAL_CIRCLE` : Cuántas veces ha registrado mora más de 60 días su entorno.

In [72]:

```
# Grafico de los atributos
plt.figure(figsize=(20, 5));
plt.subplot(1,3,1)
hlp.countplot(df_train_num, 'OBS_30_CNT_SOCIAL_CIRCLE' )
```

```
plt.subplot(1,3,2)
hlp.countplot(df_train_num, 'DEF_30_CNT_SOCIAL_CIRCLE' )

plt.subplot(1,3,3)
hlp.countplot(df_train_num, 'OBS_60_CNT_SOCIAL_CIRCLE' )
```

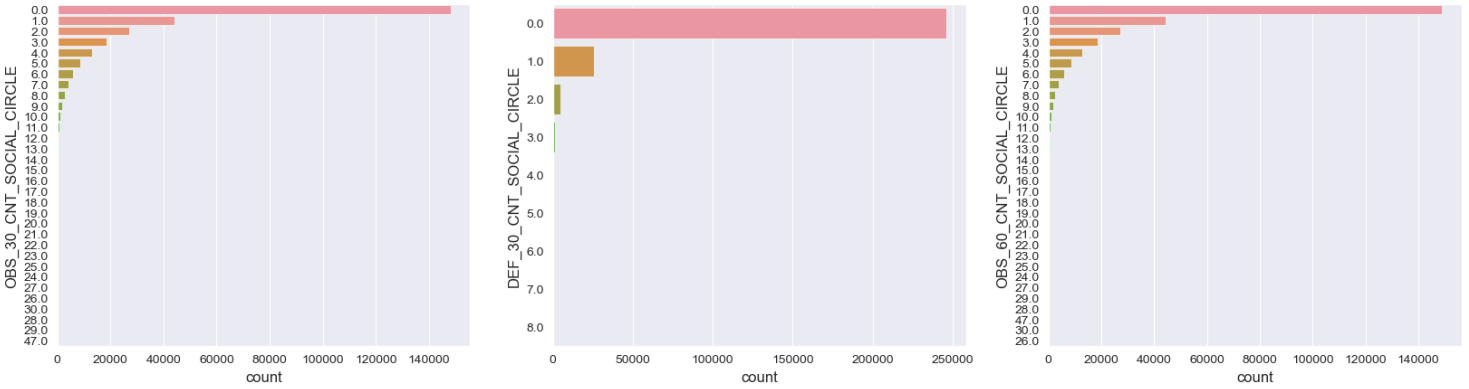

- Se eliminarán las variables `OBS_30_CNT_SOCIAL_CIRCLE` y `OBS_60_CNT_SOCIAL_CIRCLE`, por ser variables que describen lo mismo que las variables `DEF_30_CNT_SOCIAL_CIRCLE` y `DEF_60_CNT_SOCIAL_CIRCLE` respecto de cuantas veces ha registrado mora su entorno.

- `DEF_30_CNT_SOCIAL_CIRCLE` será analizada y comparada con el vector objetivo.

Gráficos de los atributos :

- `DEF_60_CNT_SOCIAL_CIRCLE` : Cuántas veces ha registrado mora más de 60 días su entorno.
- `AMT_REQ_CREDIT_BUREAU_HOUR` :Cantidad de consultas sobre el cliente al buró de crédito. Una hora antes de la postulación.
- `AMT_REQ_CREDIT_BUREAU_DAY` : Cantidad de consultas sobre el cliente al buró de crédito. Un día antes de la postulación.

In [73]:
```
# Grafico de los atributos
plt.figure(figsize=(20, 4));
plt.subplot(1,3,1)
hlp.countplot(df_train_num, 'DEF_60_CNT_SOCIAL_CIRCLE' )

plt.subplot(1,3,2)
hlp.countplot(df_train_num, 'AMT_REQ_CREDIT_BUREAU_HOUR' )

plt.subplot(1,3,3)
hlp.countplot(df_train_num, 'AMT_REQ_CREDIT_BUREAU_DAY' )
```

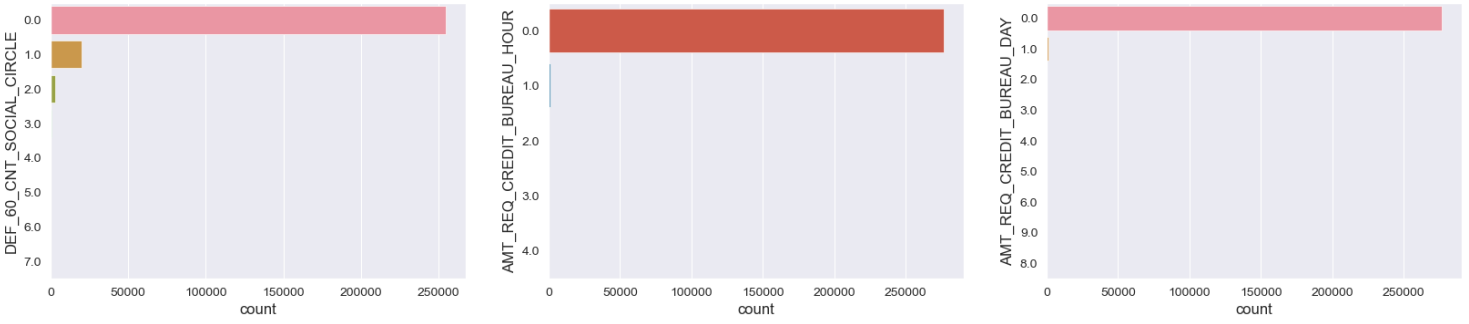

- `AMT_REQ_CREDIT_BUREAU_HOUR` y `AMT_REQ_CREDIT_BUREAU_DAY`, estas variables serán eliminadas ya que la mayoria de las observaciones estan sesgadas a un solo valor que indica cero consultas sobre el cliente al buró de crédito una hora o un día antes de la postulación.

- `DEF_60_CNT_SOCIAL_CIRCLE`, será analizada y comparada con el vector objetivo.

Gráficos de los atributos :

- `AMT_REQ_CREDIT_BUREAU_WEEK` : Cantidad de consultas sobre el cliente al buró de crédito. Una semana antes de la postulación.
- `AMT_REQ_CREDIT_BUREAU_MON` : Cantidad de consultas sobre el cliente al buró de crédito. Un mes antes de la postulación.
- `AMT_REQ_CREDIT_BUREAU_QRT` : Cantidad de consultas sobre el cliente al buró de crédito. Tres meses antes de la postulación.

In [74]:
```
# Grafico de los atributos
plt.figure(figsize=(20, 5));
plt.subplot(1,3,1)
```

```
hlp.countplot(df_train_num, 'AMT_REQ_CREDIT_BUREAU_WEEK')

plt.subplot(1,3,2)
hlp.countplot(df_train_num, 'AMT_REQ_CREDIT_BUREAU_MON' )

plt.subplot(1,3,3)
hlp.countplot(df_train_num, 'AMT_REQ_CREDIT_BUREAU_QRT' )
```

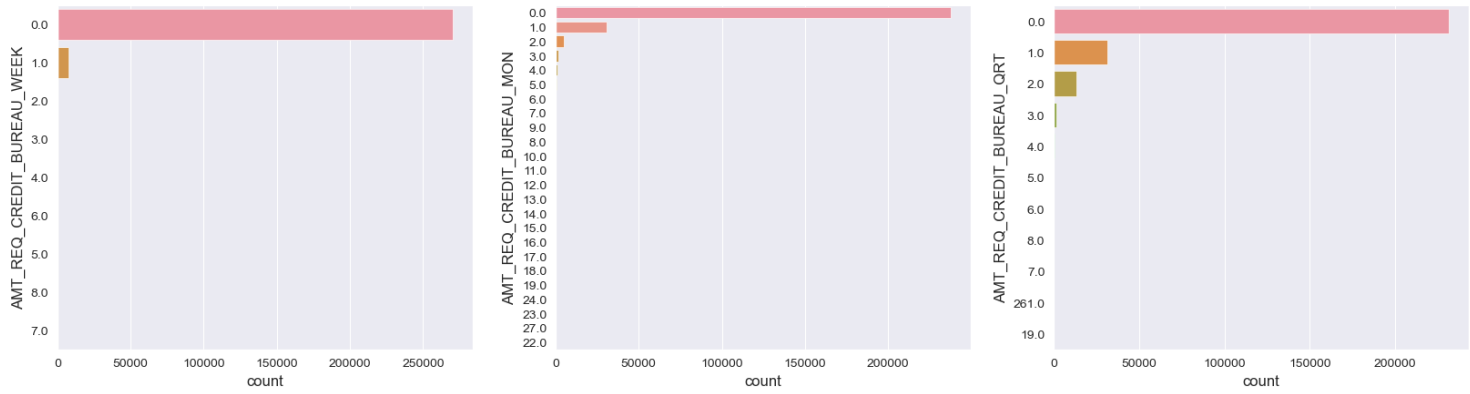

- `AMT_REQ_CREDIT_BUREAU_WEEK` y `AMT_REQ_CREDIT_BUREAU_QRT`, estas variables serán eliminadas ya que la mayoría de las observaciones estan sesgadas a un solo valor que indica cero consultas sobre el cliente al buró de crédito una semana o tres meses antes de la postulación.
- `AMT_REQ_CREDIT_BUREAU_MON`, será analizada y comparada con el vector objetivo.

Gráficos de los atributos :

- `AMT_REQ_CREDIT_BUREAU_YEAR` : Cantidad de consultas sobre el cliente al buró de crédito. Un año antes de la postulación.
- `CNT_CHILDREN` : Cantidad de hijos por parte del cliente.
- `CNT_FAM_MEMBERS` : Cuántos miembros familiares tiene el cliente.

In [75]:

```
# Grafico de los atributos
plt.figure(figsize=(20, 5));
plt.subplot(1,3,1)
hlp.countplot(df_train_num, 'AMT_REQ_CREDIT_BUREAU_YEAR')

plt.subplot(1,3,2)
hlp.countplot(df_train_num, 'CNT_CHILDREN')

plt.subplot(1,3,3)
hlp.countplot(df_train_num, 'CNT_FAM_MEMBERS' )
```

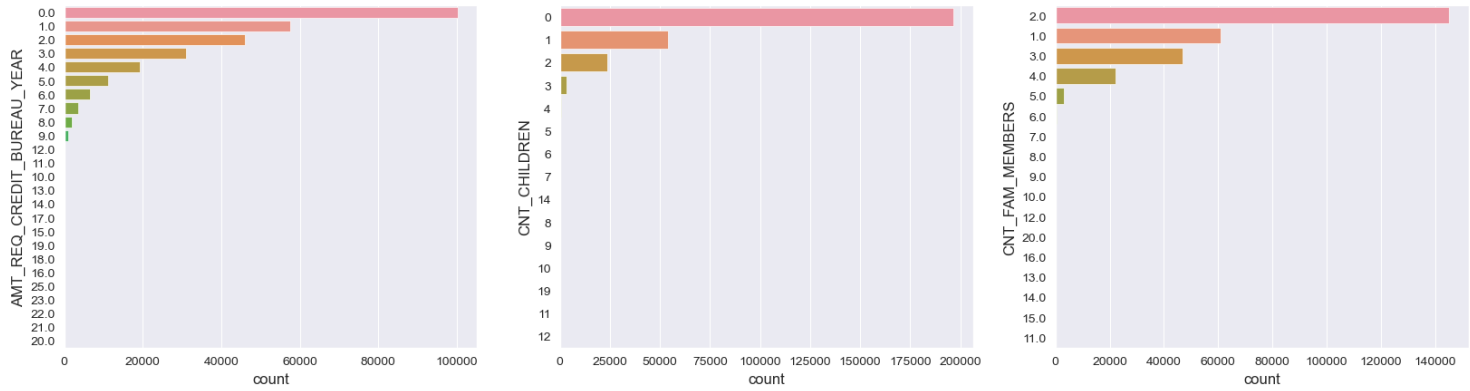

- La mayoría de los clientes que solicitan el préstamo no tienen hijos y su grupo familiar lo componen una o dos personas en su mayoría.
- `AMT_REQ_CREDIT_BUREAU_YEAR`, `CNT_CHILDREN`, `CNT_FAM_MEMBERS`, estos atributos serán analizados y comparados con el vector objetivo.

Resumen atributos continuos:

- Los atributos `AMT_INCOME_TOTAL`, `AMT_CREDIT`, `AMT_ANNUITY`, `AMT_GOODS_PRICE`, `DAYS_REGISTRATION`, `DAYS_ID_PUBLISH` fueron reprocesadas ya que al ser procesadas como logaritmo presentan una distribución mas cercana a la distribución normal. Se elimina la variable original.

- Los atributos `DAYS_EMPLOYED` y `DAYS_LAST_PHONE_CHANGE`, fueron transformadas a categóricas. Se elimina la variable original.

- Los atributos generados de las transformaciones: `RATIO_CREDIT_INCOME`, `FLAG_EMP_PHONE`, `LOG_AMT_INCOME_TOTAL`, `LOG_AMT_CREDIT`, `LOG_AMT_GOODS_PRICE`, `LOG_AMT_ANNUATY`, `REGION_POPULATION_RELATIVE`, `LOG_DAYS_REGISTRATION`, `LOG_DAYS_ID_PUBLISH`, `AGE`,

`EXT_SOURCE_2` , `EXT_SOURCE_2` , `FLAG_EMP_PHONE` , `FLAG_WORK_PHONE` , `LIVE_CITY_NOT_WORK_CITY` , `REGION_RATING_CLIENT` , `REG_CITY_NOT_LIVE_CITY` , `REG_CITY_NOT_WORK_CITY` , `DEF_30_CNT_SOCIAL_CIRCLE` , `DEF_60_CNT_SOCIAL_CIRCLE` , `AMT_REQ_CREDIT_BUREAU_MON` , `AMT_REQ_CREDIT_BUREAU_YEAR` , `CNT_CHILDREN` , `CNT_FAM_MEMBERS` , serán analizadas con el vector objetivo o eliminadas si presentan colinealidad.

- Los atributos `OBS_30_CNT_SOCIAL_CIRCLE` , `OBS_60_CNT_SOCIAL_CIRCLE` , `AMT_REQ_CREDIT_BUREAU_HOUR` , `AMT_REQ_CREDIT_BUREAU_DAY` , `AMT_REQ_CREDIT_BUREAU_WEEK` , `AMT_REQ_CREDIT_BUREAU_QRT` serán eliminados ya que estan muy sesgados a una solo valor.

- Los atributos originales: `DAYS_BIRTH` , `AMT_INCOME_TOTAL` , `AMT_CREDIT` , `AMT_ANNUITY` , `AMT_GOODS_PRICE` , `DAYS_EMPLOYED` , `DAYS_REGISTRATION` , `DAYS_ID_PUBLISH` , `DAYS_LAST_PHONE_CHANGE` , serán eliminadas por transformación de su atributo original.

In [76]:
```
# Seleccion de columnas continuas a Eliminar
#=============================================================================================
columns_num_drop = ['SK_ID_CURR', 'DAYS_BIRTH', 'AMT_INCOME_TOTAL',
                    'AMT_CREDIT', 'AMT_ANNUITY', 'AMT_GOODS_PRICE',
                    'DAYS_EMPLOYED', 'DAYS_REGISTRATION',
                    'DAYS_ID_PUBLISH', 'DAYS_LAST_PHONE_CHANGE',
                    'OBS_30_CNT_SOCIAL_CIRCLE', 'OBS_60_CNT_SOCIAL_CIRCLE',
                    'AMT_REQ_CREDIT_BUREAU_HOUR', 'AMT_REQ_CREDIT_BUREAU_DAY',
                    'AMT_REQ_CREDIT_BUREAU_WEEK', 'AMT_REQ_CREDIT_BUREAU_QRT' ]
```

2.11.4 Eliminación de atributos continuos de análisis univariado

In [77]:
```
# Eliminacion de Atributos Transformados:
#=============================================================================================
df_train = df_train.drop(columns = columns_num_drop)
```

In [78]:
```
# Dimensión de la data posterior a la eliminación de atributos continuos
df_train.shape
```

Out[78]:
```
(278232, 66)
```

In [79]:
```
print(f'Lista de {len(columns_num_drop)} atributos que fueron eliminados: \n\n{columns_num_drop}')
```

```
Lista de 16 atributos que fueron eliminados:

['SK_ID_CURR', 'DAYS_BIRTH', 'AMT_INCOME_TOTAL', 'AMT_CREDIT', 'AMT_ANNUITY', 'AMT_GOODS_PRICE', 'DAYS_EMPLOYED', 'DAYS_REGISTRATION',
'DAYS_ID_PUBLISH', 'DAYS_LAST_PHONE_CHANGE', 'OBS_30_CNT_SOCIAL_CIRCLE', 'OBS_60_CNT_SOCIAL_CIRCLE', 'AMT_REQ_CREDIT_BUREAU_HOUR', 'AMT_
REQ_CREDIT_BUREAU_DAY', 'AMT_REQ_CREDIT_BUREAU_WEEK', 'AMT_REQ_CREDIT_BUREAU_QRT']
```

2.11.5 Correlación entre variables numéricas

In [80]:
```
correlacion = df_train.corr().mask(abs(df_train.corr()) <.6, df_train) #.drop('TARGET',axis=1)
mask = np.zeros_like(correlacion, dtype=np.bool)
mask[np.triu_indices_from(mask)] = True
plt.figure(figsize=(15, 8))
plt.title('Correlación de variables numéricas', fontsize=13)
sns.heatmap(correlacion, mask=mask, annot=True, cmap='RdYlGn', linewidths=0.2, annot_kws={'size':10})
plt.show()
```

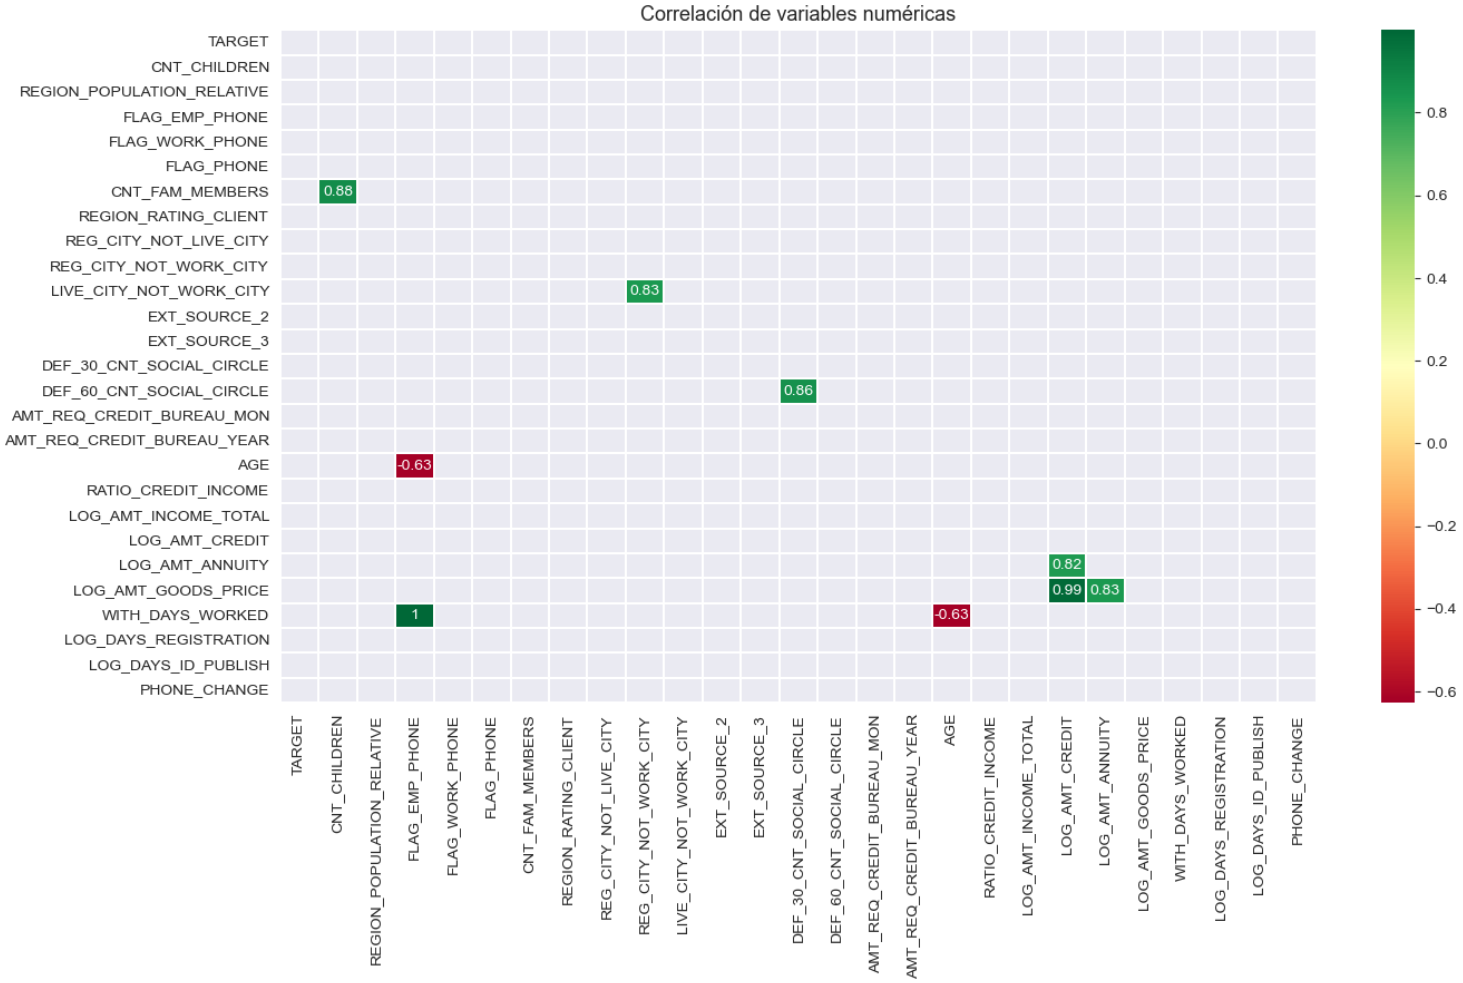

Del análisis de la correlación de las variables continuas se puede observar que:

- `LOG_AMT_ANNUITY` y `LOG_AMT_CREDIT`, estan muy correlacionadas, por lo que se mantendrá sólo una de las dos.
- `WITH_DAYS_WORKED` y `FLAG_EMP_PHONE`, estan muy correlacionadas, por lo que se mantendrá sólo una de las dos.
- `LOG_AMT_GOODS_PRICE` y `LOG_AMT_CREDIT`, otro caso de multicolinealidad.
- `LOG_AMT_GOODS_PRICE` y `LOG_AMT_ANNUITY`, otro caso de multicolinealidad.

2.11.6 Correlación entre variables numéricas y Variable Objetivo `TARGET`

In [81]:
```
# Seleccion de columnas continuas
df_train_num = df_train.select_dtypes(include=['float64', 'int']).drop('TARGET', axis=1)
columns_numeric = list(df_train_num)
```

In [82]:
```
# Separacion de clases
target = df_train['TARGET']
df_clase_1 = df_train_num[target == 1]
df_clase_0 = df_train_num[target == 0]
```

In [83]:
```
# Correlacion de Cohen
d_de_Cohen = []
for col in columns_numeric:
    a = df_clase_1[col].mean()
    b = df_clase_0[col].mean()
    std = df_train_num[col].std()
    d = round((b - a)/std, 3)
    d_de_Cohen.append((col, d))
d_de_Cohen
```

Out[83]:
```
[('CNT_CHILDREN', -0.077),
 ('REGION_POPULATION_RELATIVE', 0.128),
 ('FLAG_EMP_PHONE', -0.18),
 ('FLAG_WORK_PHONE', -0.096),
 ('FLAG_PHONE', 0.095),
 ('CNT_FAM_MEMBERS', -0.039),
 ('REGION_RATING_CLIENT', -0.214),
 ('REG_CITY_NOT_LIVE_CITY', -0.165),
```

```
('REG_CITY_NOT_WORK_CITY', -0.19),
('LIVE_CITY_NOT_WORK_CITY', -0.121),
('EXT_SOURCE_2', 0.584),
('EXT_SOURCE_3', 0.573),
('DEF_30_CNT_SOCIAL_CIRCLE', -0.114),
('DEF_60_CNT_SOCIAL_CIRCLE', -0.111),
('AMT_REQ_CREDIT_BUREAU_MON', 0.055),
('AMT_REQ_CREDIT_BUREAU_YEAR', -0.015),
('AGE', 0.298),
('RATIO_CREDIT_INCOME', -0.006),
('LOG_AMT_INCOME_TOTAL', 0.057),
('LOG_AMT_CREDIT', 0.061),
('LOG_AMT_ANNUITY', nan),
('LOG_AMT_GOODS_PRICE', 0.094),
('WITH_DAYS_WORKED', -0.18),
('LOG_DAYS_REGISTRATION', 0.129),
('LOG_DAYS_ID_PUBLISH', 0.152),
('PHONE_CHANGE', 0.072)]
```

- Del análisis de la correlación de la d de Cohen las variables `LOG_AMT_ANNUITY`, `LOG_AMT_GOODS_PRICE`, `RATIO_CREDIT_INCOME`, `REGION_POPULATION_RELATIVE` y `FLAG_EMP_PHONE`, serán eliminadas dado que la correlación es muy baja respecto del target.

2.11.7 Eliminación de atributos correlacionados

In [84]:
```
# Eliminacion de Atributos correlacionados:
# REGION_POPULATION_RELATIVE, RATIO_CREDIT_INCOME, LOG_AMT_ANNUITY, LOG_AMT_GOODS_PRICE, FLAG_EMP_PHONE
#=============================================================================================
columns_num_drop_corr = ['REGION_POPULATION_RELATIVE', 'RATIO_CREDIT_INCOME',
                         'LOG_AMT_ANNUITY', 'LOG_AMT_GOODS_PRICE', 'FLAG_EMP_PHONE']

df_train = df_train.drop(columns = columns_num_drop_corr)
```

In [85]:
```
# Dimensión de la data posterior a la eliminación de atributos continuos correlacionados
df_train.shape
```

Out[85]: (278232, 61)

2.11.8 Descripción de datos categóricos

Atributos :

- `CODE_GENDER` : Sexo del cliente
- `FLAG_OWN_CAR` : Indicador binario sobre la tenencia de automóvil por parte del cliente.
- `FLAG_OWN_REALTY` : Indicador binario sobre la propiedad de una casa o departamento por parte del cliente.
- `NAME_TYPE_SUITE` : Quien acompaña al cliente cuando fue a solicitar el préstamo.
- `NAME_INCOME_TYPE` : Tipo de ingreso por parte del cliente.
- `NAME_EDUCATION_TYPE` : Máximo nivel educacional por parte del cliente.
- `NAME_FAMILY_STATUS` : Situación familiar del cliente.
- `NAME_HOUSING_TYPE` : Cuál es la situación habitacional del cliente.
- `FLAG_MOBIL` : Da un teléfono celular de contacto
- `FLAG_CONT_MOBILE` : Se pudo contactar al cliente mediante el celular.
- `FLAG_EMAIL` : Da un email de contacto el cliente.
- `OCCUPATION_TYPE` : Cuál es la profesión del cliente.
- `REGION_RATING_CLIENT_W_CITY` : Evaluación interna (de Home Crédito Group) sobre la región donde vive el cliente considerando ciudad.
- `WEEKDAY_APPR_PROCESS_START` : Día hábil en el cual el cliente pide el préstamo.
- `HOUR_APPR_PROCESS_START` : Hora aproximada de la solicitud de préstamo por parte del cliente.
- `REG_REGION_NOT_LIVE_REGION` : Identificador booleano si es que la dirección permanente del cliente no concuerda con la dirección de contacto.
- `REG_REGION_NOT_WORK_REGION` : Identificador booleano si es que la dirección permanente del cliente no concuerda con la dirección de trabajo.
- `LIVE_REGION_NOT_WORK_REGION` : Identificador booleano si es que la dirección de contacto del cliente no concuerda con la dirección del trabajo
- `ORGANIZATION_TYPE` : Tipo de organización donde trabaja el cliente.
- `FLAG_DOCUMENT_2`, `FLAG_DOCUMENT_3`, `FLAG_DOCUMENT_4`, `FLAG_DOCUMENT_5`, `FLAG_DOCUMENT_6`, `FLAG_DOCUMENT_7`, `FLAG_DOCUMENT_8`, `FLAG_DOCUMENT_9`, `FLAG_DOCUMENT_10`, `FLAG_DOCUMENT_11`, `FLAG_DOCUMENT_12`, `FLAG_DOCUMENT_13`, `FLAG_DOCUMENT_14`, `FLAG_DOCUMENT_15`, `FLAG_DOCUMENT_16`, `FLAG_DOCUMENT_17`, `FLAG_DOCUMENT_18`, `FLAG_DOCUMENT_19`, `FLAG_DOCUMENT_20` y `FLAG_DOCUMENT_21` : Indicador documento del 2 al 21.

In [86]:
```
# Conversion de tipo de dato del vector objetivo para realizacion de graficos
df_train['TARGET_'] = df_train['TARGET'].astype('object')
target_tmp = df_train['TARGET']
df_train['TARGET_'] = np.where(target_tmp == 1, 'Mal pagador', 'Buen pagador')
```

In [87]:

```
# Descripcion estadistica de datos categoricos
pd.options.display.max_columns = None
df_train_obj = df_train.select_dtypes(include=['object']).describe()
df_train_obj
```

Out[87]:

	CODE_GENDER	FLAG_OWN_CAR	FLAG_OWN_REALTY	NAME_TYPE_SUITE	NAME_INCOME_TYPE	NAME_EDUCATION_TYPE	NAME_FAMILY_STATUS	NAME_H
count	278232	278232	278232	278232	278232	278232	278232	
unique	2	2	2	8	7	5	5	
top	F	N	Y	Unaccompanied	Working	Secondary / secondary special	Married	Ho
freq	182800	183775	190207	224541	142719	200125	178711	

- Existe una gran variedad de flag que indican si dicho documento se entrego o no, pero no se tiene claridad de que documentos fueron solictados.

In [88]:
```
# Cantidad de atributos categoricos
df_train_object = df_train.select_dtypes(include=['object'])
len(df_train_object.columns)
```

Out[88]:
```
40
```

In [89]:
```
df_train_object.columns
```

Out[89]:
```
Index(['CODE_GENDER', 'FLAG_OWN_CAR', 'FLAG_OWN_REALTY', 'NAME_TYPE_SUITE',
       'NAME_INCOME_TYPE', 'NAME_EDUCATION_TYPE', 'NAME_FAMILY_STATUS',
       'NAME_HOUSING_TYPE', 'FLAG_MOBIL', 'FLAG_CONT_MOBILE', 'FLAG_EMAIL',
       'OCCUPATION_TYPE', 'REGION_RATING_CLIENT_W_CITY',
       'WEEKDAY_APPR_PROCESS_START', 'HOUR_APPR_PROCESS_START',
       'REG_REGION_NOT_LIVE_REGION', 'REG_REGION_NOT_WORK_REGION',
       'LIVE_REGION_NOT_WORK_REGION', 'ORGANIZATION_TYPE', 'FLAG_DOCUMENT_2',
       'FLAG_DOCUMENT_3', 'FLAG_DOCUMENT_4', 'FLAG_DOCUMENT_5',
       'FLAG_DOCUMENT_6', 'FLAG_DOCUMENT_7', 'FLAG_DOCUMENT_8',
       'FLAG_DOCUMENT_9', 'FLAG_DOCUMENT_10', 'FLAG_DOCUMENT_11',
       'FLAG_DOCUMENT_12', 'FLAG_DOCUMENT_13', 'FLAG_DOCUMENT_14',
       'FLAG_DOCUMENT_15', 'FLAG_DOCUMENT_16', 'FLAG_DOCUMENT_17',
       'FLAG_DOCUMENT_18', 'FLAG_DOCUMENT_19', 'FLAG_DOCUMENT_20',
       'FLAG_DOCUMENT_21', 'TARGET_'],
      dtype='object')
```

Estas número de variables categóricas serán analizadas en este apartado, para ser eliminadas, reprocesadas o pasarán a formar parte de una categoria.

2.11.9 Gráficos atributos categóricos

Gráficos de atributos :

- `CODE_GENDER` : Sexo del cliente
- `FLAG_OWN_CAR` : Indicador binario sobre la tenencia de automóvil por parte del cliente.
- `FLAG_OWN_REALTY` : Indicador binario sobre la propiedad de una casa o departamento por parte del cliente.
- `FLAG_MOBIL` : Da un teléfono celular de contacto
- `FLAG_CONT_MOBILE` : Se pudo contactar al cliente mediante el celular.
- `FLAG_EMAIL` : Da un email de contacto el cliente.

In [90]:
```
# Columnas agrupadas para graficar
data_graf_obj1 = df_train_object.loc[:, [ 'CODE_GENDER', 'FLAG_OWN_CAR', 'FLAG_OWN_REALTY',
                                          'FLAG_MOBIL', 'FLAG_CONT_MOBILE',  'FLAG_EMAIL']]
hlp.graficos_barra(data_graf_obj1)
```

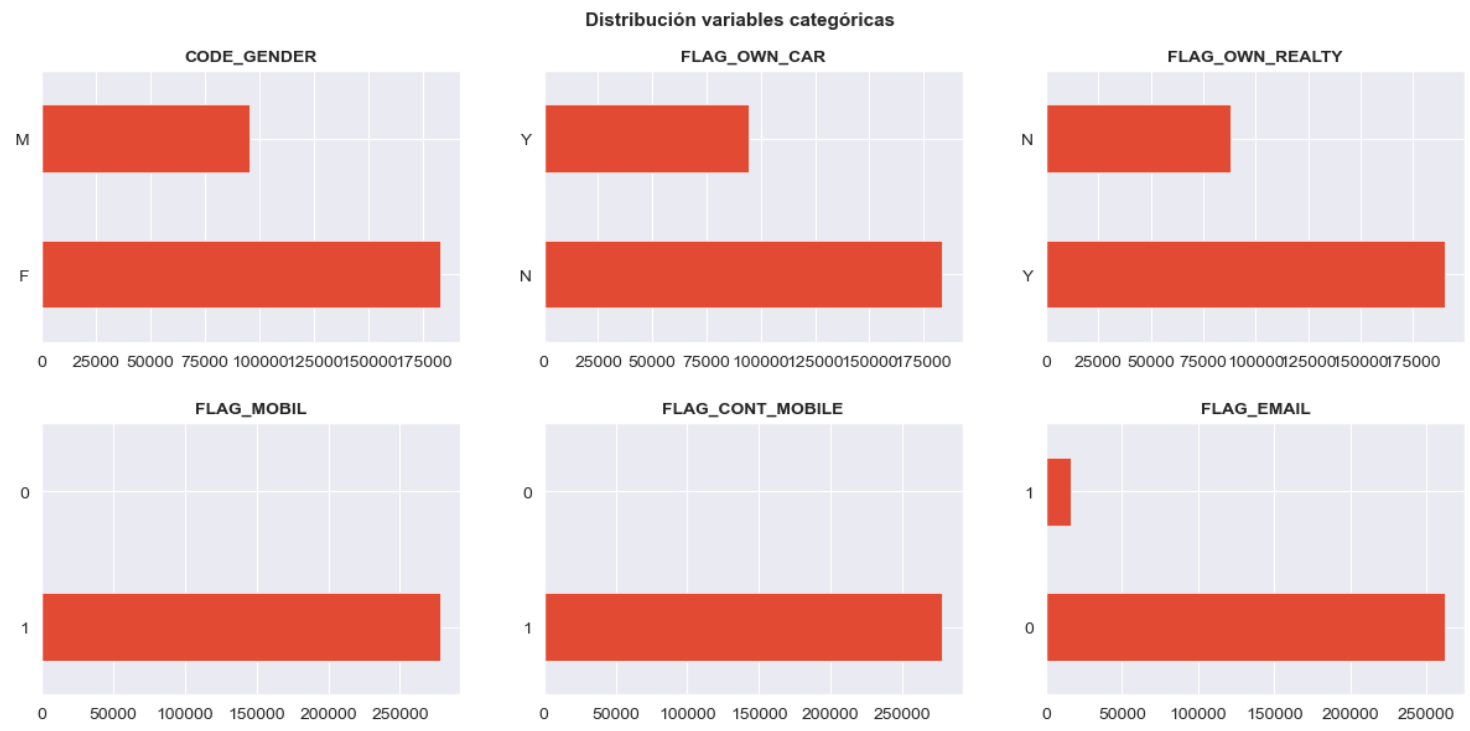

In [91]:
```
plt.figure(figsize=(5, 3));
sns.countplot(x='CODE_GENDER', data=df_train_object);
```

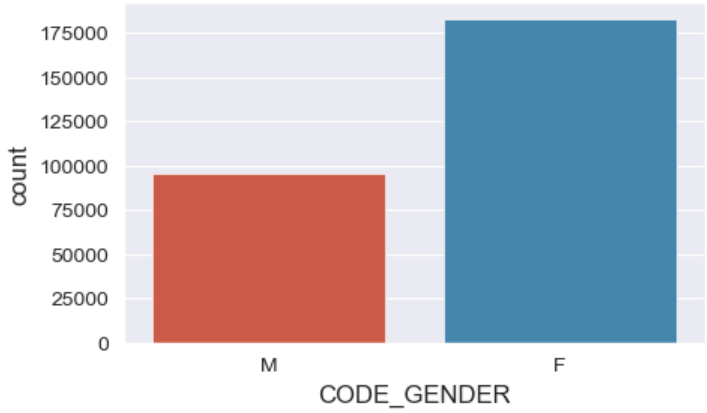

- Los atributos `FlAG_MOBIL` , `FLAG_CONT_MOBILE` , `FLAG_EMAIL` serán eliminados ya que estos atributos están muy sesgadas a una sola categoría. La mayoría de los clientes entregan un número de celular de contacto y se les pudo contactar por dicho medio.

- Se observa que en su mayoría los clientes que solicitaron el préstamo son mujeres, muchos de los clientes no tienen auto y también otros son propietarios de una casa o departamento.

- Estos atributos `CODE_GENDER` , `FLAG_OWN_CAR` , `FLAG_OWN_REALTY` , serán analizados y comparados con el vector objetivo.

Gráfico de atributos :

- `WEEKDAY_APPR_PROCESS_START` : Día hábil en el cual el cliente pide el préstamo.
- `HOUR_APPR_PROCESS_START` : Hora aproximada de la solicitud de préstamo por parte del cliente.
- `REGION_RATING_CLIENT_W_CITY` : Evaluación interna (de Home Crédito Group) sobre la región donde vive el cliente considerando ciudad.
- `REG_REGION_NOT_LIVE_REGION` : Identificador booleano si es que la dirección permanente del cliente no concuerda con la dirección de contacto
- `REG_REGION_NOT_WORK_REGION` : Identificador booleano si es que la dirección permanente del cliente no concuerda con la dirección de trabajo
- `LIVE_REGION_NOT_WORK_REGION` : Identificador booleano si es que la dirección de contacto del cliente no concuerda con la dirección del trabajo.

In [92]:
```
# Columnas a graficar
data_graf_obj2 = df_train_object.loc[:, [ 'WEEKDAY_APPR_PROCESS_START', 'HOUR_APPR_PROCESS_START',
                                          'REGION_RATING_CLIENT_W_CITY', 'REG_REGION_NOT_LIVE_REGION',
                                          'REG_REGION_NOT_WORK_REGION',  'LIVE_REGION_NOT_WORK_REGION' ]]

hlp.graficos_barra(data_graf_obj2)
```

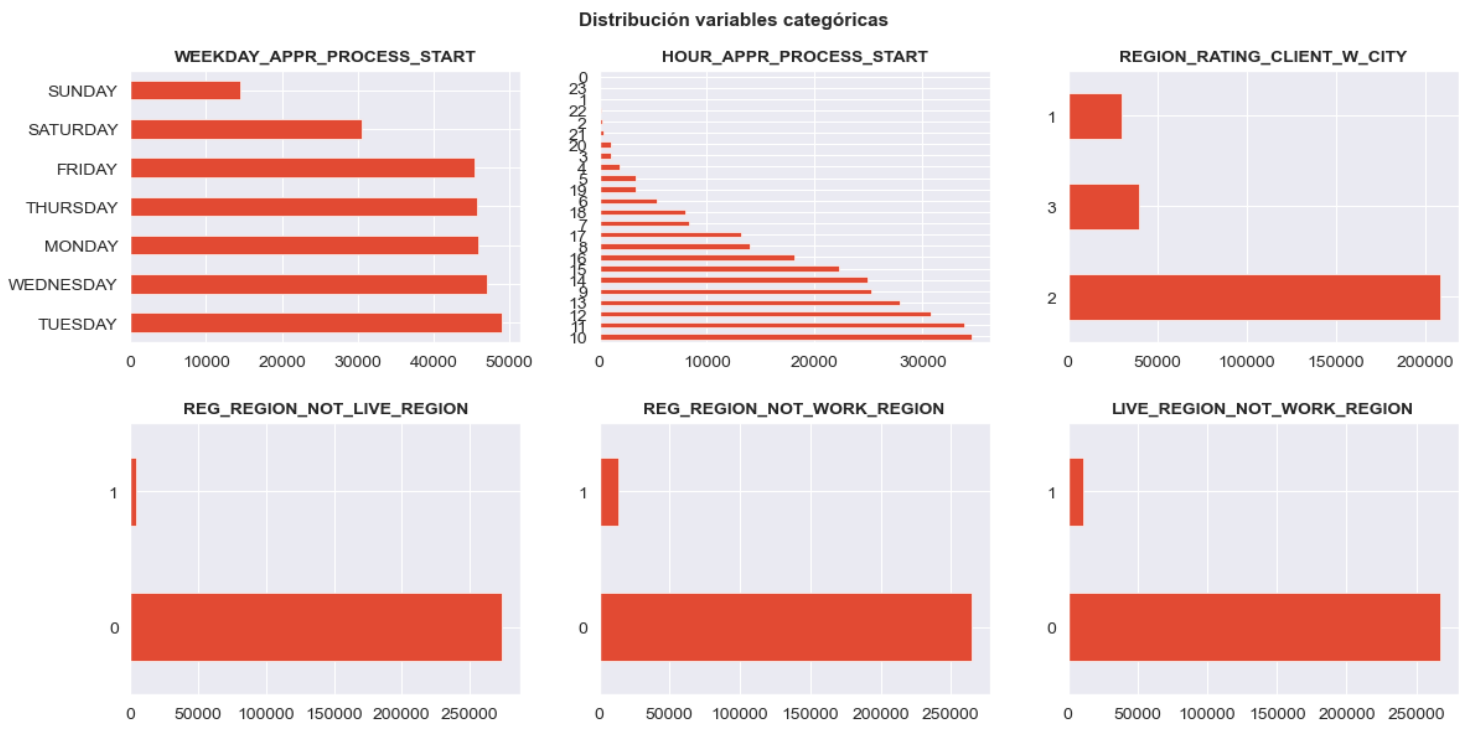

- Los atributos `REG_REGION_NOT_LIVE_REGION` , `REG_REGION_NOT_WORK_REGION` , `LIVE_REGION_NOT_WORK_REGION` , serán eliminados ya que estos atributos están muy sesgadas a una sola categoría, o no parecen ser útiles para el análisis.
- `WEEKDAY_APPR_PROCESS_START` y `HOUR_APPR_PROCESS_START` , estos atributos se eliminarán, dado que no aportan para el análisis o no afectan en que un cliente sea buen o mal pagador.
- El atributo `REGION_RATING_CLIENT_W_CITY` , será analizado y comparado con el vector objetivo.

Gráficos de Atributos :

- `NAME_TYPE_SUITE` : Quien acompaña al cliente cuando fue a solicitar el préstamo.
- `NAME_INCOME_TYPE` : Tipo de ingreso por parte del cliente.

In [93]:
```
# Analisis con grafico de barras #
plt.figure(figsize=( 20, 4 ))
# Atributo NAME_TYPE_SUITE - Quien acompaña al cliente cuando fue a solicitar el préstamo #
plt.subplot(1,2,1)
hlp.countplot(df_train_object, 'NAME_TYPE_SUITE', 'Distribución de quien acompaña al cliente al solicitar el préstamo')

# Atributo NAME_INCOME_TYPE - Tipo de ingreso por parte del cliente #
plt.subplot(1,2,2)
hlp.countplot(df_train_object, 'NAME_INCOME_TYPE', 'Distribución del tipo de ingreso por parte del cliente')
```

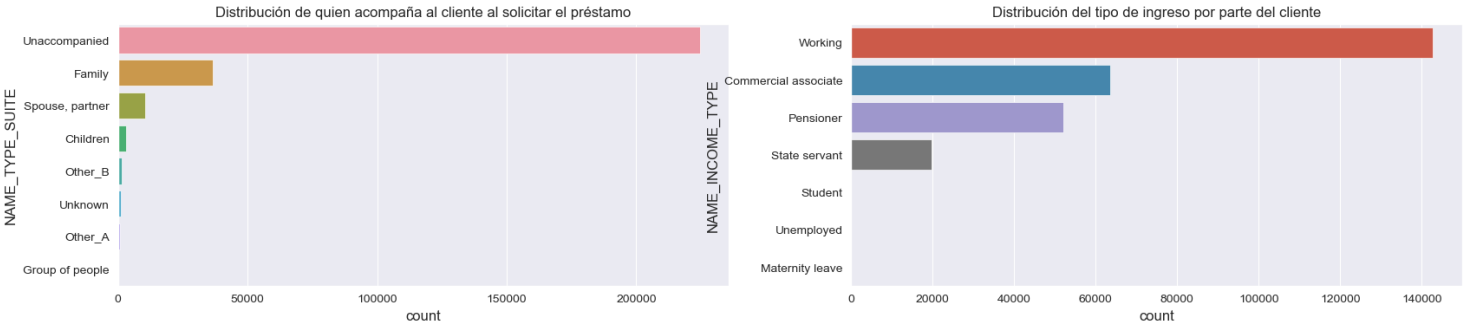

- El atributo `NAME_TYPE_SUITE` , no parece ser un atributo útil para el análisis, al parecer el cliente prefiere no ir acompañado cuando realiza esta solicitud, por lo que será eliminado.
- El atributo `NAME_INCOME_TYPE` , será recodificado a cuatro categorias: working, commercial, government y others.

In [94]:
```
# NAME_INCOME_TYPE
df_train_object['NAME_INCOME_TYPE'].value_counts(dropna=False)
```

Out[94]:
```
Working                142719
Commercial associate    63652
```

```
Pensioner               51993
State servant           19836
Student                    15
Unemployed                 15
Maternity leave             2
Name: NAME_INCOME_TYPE, dtype: int64
```

In [95]:
```
pd.crosstab(index=df_train_object['NAME_INCOME_TYPE'], columns=df_train_object['TARGET_'], normalize='index').T
```

Out[95]:

NAME_INCOME_TYPE	Commercial associate	Maternity leave	Pensioner	State servant	Student	Unemployed	Working
TARGET_							
Buen pagador	0.921605	0.0	0.945339	0.940109	1.0	0.466667	0.900567
Mal pagador	0.078395	1.0	0.054661	0.059891	0.0	0.533333	0.099433

In [96]:
```
# Recodificación a categorias NAME_INCOME_TYPE - Tipo de ingreso por parte del cliente - segun analisis de tabla
#=============================================================================================
name_income_type = df_train_object['NAME_INCOME_TYPE']
df_train['NAME_INCOME_TYPE'] = np.where((name_income_type == 'Working'), "working" ,
                                np.where((name_income_type == 'Commercial associate'), "commercial",
                                   np.where((name_income_type == 'Pensioner') | (name_income_type == 'Maternity leave') |
                                            (name_income_type == 'Student') | (name_income_type == 'Unemployed'), "others", "government
```

In [97]:
```
# NAME_INCOME_TYPE resultante
df_train['NAME_INCOME_TYPE'].value_counts()
```

Out[97]:
```
working       142719
commercial     63652
others         52025
government     19836
Name: NAME_INCOME_TYPE, dtype: int64
```

In [98]:
```
plt.figure(figsize=(5, 3))
hlp.countplot(df_train, 'NAME_INCOME_TYPE', 'Distribución del tipo de ingreso por parte del cliente');
```

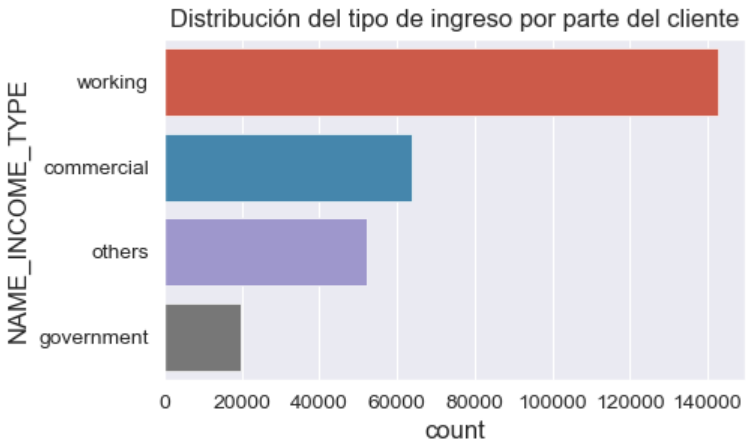

In [99]:
```
# Resultado de la recategorizacion
plt.figure(figsize=(20, 4))

plt.subplot(1,2,1)
sns.countplot(x="NAME_TYPE_SUITE", hue="TARGET_", data=df_train);

plt.subplot(1,2,2)
sns.countplot(x="NAME_INCOME_TYPE", hue="TARGET_", data=df_train);
```

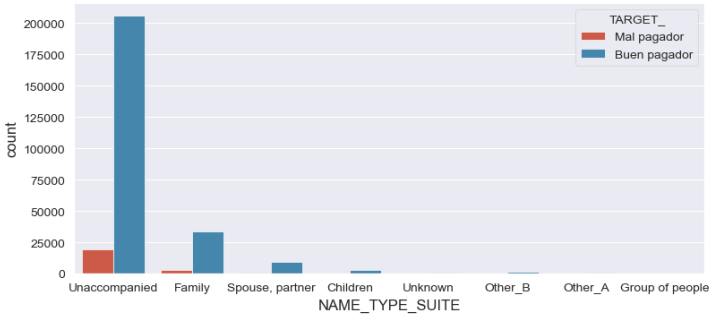

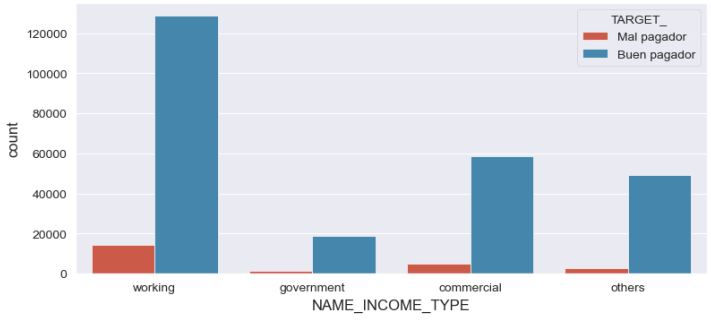

De la recodificación anterior, se analizará el comportamiento de ambas variable en el análisis bivariado.

Gráfico de Atributos :

- `NAME_EDUCATION_TYPE` : Máximo nivel educacional por parte del cliente.
- `NAME_FAMILY_STATUS` : Situación familiar del cliente.

In [100…]
```
# Analisis con grafico de barras #
plt.figure(figsize=( 20, 4 ))

# Atributo NAME_EDUCATION_TYPE - Máximo nivel educacional por parte del cliente
plt.subplot(1,2,1)
hlp.countplot(df_train_object, 'NAME_EDUCATION_TYPE', 'Distribución del máximo nivel educacional del cliente');

# Atributo NAME_FAMILY_STATUS - Situación familiar del cliente #
plt.subplot(1,2,2)
hlp.countplot(df_train_object, 'NAME_FAMILY_STATUS', 'Distribución de la situación familiar del cliente');
```

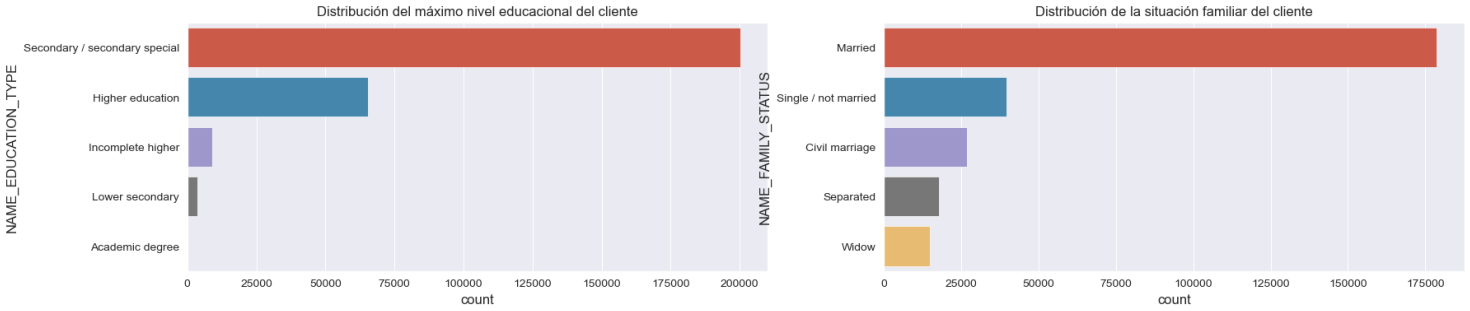

- El atributo `NAME_EDUCATION_TYPE` será recodificado a 3 categorias, y se observa que en general los clientes cuentan con estudios secundarios.
- El atributo `NAME_FAMILY_STATUS` será recodificado a 3 categorias, y los clientes indican ser casados a la hora de solicitar un crédito.

In [101…]
```
# NAME_EDUCATION_TYPE
df_train_object['NAME_EDUCATION_TYPE'].value_counts()
```

Out[101…]
```
Secondary / secondary special    200125
Higher education                  65321
Incomplete higher                  9032
Lower secondary                    3608
Academic degree                     146
Name: NAME_EDUCATION_TYPE, dtype: int64
```

In [102…]
```
pd.crosstab(index=df_train_object['NAME_EDUCATION_TYPE'], columns=df_train_object['TARGET_'], normalize='index')
```

Out[102…]

TARGET_	Buen pagador	Mal pagador
NAME_EDUCATION_TYPE		
Academic degree	0.979452	0.020548
Higher education	0.943449	0.056551
Incomplete higher	0.911205	0.088795
Lower secondary	0.889967	0.110033
Secondary / secondary special	0.908432	0.091568

In [103…]
```
# Recodificación a categorias NAME_EDUCATION_TYPE - Máximo nivel educacional por parte del cliente - segun analisis de tabla
#=============================================================================================
name_education_type = df_train_object['NAME_EDUCATION_TYPE']
df_train['NAME_EDUCATION_TYPE'] = np.where(((name_education_type == 'Secondary / secondary special') |\
                                            (name_education_type == 'Incomplete higher')), "secondary" ,\
                                   np.where(((name_education_type == 'Higher education') |\
                                             (name_education_type == 'Academic degree')),  "university", "school"))
```

In [104…]
```
# NAME_EDUCATION_TYPE resultante
df_train['NAME_EDUCATION_TYPE'].value_counts()
```

Out[104…]
```
secondary     209157
university     65467
school          3608
Name: NAME_EDUCATION_TYPE, dtype: int64
```

In [105…]
```
plt.figure(figsize=(5, 3))
hlp.countplot(df_train, 'NAME_EDUCATION_TYPE', 'Distribución del máximo nivel educacional del cliente');
```

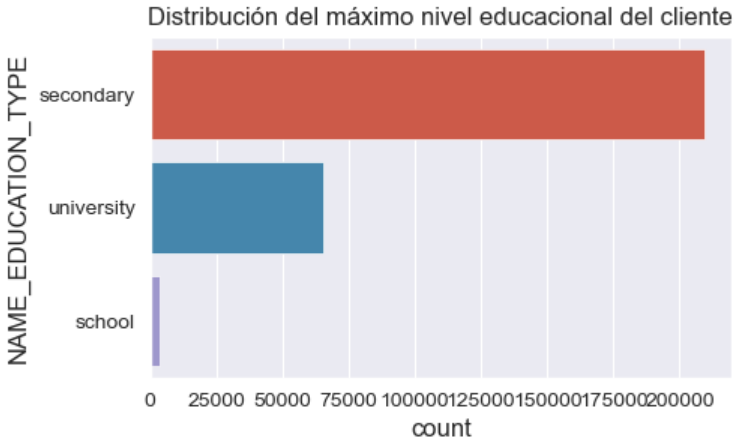

In [106…
```
# NAME_FAMILY_STATUS
df_train_object['NAME_FAMILY_STATUS'].value_counts()
```

Out[106…
```
Married                 178711
Single / not married     39709
Civil marriage           26981
Separated                17846
Widow                    14985
Name: NAME_FAMILY_STATUS, dtype: int64
```

In [107…
```
pd.crosstab(index=df_train_object['NAME_FAMILY_STATUS'], columns=df_train_object['TARGET_']).apply(lambda r: r/r.sum() * 100, axis=1).T
```

Out[107…

NAME_FAMILY_STATUS	Civil marriage	Married	Separated	Single / not married	Widow
TARGET_					
Buen pagador	89.755754	92.18291	91.482685	89.747916	94.020687
Mal pagador	10.244246	7.81709	8.517315	10.252084	5.979313

In [108…
```
# Recodificación a categorias NAME_FAMILY_STATUS - Situación familiar del cliente - segun analisis de tabla
#==============================================================================================
name_family_status = df_train_object['NAME_FAMILY_STATUS']
df_train['NAME_FAMILY_STATUS'] = np.where(((name_family_status == 'Married') | (name_family_status == 'Civil marriage')), "married" , 'n
```

In [109…
```
df_train['NAME_FAMILY_STATUS'].value_counts()
```

Out[109…
```
married        205692
not_married     72540
Name: NAME_FAMILY_STATUS, dtype: int64
```

In [110…
```
plt.figure(figsize=(5, 3))
hlp.countplot(df_train, 'NAME_FAMILY_STATUS', 'Distribución de la situación familiar del cliente');
```

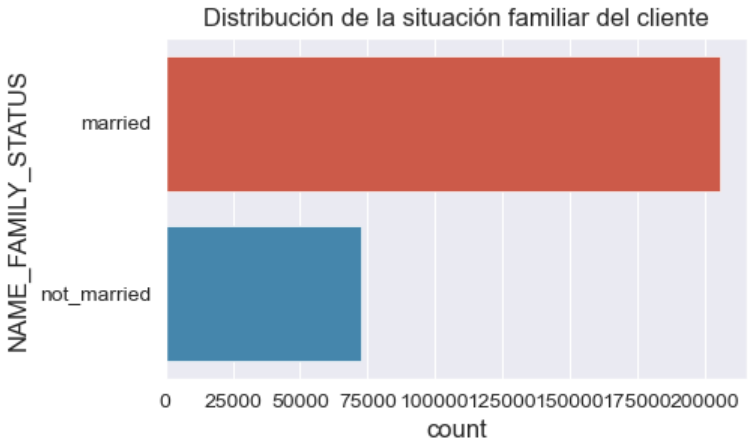

In [111…
```
# Resultado de la recodificacion
plt.figure(figsize=(20, 4))

plt.subplot(1,2,1)
sns.countplot(x="NAME_EDUCATION_TYPE", hue="TARGET_", data=df_train);
```

```
plt.subplot(1,2,2)
sns.countplot(x="NAME_FAMILY_STATUS", hue="TARGET_", data=df_train);
```

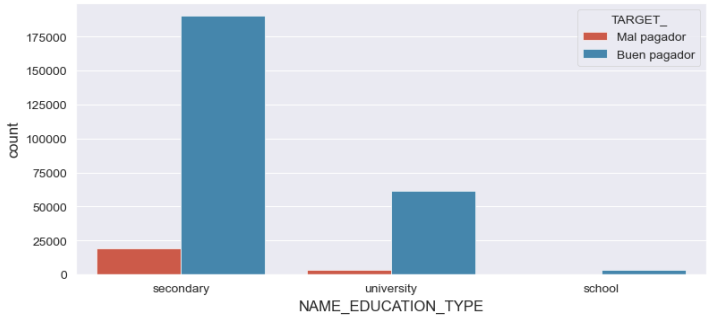

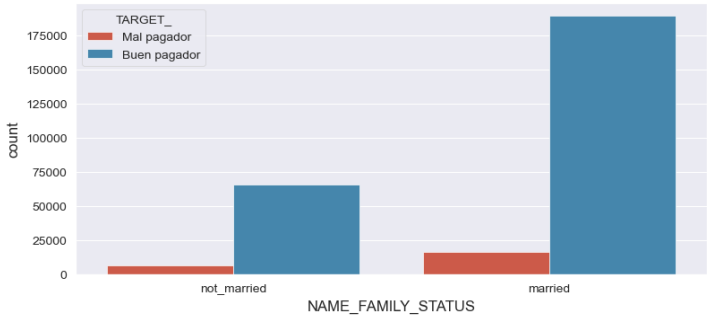

De la recodificación anterior, se analizará el comportamiento de ambas variables en el análisis bivariado.

Gráfico de atributos :

- `NAME_HOUSING_TYPE` : Cuál es la situación habitacional del cliente.
- `OCCUPATION_TYPE` : Cuál es la profesión del cliente.

In [112…

```
# Analisis con grafico de barras #
plt.figure(figsize=( 20, 5 ))

# Atributo NAME_HOUSING_TYPE - Cuál es la situación habitacional del cliente #
plt.subplot(1,2,1)
hlp.countplot(df_train_object, 'NAME_HOUSING_TYPE', 'Distribución de la situación habitacional del cliente');

# Atributo OCCUPATION_TYPE - Tipo de organización donde trabaja el cliente #
plt.subplot(1,2,2)
hlp.countplot(df_train_object, 'OCCUPATION_TYPE', 'Distribución de la profesión del cliente');
```

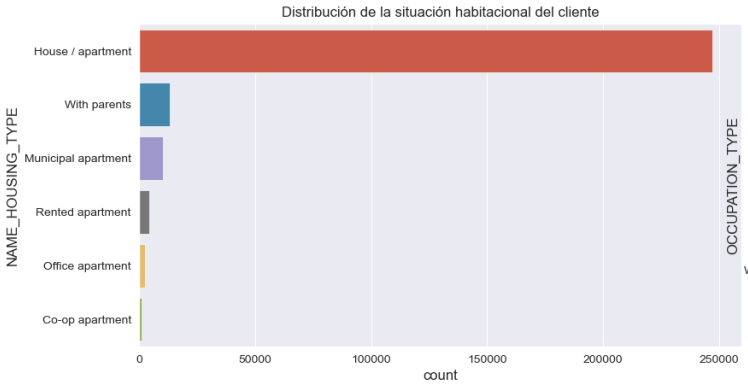

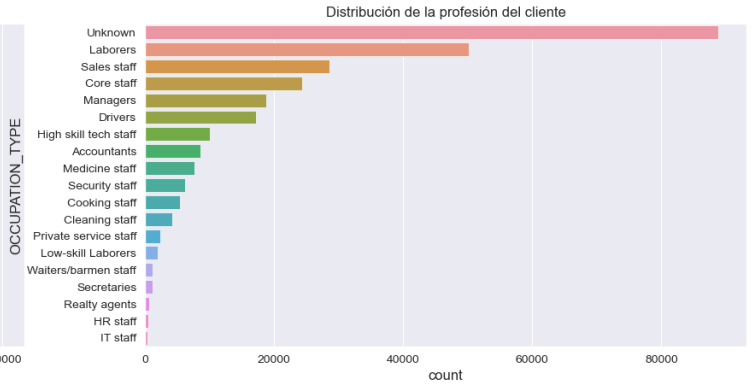

- El atributo `NAME_HOUSING_TYPE` será recodificado a tres categorias, los clientes señalan tener casa o apartamento.
- El atributo `OCCUPATION_TYPE` será recodificado a 5 niveles, más la categoria `Unknown` a clientes que no se identifican en algun nivel profesional.

In [113…

```
plt.figure(figsize=(15, 4))
sns.histplot(binwidth=0.5, x='NAME_HOUSING_TYPE', hue="TARGET_", data=df_train_object, stat="count", multiple="stack");
plt.xticks(rotation=0);
```

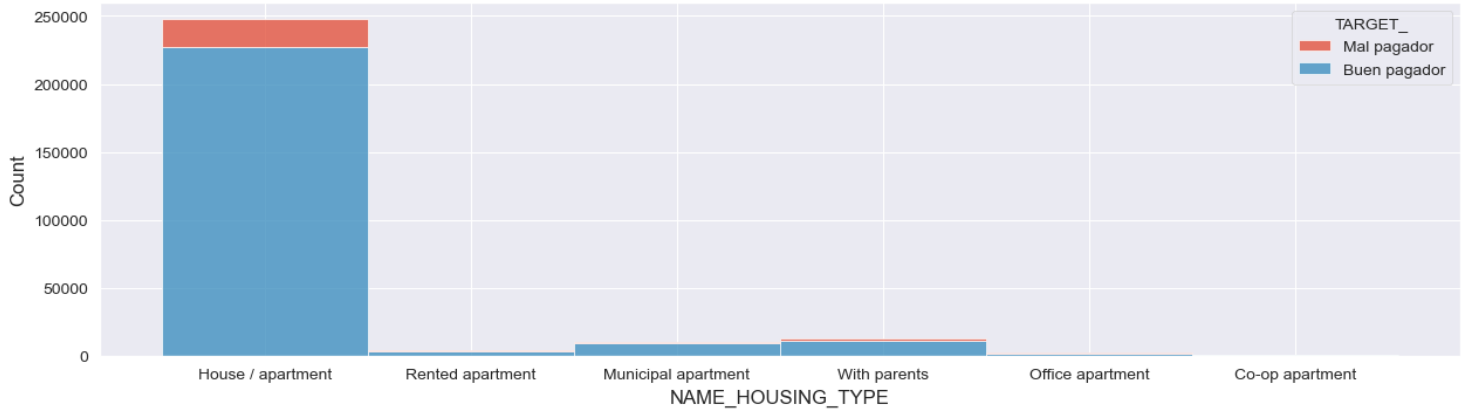

In [114…

```
pd.crosstab(index=df_train_object['NAME_HOUSING_TYPE'], columns=df_train_object['TARGET_']).apply(lambda r: r/r.sum() * 100, axis=1).T
```

Out[114…

NAME_HOUSING_TYPE	Co-op apartment	House / apartment	Municipal apartment	Office apartment	Rented apartment	With parents
TARGET_						
Buen pagador	91.649899	91.939415	91.120445	93.208031	87.296037	87.79755
Mal pagador	8.350101	8.060585	8.879555	6.791969	12.703963	12.20245

In [115…

```
# Recodificación a categorias NAME_HOUSING_TYPE - Cuál es la situación habitacional del cliente - segun analisis de tabla y grafico
#=============================================================================================
name_housing_type = df_train_object['NAME_HOUSING_TYPE']
df_train['NAME_HOUSING_TYPE'] = np.where(((name_housing_type == 'With parents') | (name_housing_type == 'Rented apartment')), 'with_pare
                                    np.where((name_housing_type == 'House / apartment'), 'house_apartment', 'others'))
```

In [116…

```
# NAME_HOUSING_TYPE resultante
df_train['NAME_HOUSING_TYPE'].value_counts()
```

Out[116…

```
house_apartment           247389
with_parents_or_rented     17271
others                     13572
Name: NAME_HOUSING_TYPE, dtype: int64
```

In [117…

```
plt.figure(figsize=(5, 3))
hlp.countplot(df_train, 'NAME_HOUSING_TYPE', 'Distribución de la situación habitacional del cliente');
```

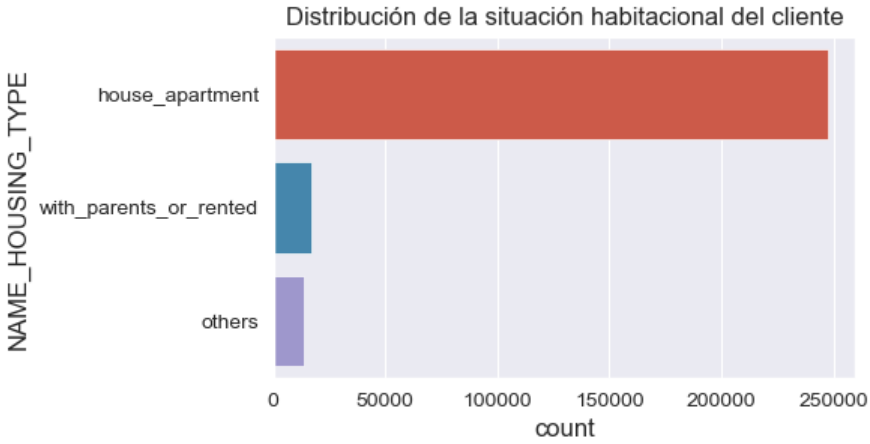

In [118…

```
plt.figure(figsize=(15, 4))
sns.histplot(binwidth=0.5, x="OCCUPATION_TYPE", hue="TARGET_", data=df_train_object, stat="count", multiple="stack");
plt.xticks(rotation=60);
```

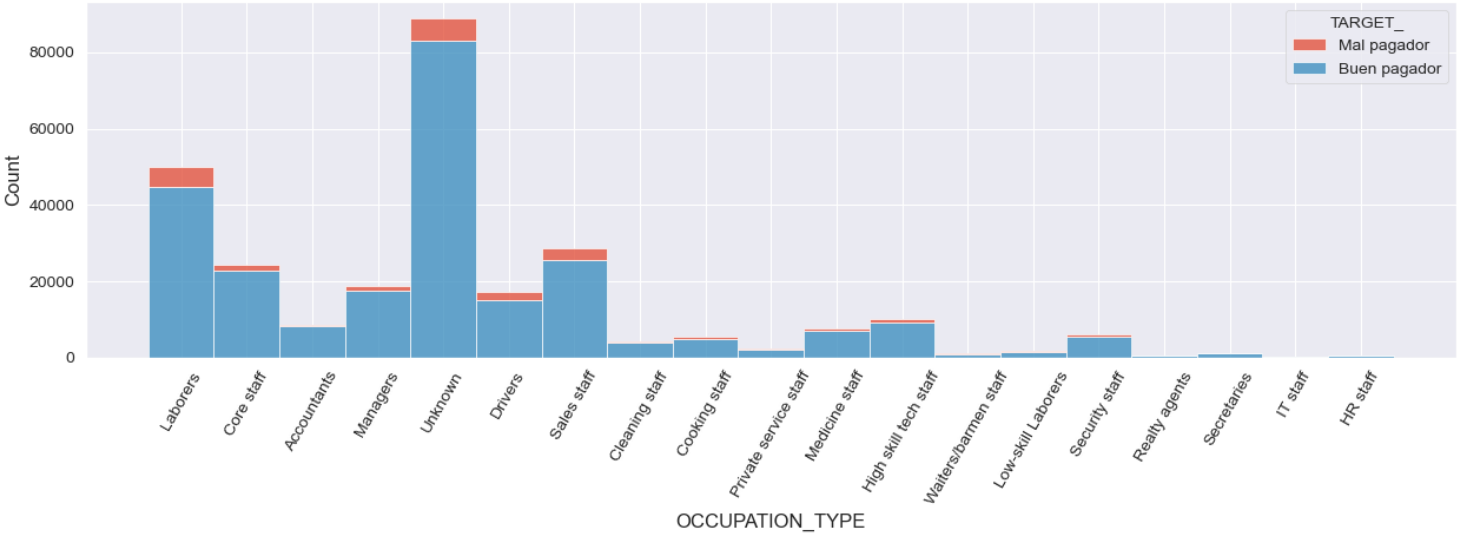

Como se observa, existen 18 categorías únicas de la varible `OCCUPATION_TYPE`, por lo que se recategoriza a 5 niveles para disminuir la cantidad de valores dentro de esta. Se debe considerar además que esta varible posee 88800 nulos que corresponden a un 31.9% de sus observaciones, por lo que, se define una categoria como `Unknown` para representar a los clientes que no tienen definido el tipo de ocupación.

Para agrupar, se analiza la tasa de malos pagadores por categoría, agrupando categorías que tienen % de malos pagadores similares. Así, se espera obtener distintos grupos que contengan distintos tipos de ocupación, con un comportamiento similar en función de la variable objetivo, y a su vez, que los distintos grupos tengan comportamiento diferente (lo cual se verá en análisis bivariado).

In [119…
```
# Recodificación de categorias OCCUPATION_TYPE - Cuál es la profesión del cliente
#=================================================================================================
lista_g1 = ['Core staff','High skill tech staff','HR staff','IT staff','Managers',
            'Medicine staff','Private service staff','Realty agents','Secretaries']
lista_g2 = ['Cleaning staff','Sales staff']
lista_g3 = ['Cooking staff','Laborers','Security staff']
lista_g4 = ['Drivers','Low-skill Laborers','Waiters/barmen staff']
lista_g5 = ['Accountants']

df_train['OCCUPATION_TYPE'] = df_train['OCCUPATION_TYPE'].replace(lista_g1,'OCCUPATION_TYPE_G1')
df_train['OCCUPATION_TYPE'] = df_train['OCCUPATION_TYPE'].replace(lista_g2,'OCCUPATION_TYPE_G2')
df_train['OCCUPATION_TYPE'] = df_train['OCCUPATION_TYPE'].replace(lista_g3,'OCCUPATION_TYPE_G3')
df_train['OCCUPATION_TYPE'] = df_train['OCCUPATION_TYPE'].replace(lista_g4,'OCCUPATION_TYPE_G4')
df_train['OCCUPATION_TYPE'] = df_train['OCCUPATION_TYPE'].replace(lista_g5,'OCCUPATION_TYPE_G5')
```

In [120…
```
# OCCUPATION_TYPE Resultante
df_train['OCCUPATION_TYPE'].value_counts()
```

Out[120…
```
Unknown               88800
OCCUPATION_TYPE_G1    65962
OCCUPATION_TYPE_G3    61746
OCCUPATION_TYPE_G2    32769
OCCUPATION_TYPE_G4    20348
OCCUPATION_TYPE_G5     8607
Name: OCCUPATION_TYPE, dtype: int64
```

In [121…
```
plt.figure(figsize=(5, 3))
hlp.countplot(df_train, 'OCCUPATION_TYPE', 'Distribución de la profesión del cliente');
```

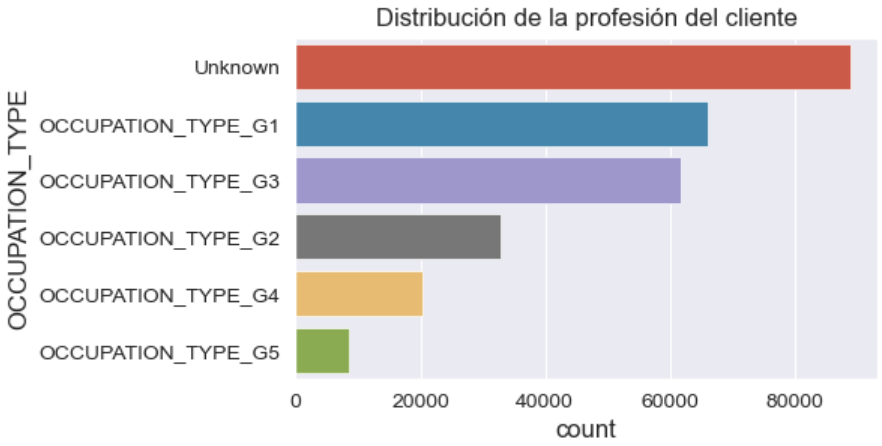

El ajuste del atributo `OCCUPATION_TYPE`, fue resumido a 5 categorias y de la imputacion de nulos se reemplazo el valor `NaN` por `Unknown`.

- Grupo 1 `OCCUPATION TYPE` representa a las profesiones: `Core staff`, `High skill tech staff`, `HR staff`, `IT staff`, `Managers`, `Medicine staff`, `Private service staff`, `Realty agents`, `Secretaries`
- Grupo 2 `OCCUPATION TYPE` representa a las profesiones: `Cleaning staff`, `Sales staff`
- Grupo 3 `OCCUPATION TYPE` representa a las profesiones: `Cooking staff`, `Laborers`, `Security staff`
- Grupo 4 `OCCUPATION TYPE` representa a las profesiones: `Drivers`, `Low-skill Laborers`, `Waiters/barmen staff`
- Grupo 5 `OCCUPATION TYPE` representa a las profesiones: `Accountants`

In [122…
```
# Resultado de la recodificación
plt.figure(figsize=(20, 4))

plt.subplot(1,2,1)
sns.countplot(x="NAME_HOUSING_TYPE", hue="TARGET_", data=df_train);

plt.subplot(1,2,2)
sns.countplot(x="OCCUPATION_TYPE", hue="TARGET_", data=df_train);
plt.xticks(rotation=60);
```

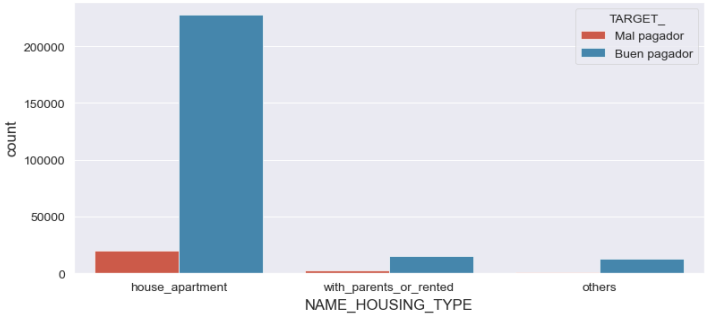

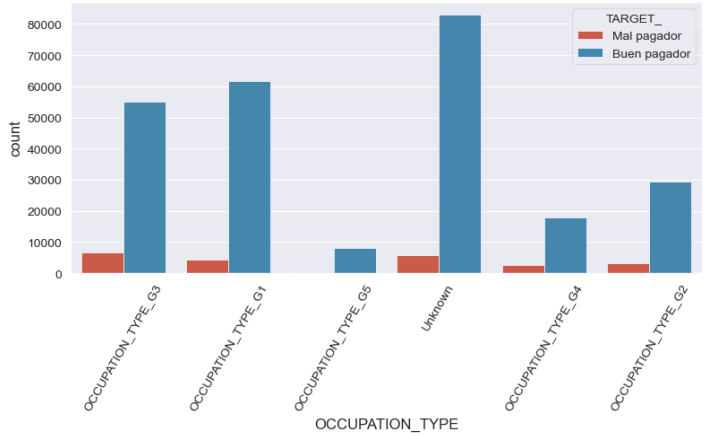

De la recodificación anterior, se analizará el comportamiento de ambas variables en el análisis bivariado.

Gráfico de atributo :

- `ORGANIZATION_TYPE` : Tipo de organización donde trabaja el cliente.

In [123…
```
# Atributo ORGANIZATION_TYPE - Tipo de organización donde trabaja el cliente
plt.figure(figsize=(15, 8))
hlp.countplot(df_train_object, 'ORGANIZATION_TYPE', 'Distribución del tipo de organización donde trabaja el cliente');
```

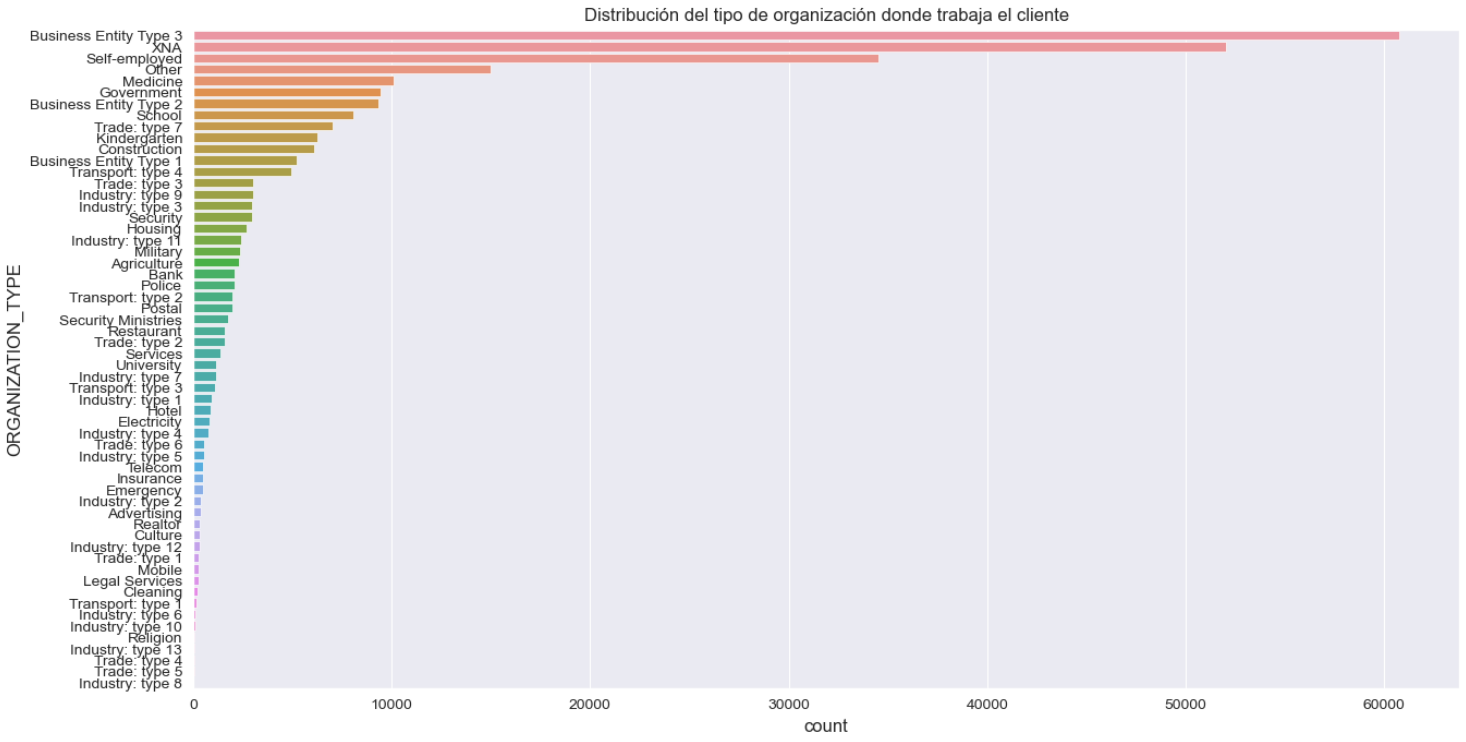

- El atributo `ORGANIZATION_TYPE` , será recodificado en varias categorias, dado que se observan diversas entidades y subcategorias según el tipo. También se observa la categoria `XNA` con una alta concentración de observaciones nulas.

In [124…
```
len(df_train_object['ORGANIZATION_TYPE'].value_counts())
```

Out[124…
```
58
```

Como se observa, existen 58 categorías únicas de la varible `ORGANIZATION_TYPE` , por lo que se recategoriza a 8 niveles para disminuir la cantidad de valores dentro de esta. Se debe considerar además que esta variable posee 52008 nulos que se sumaran a la última categoría.

La primera categorización se realiza en base a la descripción de la variable, donde por ejemplo valores como `Industry: type 1` , `Industry: type 10` (distintos tipos de organizaciones), se agrupan dentro de una misma categoría `Industry` . Para esto se aplica la función `extrae_tipo` .

Del resultado de esta agrupación resultan 35 categorías, por lo que se vuelven a categorizar para reducir la dimensionalidad. Para esto se utiliza la misma metodología que con la variable `ORGANIZATION_TYPE` , donde se analiza el % de malos según categoría. Así, se espera obtener distintos grupos que contengan distintos tipos de organización, con un comportamiento similar en función de la variable objetivo, y a su vez, que los distintos grupos tengan comportamiento diferente (lo cual se verá en análisis bivariado).

In [125…

```
# Recodificacion para recategorizar ORGANIZATION_TYPE
#=====================================================================================================

# De esta recodificacion se obtiene  35 categorias
df_train['ORGANIZATION_TYPE'] = df_train['ORGANIZATION_TYPE'].apply(lambda x: hlp.extrae_tipo(x))

# Se agrupan las 35 categorias segun niveles de riesgo en 8 niveles
lista_g1 = ["Construction","Realtor","Restaurant"]
lista_g2 = ["Agriculture","Cleaning","Security","Self-employed","Transport"]
lista_g3 = ["Business Entity","Trade"]
lista_g4 = ["Advertising","Industry","Mobile","Postal"]
lista_g5 = ["Housing","Legal Services","Other"]
lista_g6 = ["Electricity","Emergency","Government","Kindergarten","Medicine","Services","Telecom"]
lista_g7 = ["Hotel","Insurance","Religion","School"]
lista_g8 = ["Bank","Culture","Military","Police","Security Ministries","University","XNA"]

df_train['ORGANIZATION_TYPE'] = df_train['ORGANIZATION_TYPE'].replace(lista_g1,'ORGANIZATION_TYPE_G1')
df_train['ORGANIZATION_TYPE'] = df_train['ORGANIZATION_TYPE'].replace(lista_g2,'ORGANIZATION_TYPE_G2')
df_train['ORGANIZATION_TYPE'] = df_train['ORGANIZATION_TYPE'].replace(lista_g3,'ORGANIZATION_TYPE_G3')
df_train['ORGANIZATION_TYPE'] = df_train['ORGANIZATION_TYPE'].replace(lista_g4,'ORGANIZATION_TYPE_G4')
df_train['ORGANIZATION_TYPE'] = df_train['ORGANIZATION_TYPE'].replace(lista_g5,'ORGANIZATION_TYPE_G5')
df_train['ORGANIZATION_TYPE'] = df_train['ORGANIZATION_TYPE'].replace(lista_g6,'ORGANIZATION_TYPE_G6')
df_train['ORGANIZATION_TYPE'] = df_train['ORGANIZATION_TYPE'].replace(lista_g7,'ORGANIZATION_TYPE_G7')
df_train['ORGANIZATION_TYPE'] = df_train['ORGANIZATION_TYPE'].replace(lista_g8,'ORGANIZATION_TYPE_G8')
```

In [126…

```
# Atributo ORGANIZATION_TYPE - Tipo de organización donde trabaja el cliente
plt.figure(figsize=(15, 5))
hlp.countplot(df_train, 'ORGANIZATION_TYPE', 'Distribución del tipo de organización donde trabaja el cliente');
```

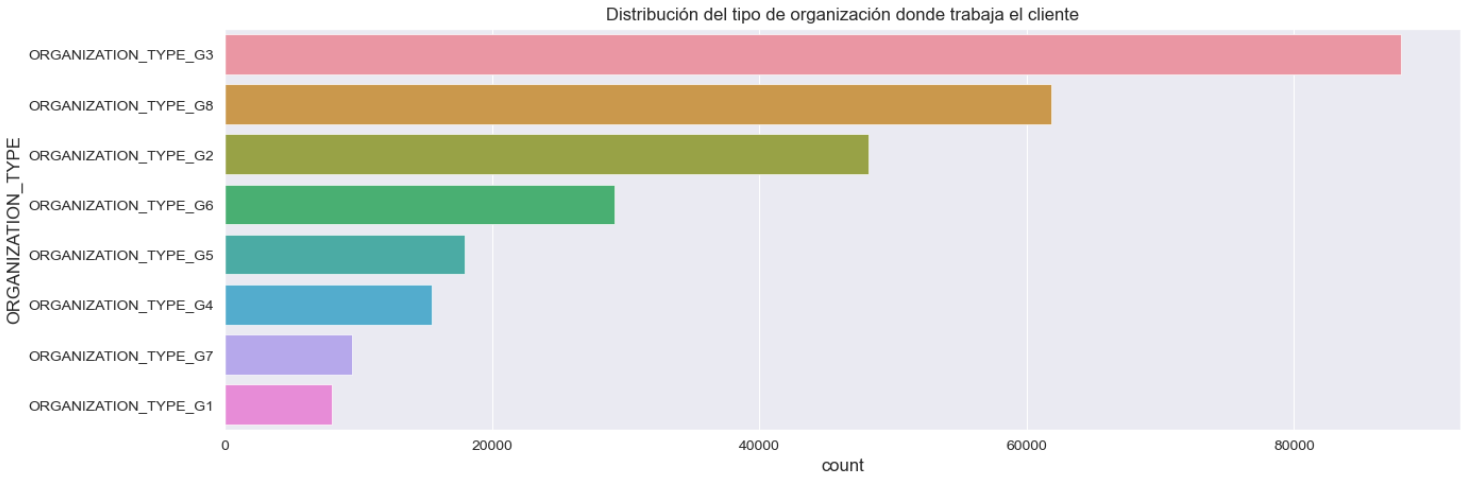

La 8 categorias son:

- Grupo 1 `ORGANIZATION TYPE` representa a las organizaciones: `Construction` , `Realtor` , `Restaurant`
- Grupo 2 `ORGANIZATION TYPE` representa a las organizaciones: `Agriculture` , `Cleaning` , `Security` , `Self-employed` , `Transport`
- Grupo 3 `ORGANIZATION TYPE` representa a las organizaciones: `Business` , `Entity` , `Trade`
- Grupo 4 `ORGANIZATION TYPE` representa a las organizaciones: `Advertising` , `Industry` , `Mobile` , `Postal`
- Grupo 5 `ORGANIZATION TYPE` representa a las organizaciones: `Housing` , `Legal Services` , `Other`
- Grupo 6 `ORGANIZATION TYPE` representa a las organizaciones: `Electricity` , `Emergency` , `Government` , `Kindergarten` , `Medicine` , `Services` , `Telecom`
- Grupo 7 `ORGANIZATION TYPE` representa a las organizaciones: `Hotel` , `Insurance` , `Religion` , `School`
- Grupo 8 `ORGANIZATION TYPE` representa a las organizaciones: `Bank` , `Culture` , `Military` , `Police` , `Security` , `Ministries` , `University` y `XNA` .

In [127…

```
# Resultado de la recodificación
plt.figure(figsize=(20, 5))
sns.countplot(x="ORGANIZATION_TYPE", hue="TARGET_", data=df_train);
plt.xticks(rotation=10);
```

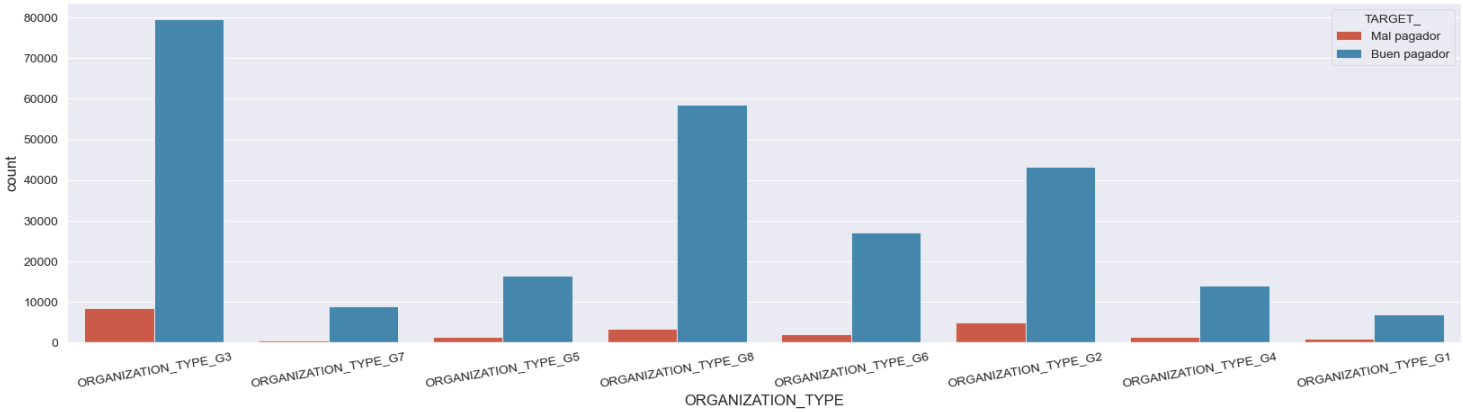

De la recodificación anterior, se analizará el comportamiento de ambas variables en el análisis bivariado.

Gráfico de atributos:

- `FLAG_DOCUMENT_2` : Indicador documento 2.
- `FLAG_DOCUMENT_3` : Indicador documento 3.
- `FLAG_DOCUMENT_4` : Indicador documento 4.
- `FLAG_DOCUMENT_5` : Indicador documento 5.
- `FLAG_DOCUMENT_6` : Indicador documento 6.
- `FLAG_DOCUMENT_7` : Indicador documento 7.

In [128…

```
# Columnas agrupadas para graficar
data_graf_obj3 = df_train_object.loc[:, [ 'FLAG_DOCUMENT_2', 'FLAG_DOCUMENT_3', 'FLAG_DOCUMENT_4',
                                          'FLAG_DOCUMENT_5', 'FLAG_DOCUMENT_6', 'FLAG_DOCUMENT_7' ]]
hlp.graficos_barra(data_graf_obj3)
```

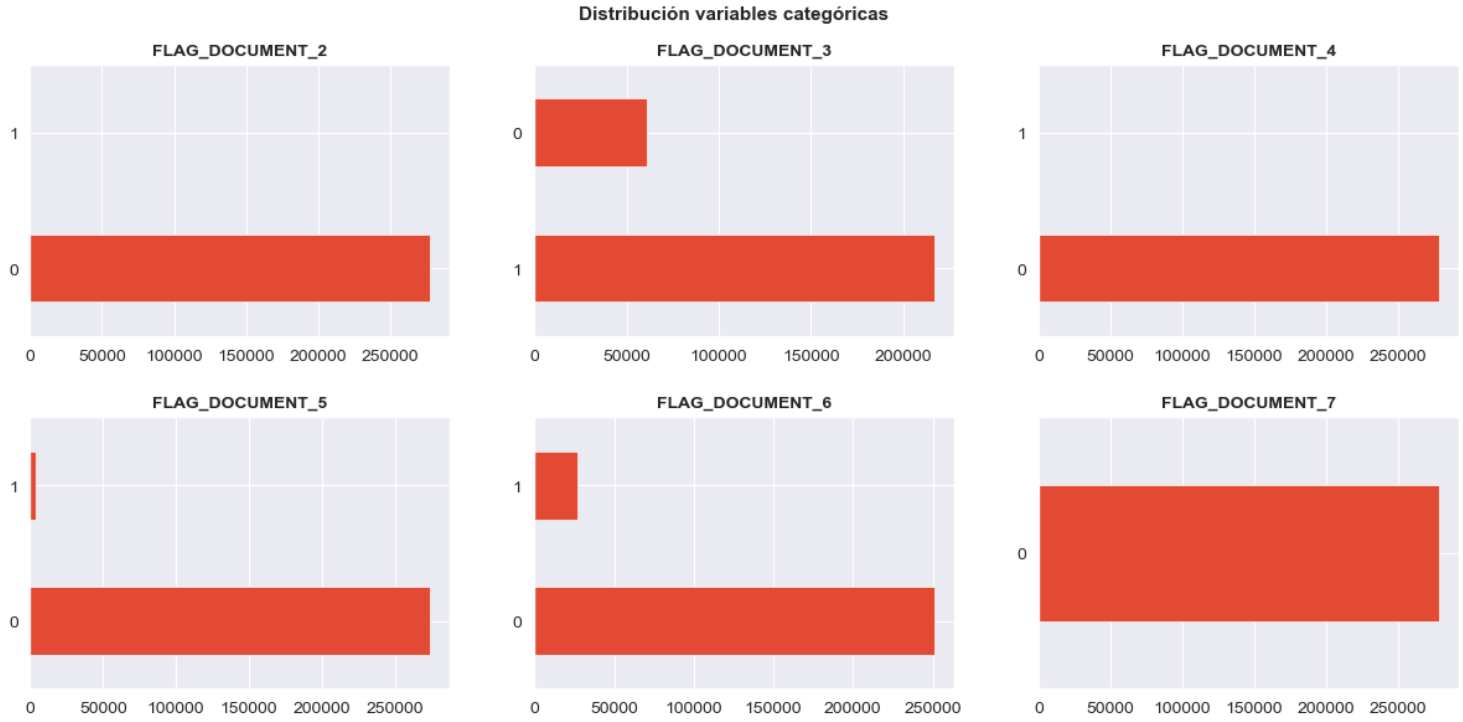

Estos atributos: `FLAG_DOCUMENT_2` , `FLAG_DOCUMENT_3` , `FLAG_DOCUMENT_4` , `FLAG_DOCUMENT_5` , `FLAG_DOCUMENT_6` , `FLAG_DOCUMENT_7` , serán eliminados , ya que algunas categorías solo tienen un nivel, además de indicar un flag de documento, donde no sabemos cual es más o menos importante.

Gráfico de atributos:

- `FLAG_DOCUMENT_8` : Indicador documento 8.
- `FLAG_DOCUMENT_9` : Indicador documento 9.
- `FLAG_DOCUMENT_10` : Indicador documento 10.
- `FLAG_DOCUMENT_11` : Indicador documento 11.
- `FLAG_DOCUMENT_12` : Indicador documento 12.
- `FLAG_DOCUMENT_13` : Indicador documento 13.

In [129…

```
# Columnas agrupadas para graficar
data_graf_obj4 = df_train_object.loc[:, [ 'FLAG_DOCUMENT_8', 'FLAG_DOCUMENT_9', 'FLAG_DOCUMENT_10',
```

```
                                    'FLAG_DOCUMENT_11', 'FLAG_DOCUMENT_12', 'FLAG_DOCUMENT_13' ]]
hlp.graficos_barra(data_graf_obj4)
```

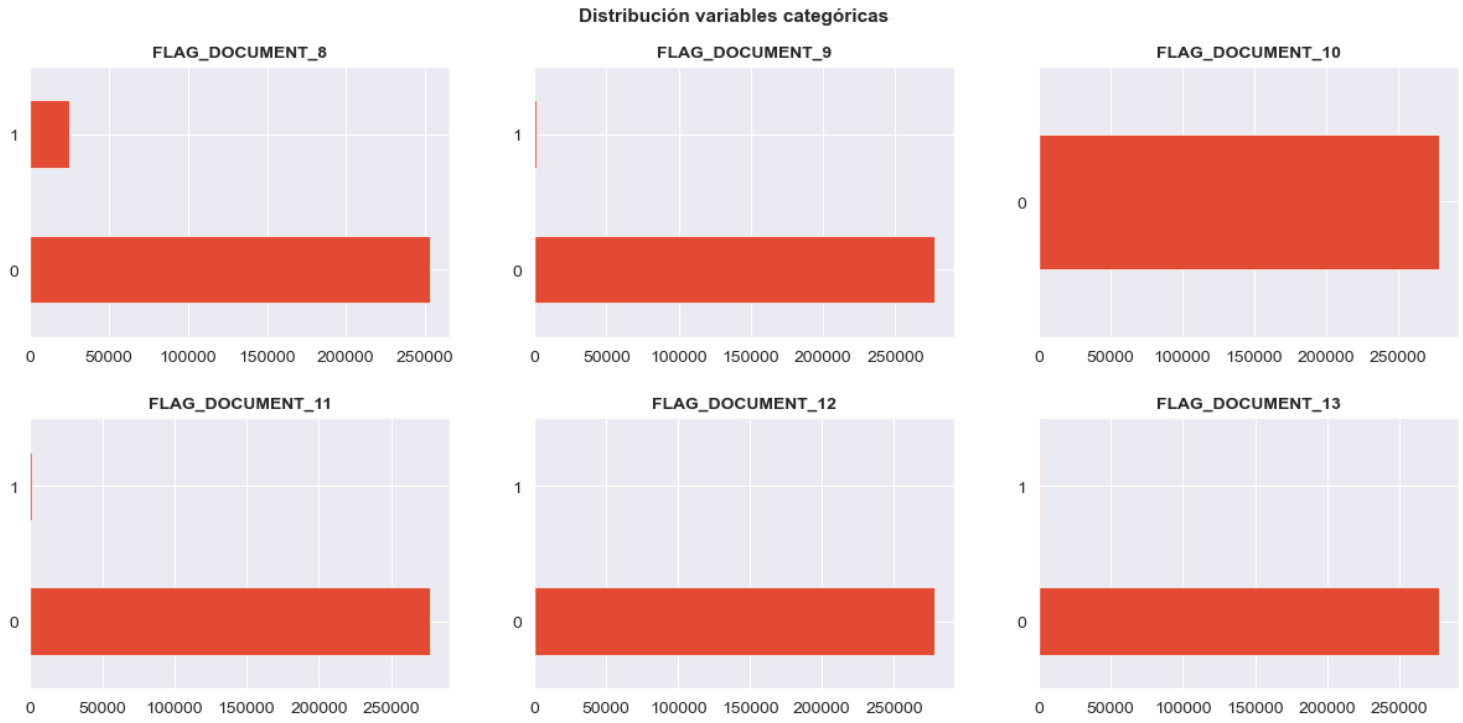

Estos atributos: `FLAG_DOCUMENT_8` , `FLAG_DOCUMENT_9` , `FLAG_DOCUMENT_10` , `FLAG_DOCUMENT_11` , `FLAG_DOCUMENT_12` y `FLAG_DOCUMENT_13` serán eliminados , ya que algunas solo tienen un nivel, además de indicar un flag de documento, donde no sabemos cual es más o menos importante.

Gráfico de atributos:

- `FLAG_DOCUMENT_14` : Indicador documento 14.
- `FLAG_DOCUMENT_15` : Indicador documento 15.
- `FLAG_DOCUMENT_16` : Indicador documento 16.
- `FLAG_DOCUMENT_17` : Indicador documento 17.
- `FLAG_DOCUMENT_18` : Indicador documento 18.
- `FLAG_DOCUMENT_19` : Indicador documento 19.

In [130…

```
# Columnas agrupadas para graficar
data_graf_obj5 = df_train_object.loc[:, [ 'FLAG_DOCUMENT_14', 'FLAG_DOCUMENT_15', 'FLAG_DOCUMENT_16',
                                    'FLAG_DOCUMENT_17', 'FLAG_DOCUMENT_18', 'FLAG_DOCUMENT_19' ]]
hlp.graficos_barra(data_graf_obj5)
```

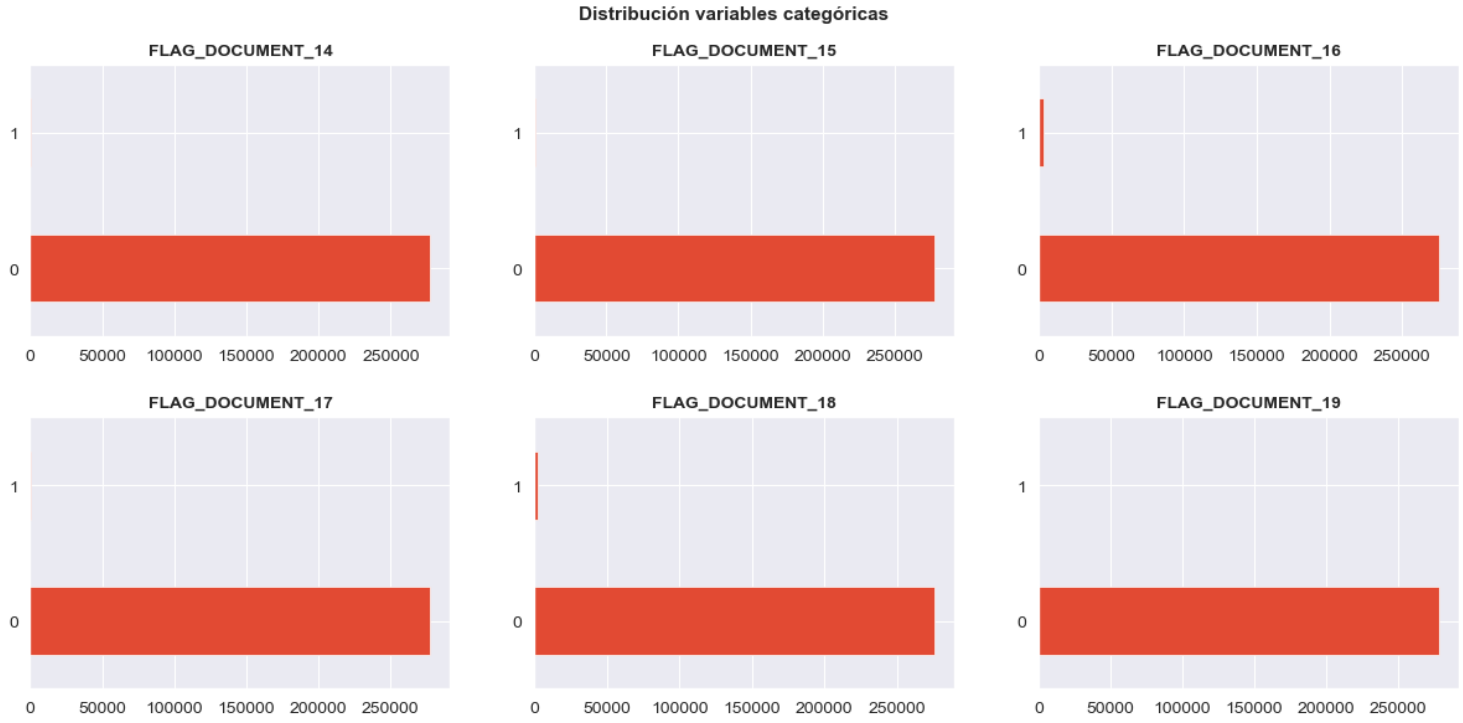

- Estos atributos `FLAG_DOCUMENT_14` , `FLAG_DOCUMENT_15` , `FLAG_DOCUMENT_16` , `FLAG_DOCUMENT_17` , `FLAG_DOCUMENT_18` y `FLAG_DOCUMENT_19` serán eliminados, ya que estas categorías sólo tienen un nivel o estan muy sesgadas a una sola categoría, además de indicar un flag de documento, pero no sabemos cual es más o menos importante.

Gráfico de atributos:

- `FLAG_DOCUMENT_20` : Indicador documento 20.
- `FLAG_DOCUMENT_21` : Indicador documento 21.

In [131…
```
# Analisis con grafico de barras #
plt.figure(figsize=( 20, 5 ))
# Atributo FLAG_DOCUMENT_20 -
plt.subplot(1,2,1)
hlp.countplot(df_train_object, 'FLAG_DOCUMENT_20', 'Distribución de documento 20');

# Atributo FLAG_DOCUMENT_21  -
plt.subplot(1,2,2)
hlp.countplot(df_train_object, 'FLAG_DOCUMENT_21', 'Distribución de documneto 21');
```

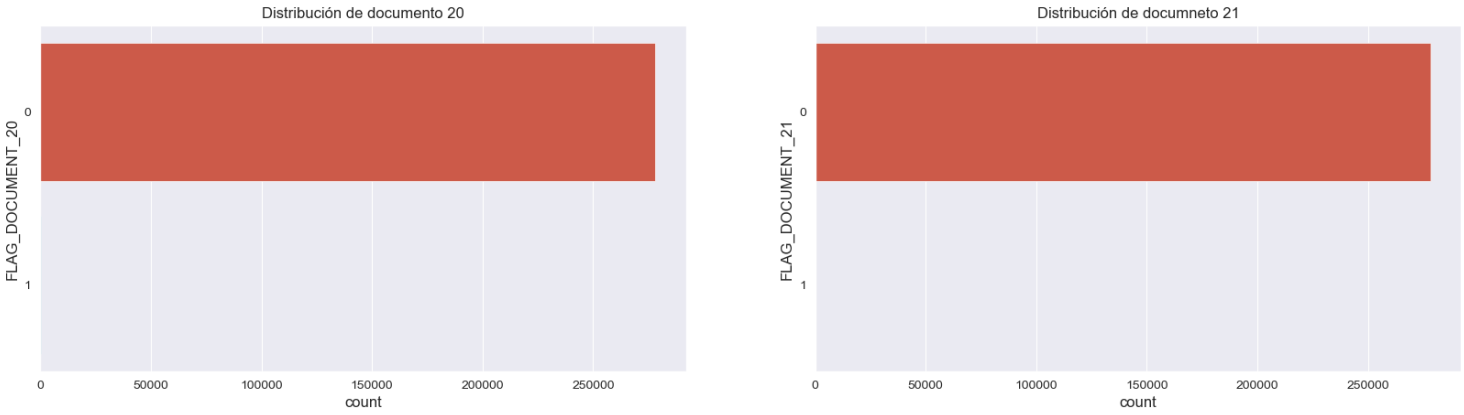

- Se eliminarán los atributos `FLAG_DOCUMENT_20` , `FLAG_DOCUMENT_21` , ya que solo tienen un nivel, además de indicar un flag de documento, pero no sabemos cual es mas o menos importante.

2.11.10 Eliminación de atributos categóricos de análisis univariado

In [132…
```
# Seleccion de columnas categoricas a Eliminar
#=============================================================================================
columns_object_drop = [
    'FLAG_MOBIL', 'FLAG_CONT_MOBILE', 'FLAG_EMAIL', 'REG_REGION_NOT_LIVE_REGION', 'REG_REGION_NOT_WORK_REGION',
    'LIVE_REGION_NOT_WORK_REGION', 'WEEKDAY_APPR_PROCESS_START', 'HOUR_APPR_PROCESS_START',
    'NAME_TYPE_SUITE', 'FLAG_DOCUMENT_2', 'FLAG_DOCUMENT_3', 'FLAG_DOCUMENT_4', 'FLAG_DOCUMENT_5',
    'FLAG_DOCUMENT_6', 'FLAG_DOCUMENT_7', 'FLAG_DOCUMENT_8', 'FLAG_DOCUMENT_9', 'FLAG_DOCUMENT_10',
    'FLAG_DOCUMENT_11', 'FLAG_DOCUMENT_12', 'FLAG_DOCUMENT_13', 'FLAG_DOCUMENT_14', 'FLAG_DOCUMENT_15' ,
    'FLAG_DOCUMENT_16', 'FLAG_DOCUMENT_17', 'FLAG_DOCUMENT_18' , 'FLAG_DOCUMENT_19', 'FLAG_DOCUMENT_20',
    'FLAG_DOCUMENT_21']
```

In [133…
```
len(columns_object_drop)
```

Out[133… 29

In [134…
```
# Eliminacion de Atributos categoricas Transformados:
#=============================================================================================
df_train = df_train.drop(columns = columns_object_drop)
```

In [135…
```
df_train.columns
```

Out[135…
```
Index(['TARGET', 'CODE_GENDER', 'FLAG_OWN_CAR', 'FLAG_OWN_REALTY',
       'CNT_CHILDREN', 'NAME_INCOME_TYPE', 'NAME_EDUCATION_TYPE',
       'NAME_FAMILY_STATUS', 'NAME_HOUSING_TYPE', 'FLAG_WORK_PHONE',
       'FLAG_PHONE', 'OCCUPATION_TYPE', 'CNT_FAM_MEMBERS',
       'REGION_RATING_CLIENT', 'REGION_RATING_CLIENT_W_CITY',
       'REG_CITY_NOT_LIVE_CITY', 'REG_CITY_NOT_WORK_CITY',
       'LIVE_CITY_NOT_WORK_CITY', 'ORGANIZATION_TYPE', 'EXT_SOURCE_2',
       'EXT_SOURCE_3', 'DEF_30_CNT_SOCIAL_CIRCLE', 'DEF_60_CNT_SOCIAL_CIRCLE',
       'AMT_REQ_CREDIT_BUREAU_MON', 'AMT_REQ_CREDIT_BUREAU_YEAR', 'AGE',
       'LOG_AMT_INCOME_TOTAL', 'LOG_AMT_CREDIT', 'WITH_DAYS_WORKED',
       'LOG_DAYS_REGISTRATION', 'LOG_DAYS_ID_PUBLISH', 'PHONE_CHANGE',
       'TARGET_'],
      dtype='object')
```

In [136…
```
df_train.shape
```

Out[136…
```
(278232, 33)
```

2.12 Análisis bivariado de atributos con Vector Objetivo

2.12.1 Gráficos

In [137…
```
# Seleccion de variables continuas
df_train_num = df_train.select_dtypes(include=['float64', 'int'])
df_train_num.columns
```

Out[137…
```
Index(['TARGET', 'CNT_CHILDREN', 'FLAG_WORK_PHONE', 'FLAG_PHONE',
       'CNT_FAM_MEMBERS', 'REGION_RATING_CLIENT', 'REG_CITY_NOT_LIVE_CITY',
       'REG_CITY_NOT_WORK_CITY', 'LIVE_CITY_NOT_WORK_CITY', 'EXT_SOURCE_2',
       'EXT_SOURCE_3', 'DEF_30_CNT_SOCIAL_CIRCLE', 'DEF_60_CNT_SOCIAL_CIRCLE',
       'AMT_REQ_CREDIT_BUREAU_MON', 'AMT_REQ_CREDIT_BUREAU_YEAR', 'AGE',
       'LOG_AMT_INCOME_TOTAL', 'LOG_AMT_CREDIT', 'WITH_DAYS_WORKED',
       'LOG_DAYS_REGISTRATION', 'LOG_DAYS_ID_PUBLISH', 'PHONE_CHANGE'],
      dtype='object')
```

Gráfico de atributos con target:

- `LOG_AMT_INCOME_TOTAL` : ingreso total del cliente
- `LOG_AMT_CREDIT` : cantidad total del préstamo realizado.
- `LOG_DAYS_REGISTRATION` : cantidad de días previos a la última modificación de los registros del cliente previos a la postulación.
- `LOG_DAYS_ID_PUBLISH` : cantidad de días previos a la modificación de su documento de identificación con el cual postulo al préstamo.

In [138…
```
# Gráficos
mask0 = df_train['TARGET_']=='Buen pagador'
mask1 = df_train['TARGET_']=='Mal pagador'

plt.figure(figsize=(20, 10))
plt.subplot(2,2,1)
sns.distplot(df_train['LOG_AMT_INCOME_TOTAL'][mask0].dropna(), kde_kws={"color": "b", "lw": 2, "label": "Buen Pagador"})
sns.distplot(df_train['LOG_AMT_INCOME_TOTAL'][mask1], kde_kws={"color": "r", "lw": 2, "label": "Mal Pagador"});
plt.xlabel('Ingreso total del cliente', fontsize = 12);
plt.legend();

plt.subplot(2,2,2)
sns.distplot(df_train['LOG_AMT_CREDIT'][mask0], kde_kws={"color": "r", "lw": 2, "label": "Buen Pagador"})
sns.distplot(df_train['LOG_AMT_CREDIT'][mask1], kde_kws={"color": "b", "lw": 2, "label": "Mal Pagador"});
plt.xlabel('Cantidad total del préstamo realizado', fontsize = 12);
plt.legend();

plt.subplot(2,2,3)
sns.distplot(df_train['LOG_DAYS_REGISTRATION'][mask0], kde_kws={"color": "r", "lw": 2, "label": "Buen Pagador"})
sns.distplot(df_train['LOG_DAYS_REGISTRATION'][mask1], kde_kws={"color": "b", "lw": 2, "label": "Mal Pagador"});
plt.xlabel('Cantidad de días previos a la última modificación de los registros del cliente', fontsize = 12);
plt.legend();

plt.subplot(2,2,4)
sns.distplot(df_train['LOG_DAYS_ID_PUBLISH'][mask0], kde_kws={"color": "r", "lw": 2, "label": "Buen Pagador"})
sns.distplot(df_train['LOG_DAYS_ID_PUBLISH'][mask1], kde_kws={"color": "b", "lw": 2, "label": "Mal Pagador"});
plt.xlabel('Cantidad de días previos a la modificación de su documento de identificación', fontsize = 12);
plt.legend();
```

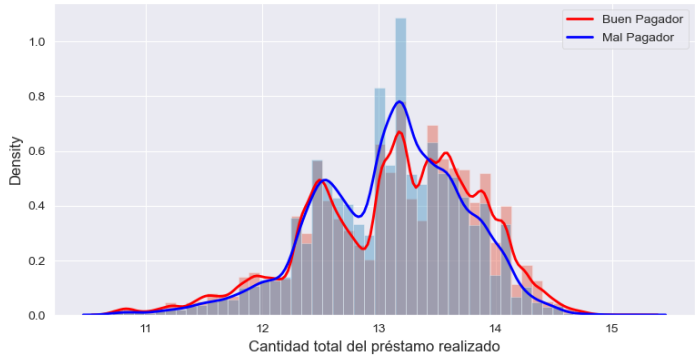

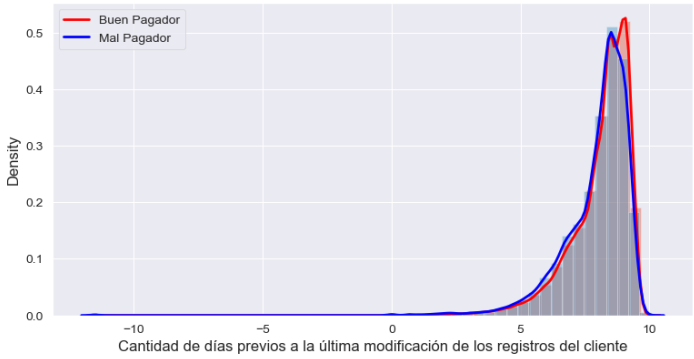

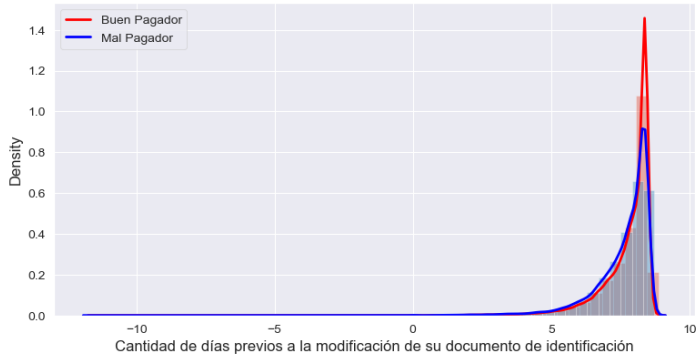

- Las variables `LOG_AMT_INCOME_TOTAL` , `LOG_DAYS_REGISTRATION` , `LOG_DAYS_ID_PUBLISH` presentan varios observaciones atipicas, de esta manera se advierte que son variables que podrían ser buenas predictoras.

- `LOG_AMT_CREDIT` , tiene una distribución similar respecto del comportamiento del cliente.

Gráfico de atributos con target:

- `AGE` : Edad del cliente cuando solicito el préstamo.
- `CNT_CHILDREN` : Cantidad de hijos.
- `CNT_FAM_MEMBERS` : Cuántos miembros familiares tiene el cliente.

In [139…

```
# Gráficos
mask0 = df_train['TARGET_']=='Buen pagador'
mask1 = df_train['TARGET_']=='Mal pagador'

plt.figure(figsize=(20,4))
plt.subplot(1,3,1)
sns.distplot(df_train['AGE'][mask0].dropna(), kde_kws={"color": "b", "lw": 2, "label": "Buen Pagador"})
sns.distplot(df_train['AGE'][mask1], kde_kws={"color": "r", "lw": 2, "label": "Mal Pagador"});
plt.xlabel('Edad del cliente', fontsize = 10);
plt.legend();

plt.subplot(1,3,2)
sns.distplot(df_train['CNT_CHILDREN'][mask0], kde_kws={"color": "r", "lw": 2, "label": "Buen Pagador"})
sns.distplot(df_train['CNT_CHILDREN'][mask1], kde_kws={"color": "b", "lw": 2, "label": "Mal Pagador"});
plt.xlabel('Cantidad de hijos', fontsize = 10);
plt.legend();

plt.subplot(1,3,3)
sns.distplot(df_train['CNT_FAM_MEMBERS'][mask0], kde_kws={"color": "r", "lw": 2, "label": "Buen Pagador"})
sns.distplot(df_train['CNT_FAM_MEMBERS'][mask1], kde_kws={"color": "b", "lw": 2, "label": "Mal Pagador"});
plt.xlabel('Miembros familiares del cliente', fontsize = 10);
plt.legend();
```

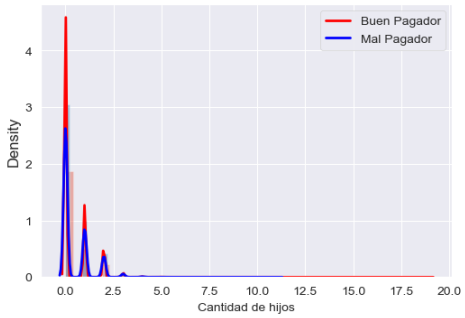

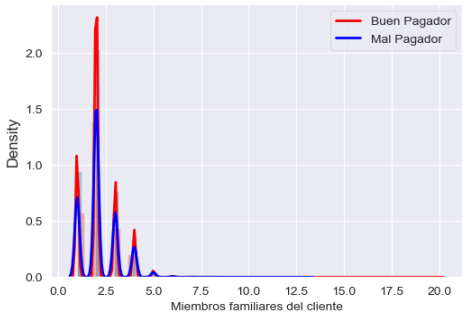

- Los clientes con mayor cantidad de hijos tienden a ser malos pagadores y su distribución es distinta, lo que adelanta que será una variable importante

para el modelo.

- En las variables `CNT_CHILDREN` y `CNT_FAM_MEMBERS` tienen una distribución similar respecto del comportamiento del cliente, y contienen outlier, pues se nota en sus colas de las distribución que están muy cargadas hacia el extremo derecho.

Gráfico de atributos con target:

- `REGION_RATING_CLIENT` : Evaluación interna (de Home Credit Group) sobre la región donde vive el cliente.
- `REG_CITY_NOT_LIVE_CITY` : Identificador booleano si es que la dirección permanente no concuerda con la dirección de contacto.
- `REG_CITY_NOT_WORK_CITY` : Identificador booleano si es que la dirección permanente no concuerda con la dirección del trabajo.
- `LIVE_CITY_NOT_WORK_CITY` : Identificador booleano si es que la dirección de contacto del cliente no concuerda con la dirección del trabajo.

In [140…

```
# Gráficos
mask0 = df_train['TARGET_']=='Buen pagador'
mask1 = df_train['TARGET_']=='Mal pagador'

plt.figure(figsize=(22, 10))
plt.subplot(2,2,1)
sns.distplot(df_train['REGION_RATING_CLIENT'][mask0].dropna(), kde_kws={"color": "b", "lw": 2, "label": "Buen Pagador"})
sns.distplot(df_train['REGION_RATING_CLIENT'][mask1], kde_kws={"color": "r", "lw": 2, "label": "Mal Pagador"});
plt.xlabel('Evaluación interna sobre la región donde vive el cliente', fontsize = 12);
plt.legend();

plt.subplot(2,2,2)
sns.distplot(df_train['REG_CITY_NOT_LIVE_CITY'][mask0], kde_kws={"color": "r", "lw": 2, "label": "Buen Pagador"})
sns.distplot(df_train['REG_CITY_NOT_LIVE_CITY'][mask1], kde_kws={"color": "b", "lw": 2, "label": "Mal Pagador"});
plt.xlabel('Dirección permanente no concuerda con la dirección de contacto.', fontsize = 12);
plt.legend();

plt.subplot(2,2,3)
sns.distplot(df_train[ 'REG_CITY_NOT_WORK_CITY'][mask0], kde_kws={"color": "r", "lw": 2, "label": "Buen Pagador"})
sns.distplot(df_train[ 'REG_CITY_NOT_WORK_CITY'][mask1], kde_kws={"color": "b", "lw": 2, "label": "Mal Pagador"});
plt.xlabel('Dirección permanente no concuerda con la dirección del trabajo.', fontsize = 12);
plt.legend();

plt.subplot(2,2,4)
sns.distplot(df_train['LIVE_CITY_NOT_WORK_CITY'][mask0], kde_kws={"color": "r", "lw": 2, "label": "Buen Pagador"})
sns.distplot(df_train['LIVE_CITY_NOT_WORK_CITY' ][mask1], kde_kws={"color": "b", "lw": 2, "label": "Mal Pagador"});
plt.xlabel('Dirección de contacto del cliente no concuerda con la dirección del trabajo', fontsize = 12);
plt.legend();
```

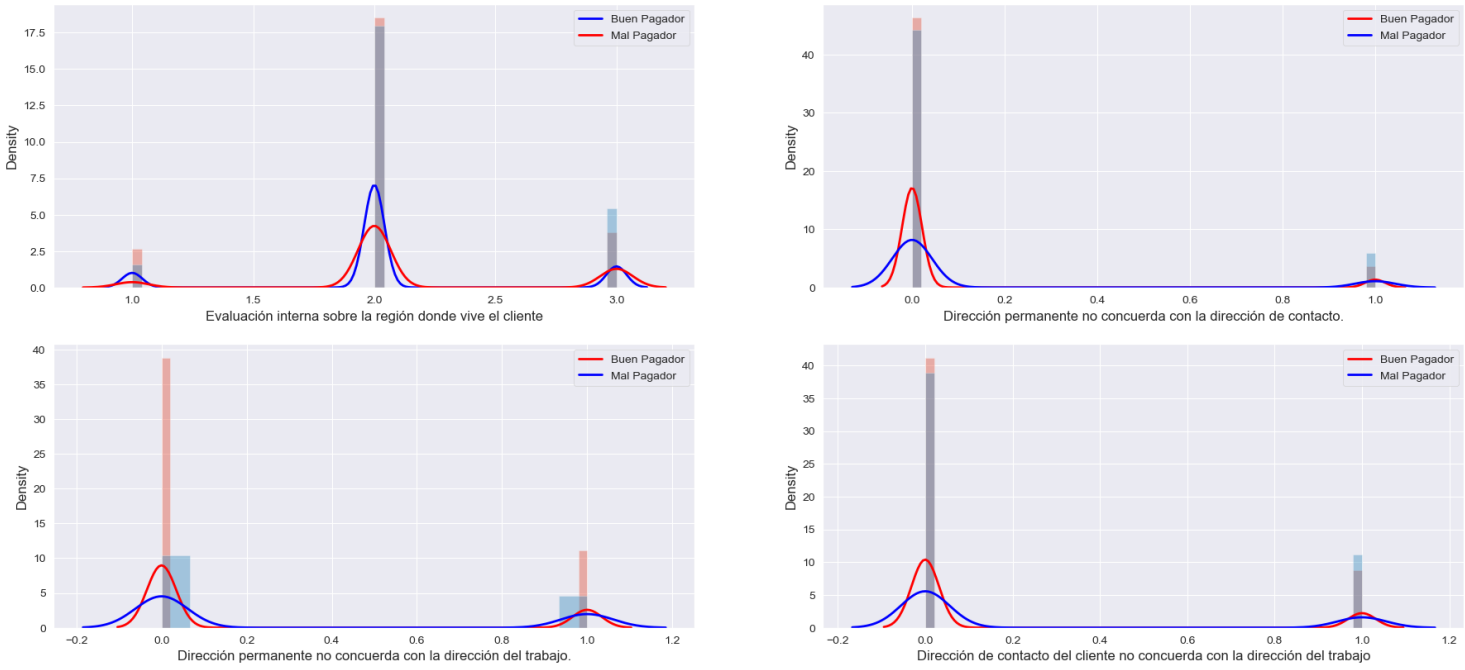

- Estas variables tienen una distribución muy similar respecto del comportamiento del cliente, por lo que no aportarían al modelo.

Gráfico de atributos con target:

- `FLAG_EMP_PHONE` : Da un teléfono de trabajo de contacto. (1: YES, 0: NO)
- `FLAG_WORK_PRONE` : Da un telefono de hogar de contacto. (1: YES, 0: NO)
- `PHONE_CHANGE` : Cambia de telefóno antes de la postulación.

In [141…

```
# Atributos
mask0 = df_train['TARGET_']=='Buen pagador'
mask1 = df_train['TARGET_']=='Mal pagador'
```

```
plt.figure(figsize=(20 ,5 ))

plt.subplot(1,2,1)
sns.distplot(df_train['PHONE_CHANGE'][mask0], kde_kws={"color": "r", "lw": 2, "label": "Buen Pagador"})
sns.distplot(df_train['PHONE_CHANGE'][mask1], kde_kws={"color": "b", "lw": 2, "label": "Mal Pagador"});
plt.xlabel('Cambia de telefono', fontsize = 10);
plt.legend();

plt.subplot(1,2,2)
sns.distplot(df_train['FLAG_WORK_PHONE'][mask0], kde_kws={"color": "r", "lw": 2, "label": "Buen Pagador"})
sns.distplot(df_train['FLAG_WORK_PHONE'][mask1], kde_kws={"color": "b", "lw": 2, "label": "Mal Pagador"});
plt.xlabel('Da un teléfono de hogar para contacto', fontsize = 10);
plt.legend();
```

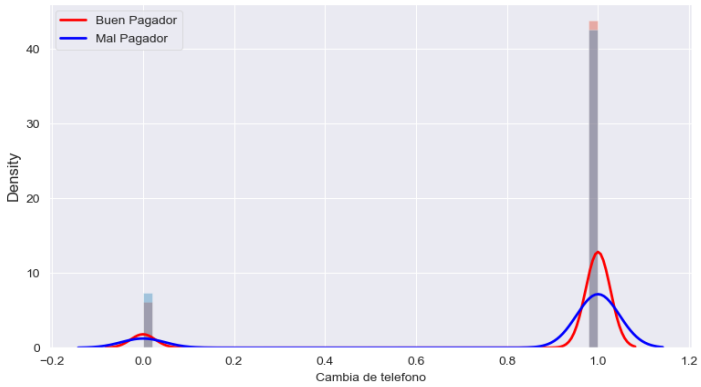

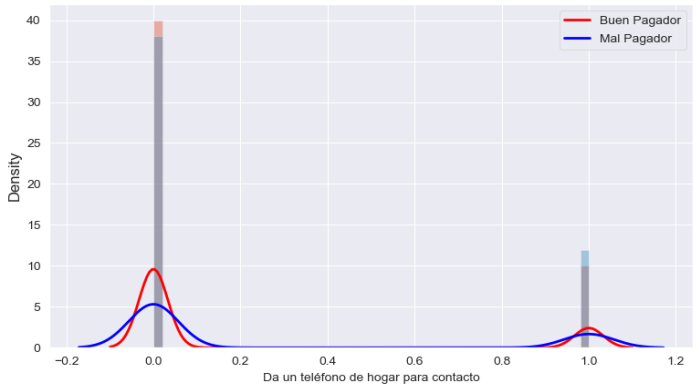

- Existe un alto porcentaje de clientes con edades entre los 25 y 40 años calificados como malos pagadores.
- Clientes que no entregan teléfono de trabajo tienden a ser buenos pagadores, pero no entregan teléfono de hogar.
- La distribucion de ambas variables tienen una distribución muy similar respecto del comportamiento del cliente, por lo que no aportarían al modelo.

Gráfico de atributos con target:

- `WITH_DAYS_WORKED` : Con días trabajados previos a la postulación.
- `EXT_SOURCE_2` : Puntaje normalizado de fuente externa 2.
- `EXT_SOURCE_3` : Puntaje normalizado de fuente externa 3.

In [142…

```
# Atributos

mask0 = df_train['TARGET_']=='Buen pagador'
mask1 = df_train['TARGET_']=='Mal pagador'

plt.figure(figsize=(20 ,5 ))

plt.subplot(1,3,1)
sns.distplot(df_train['WITH_DAYS_WORKED'][mask0], kde_kws={"color": "r", "lw": 2, "label": "Buen Pagador"})
sns.distplot(df_train['WITH_DAYS_WORKED'][mask1], kde_kws={"color": "b", "lw": 2, "label": "Mal Pagador"});
plt.xlabel('Con dias trabajados previos a la postulación', fontsize = 10);
plt.legend();

plt.subplot(1,3,2)
sns.distplot(df_train['EXT_SOURCE_2'][mask0], kde_kws={"color": "r", "lw": 2, "label": "Buen Pagador"})
sns.distplot(df_train['EXT_SOURCE_2'][mask1], kde_kws={"color": "b", "lw": 2, "label": "Mal Pagador"});
plt.xlabel('Puntaje normalizado de fuente externa 2', fontsize = 10);
plt.legend();

plt.subplot(1,3,3)
sns.distplot(df_train['EXT_SOURCE_3'][mask0], kde_kws={"color": "r", "lw": 2, "label": "Buen Pagador"})
sns.distplot(df_train['EXT_SOURCE_3'][mask1], kde_kws={"color": "b", "lw": 2, "label": "Mal Pagador"});
plt.xlabel('Puntaje normalizado de fuente externa 3', fontsize = 10);
plt.legend();
```

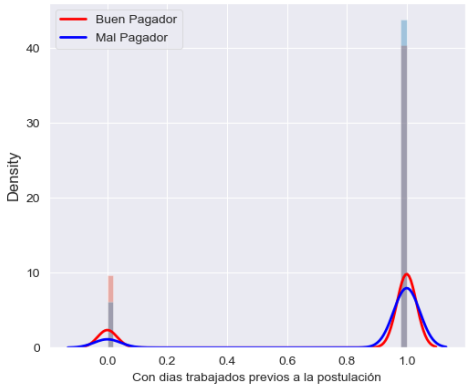

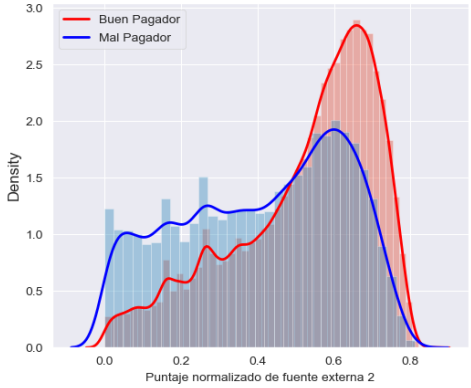

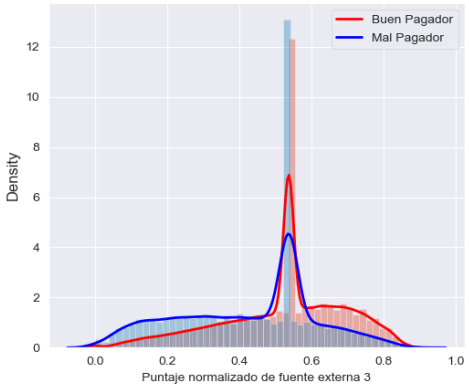

- Existe una mayor presencia de clientes con mejores puntajes de ser calificado como mejores pagadores.
- `WITH_DAYS_WORKED` tienen una distribución muy similar respecto del comportamiento del cliente, por lo que no aportaría significativamente al modelo, para el caso de las variables `EXT_SOURCE_2` y `EXT_SOURCE_3` las distribuciones son considerablemente distintas , por lo que podrian ser variables importantes para el modelo.

Gráfico de atributos con target:

- `DEF_30_CNT_SOCIAL_CIRCLE` : Cuántas veces ha registrado mora más de 30 días su entorno.
- `DEF_60_CNT_SOCIAL_CIRCLE` : Cuántas veces ha registrado mora más de 60 días su entorno.
- `AMT_REQ_CREDIT_BUREAU_MON` : Cantidad de consultas sobre el cliente al buró de crédito. Un mes antes de la postulación.
- `AMT_REQ_CREDIT_BUREAU_YEAR` : Cantidad de consultas sobre el cliente al buró de crédito. Un año antes de la postulación.

In [143…

```
# Gráficos
mask0 = df_train['TARGET_']=='Buen pagador'
mask1 = df_train['TARGET_']=='Mal pagador'

plt.figure(figsize=(22, 10))
plt.subplot(2,2,1)
sns.distplot(df_train['DEF_30_CNT_SOCIAL_CIRCLE'][mask0].dropna(), kde_kws={"color": "b", "lw": 2, "label": "Buen Pagador"})
sns.distplot(df_train['DEF_30_CNT_SOCIAL_CIRCLE'][mask1], kde_kws={"color": "r", "lw": 2, "label": "Mal Pagador"});
plt.xlabel('Cuántas veces ha registrado mora más de 30 días su entorno', fontsize = 12);
plt.legend();

plt.subplot(2,2,2)
sns.distplot(df_train['DEF_60_CNT_SOCIAL_CIRCLE'][mask0].dropna(), kde_kws={"color": "b", "lw": 2, "label": "Buen Pagador"})
sns.distplot(df_train['DEF_60_CNT_SOCIAL_CIRCLE'][mask1], kde_kws={"color": "r", "lw": 2, "label": "Mal Pagador"});
plt.xlabel('Cuántas veces ha registrado mora más de 60 días su entorno', fontsize = 12);
plt.legend();

plt.subplot(2,2,3)
sns.distplot(df_train['AMT_REQ_CREDIT_BUREAU_MON'][mask0], kde_kws={"color": "r", "lw": 2, "label": "Buen Pagador"})
sns.distplot(df_train['AMT_REQ_CREDIT_BUREAU_MON'][mask1], kde_kws={"color": "b", "lw": 2, "label": "Mal Pagador"});
plt.xlabel('Cantidad de consultas al buró de crédito un mes antes', fontsize = 12);
plt.legend();

plt.subplot(2,2,4)
sns.distplot(df_train['AMT_REQ_CREDIT_BUREAU_YEAR'][mask0], kde_kws={"color": "r", "lw": 2, "label": "Buen Pagador"})
sns.distplot(df_train['AMT_REQ_CREDIT_BUREAU_YEAR'][mask1], kde_kws={"color": "b", "lw": 2, "label": "Mal Pagador"});
plt.xlabel('Cantidad de consultas al buró de crédito un año antes', fontsize = 12);
plt.legend();
```

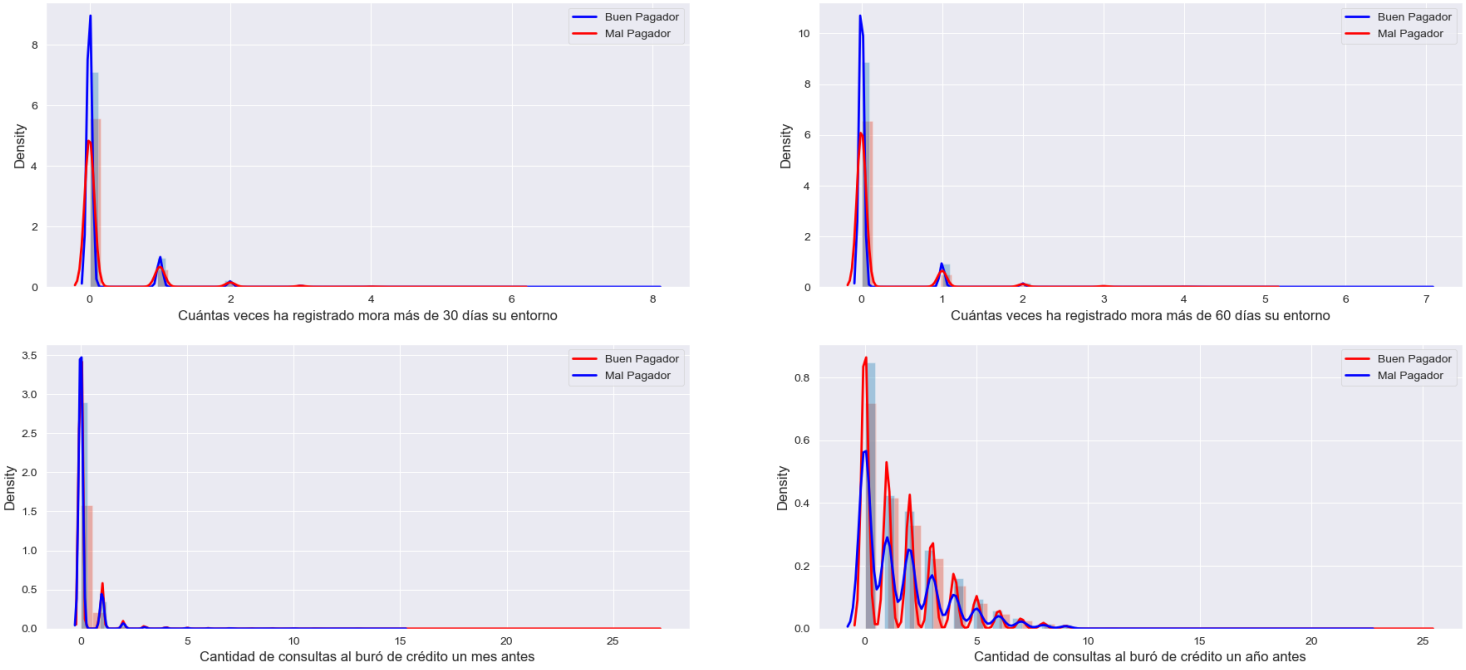

- Estos atributos `DEF_30_CNT_SOCIAL_CIRCLE` , `DEF_60_CNT_SOCIAL_CIRCLE` , `AMT_REQ_CREDIT_BUREAU_MON` y `AMT_REQ_CREDIT_BUREAU_YEAR` presentan varios observaciones atipicas, lo que sugiere que podrían ser variables importantes para el modelo.

In [144…

```
# Seleccion de variables categoricas
df_train_object = df_train.select_dtypes(include=['object'])
df_train_object.columns
```

Out[144…

```
Index(['CODE_GENDER', 'FLAG_OWN_CAR', 'FLAG_OWN_REALTY', 'NAME_INCOME_TYPE',
       'NAME_EDUCATION_TYPE', 'NAME_FAMILY_STATUS', 'NAME_HOUSING_TYPE',
       'OCCUPATION_TYPE', 'REGION_RATING_CLIENT_W_CITY', 'ORGANIZATION_TYPE',
       'TARGET_'],
      dtype='object')
```

Gráfico Boxplot entre Target y edad segmentado por género

In [145…

```
sns.set_style("darkgrid")
plt.figure(figsize=(8, 4))
sns.boxplot(x="TARGET_", y="AGE", hue="CODE_GENDER", palette=["g", "m"], data=df_train);
#sns.despine(offset=10, trim=True)
```

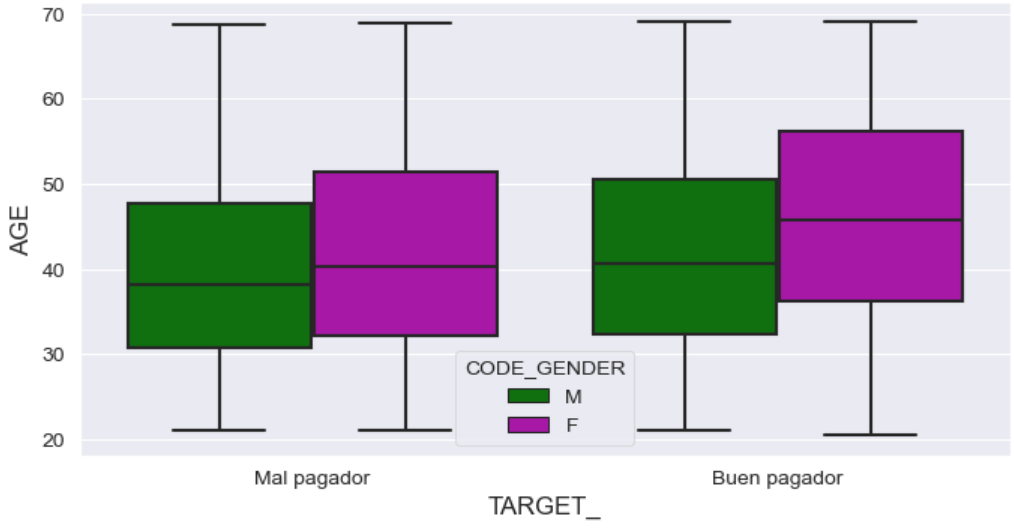

- No se observa una diferencia de edad marcada entre los hombres respecto de su comportamiento de pago, son la mujeres las que tienden a tener un mejor comportamiento de pago entre los 35 y 55 años de edad, a diferencia de los hombres que mejoran su comportamiento entre los 30 y 50 años.

Gráfico de atributos con target:

- `CODE_GENDER` : Sexo del cliente.
- `FLAG_OWN_CAR` : Indicador binario sobre la tenencia de automóvil por parte del cliente.
- `FLAG_OWN_REALTY` : Indicador binario sobre la propiedad de una casa o departamento por parte del cliente.

In [146…

```
# Seleccion de columnas para graficar
sns.set_style("white")
data_graf_obj1 = df_train_object.loc[:, [ 'CODE_GENDER', 'FLAG_OWN_CAR', 'FLAG_OWN_REALTY' ]]
hlp.barplot_multiple_porc(df_train, data_graf_obj1, 0)
```

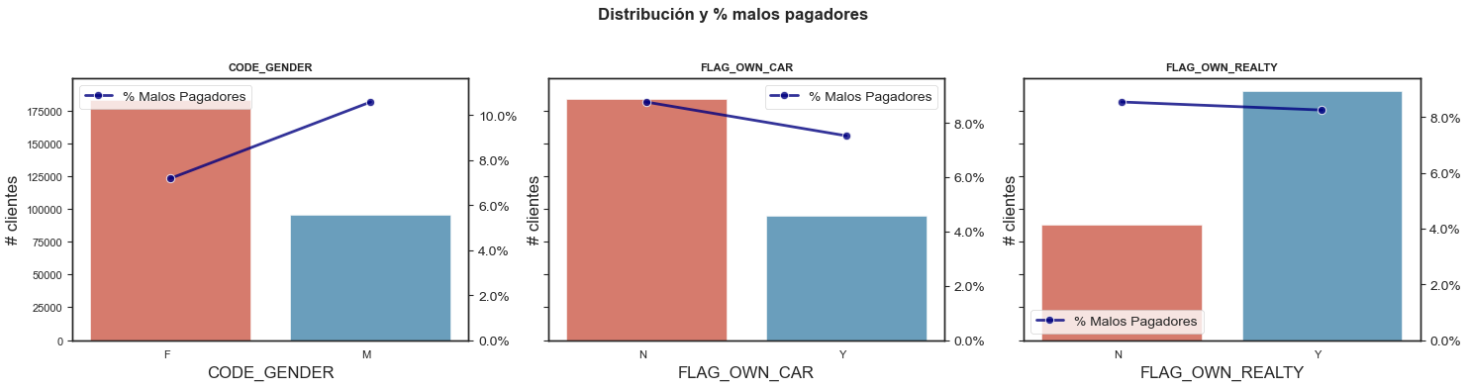

- Se observa un mayor porcentaje de malos pagadores en los hombres con respecto a las mujeres.
- Respecto de la tenencia de automovil `FLAG_OWN_CAR` por parte del cliente, este presenta un mal comportamiento de pago, si no tiene auto.
- Respecto si el cliente posee casa o departamento `FLAG_OWN_REALTY`, no hay mucha diferencia entre la tasa de malos, por lo que esta variable se eliminará.

Gráfico de atributos con target:

- `NAME_EDUCATION_TYPE` : Máximo nivel educacional por parte del cliente.
- `NAME_FAMILY_STATUS` : Situación familiar del cliente.
- `NAME_INCOME_TYPE` : Tipo de ingreso.
- `REGION_RATING_CLIENT_W_CITY` : Evaluación interna (de Home Crédito Group) sobre la región donde vive el cliente considerando ciudad.

In [147…

```
# Seleccion de columnas para graficar
data_graf_obj2 = df_train_object.loc[:, [ 'NAME_EDUCATION_TYPE', 'NAME_FAMILY_STATUS',  'REGION_RATING_CLIENT_W_CITY' ]]
hlp.barplot_multiple_porc(df_train, data_graf_obj2, 0)
```

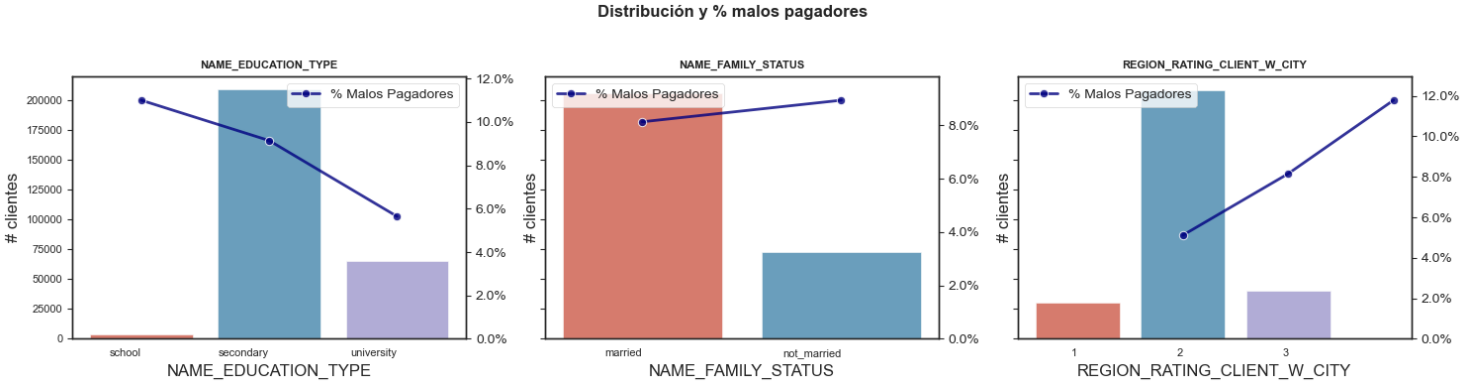

- Los clientes que tienen mejor nivel de educación son mejores pagadores.
- Ser casado indica mejor comportamiento de pago, aunque no se observa una gran variación respecto de su situacion familiar.
- Se elimina `REGION_RATING_CLIENTE_W_CITY` por tener un comportamiento equivalente a `REGION_RATING_CLIENT`.

In [148…

```
# Atributo NAME_INCOME_TYPE con TARGET
hlp.grafico_bivariado_cat(df_train, 'NAME_INCOME_TYPE','TARGET', (15,4), 0);
```

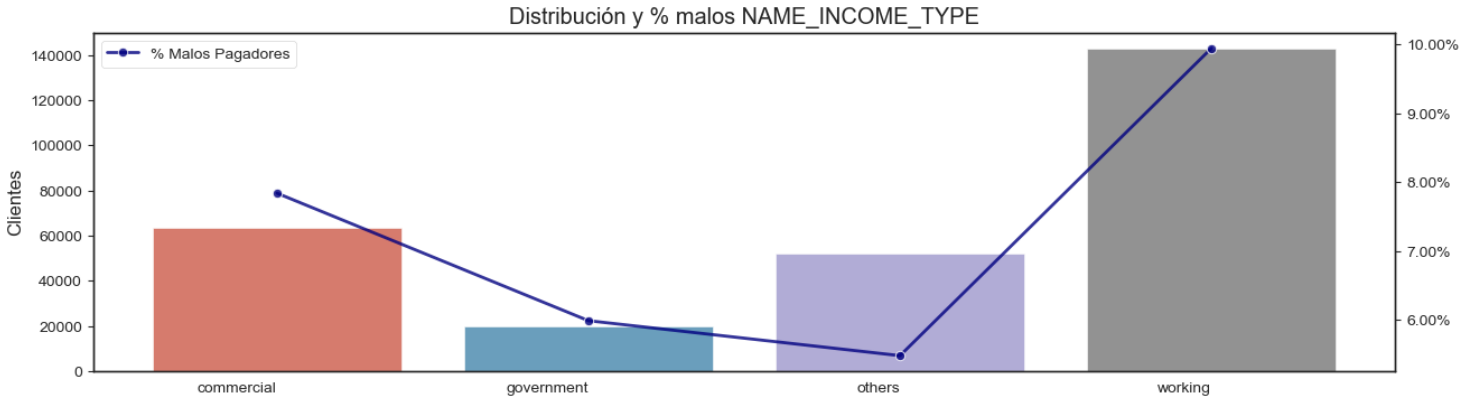

- Existe un porcentaje de clientes que trabajan que tienen un peor comportamiento de pago a diferencia de otros en los que se incluyen los desempleados y estudiantes.

Gráfico de atributos con target:

- `NAME_HOUSING_TYPE` : Cuál es la situación habitacional del cliente.

In [149…

```
# Atributo NAME_HOUSING_TYPE con TARGET
hlp.grafico_bivariado_cat(df_train, 'NAME_HOUSING_TYPE','TARGET', (15,4), 0);
```

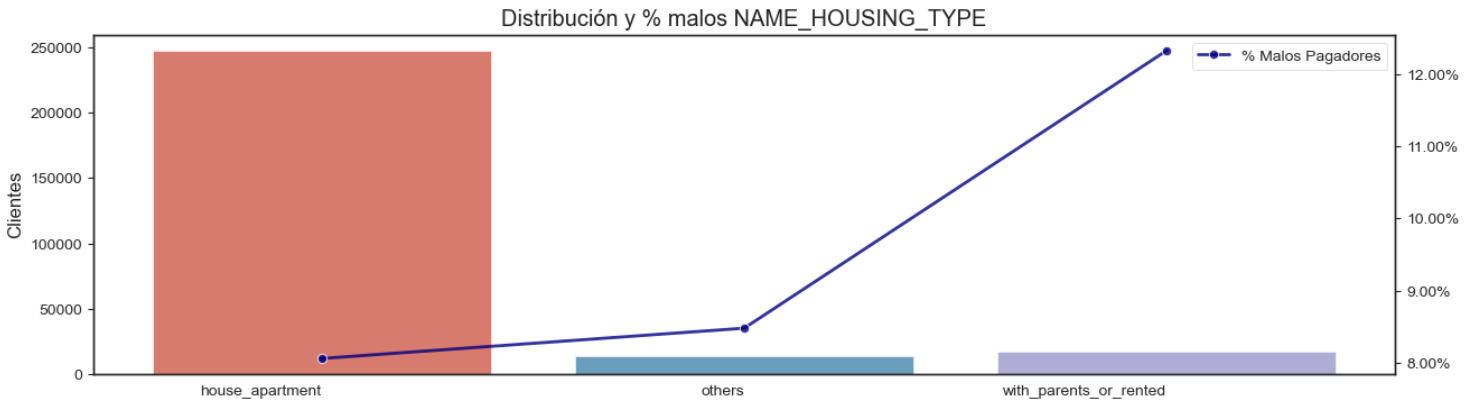

- Los clientes que no arriendan tienen mejor comportamiento de pago.

Gráfico de atributo con target :

- `ORGANIZATION_TYPE` : Tipo de organización donde trabaja el cliente.

In [150…

```
# Atributo ORGANIZATION_TYPE con TARGET
hlp.grafico_bivariado_cat(df_train, 'ORGANIZATION_TYPE','TARGET',(20,5), 10 );
```

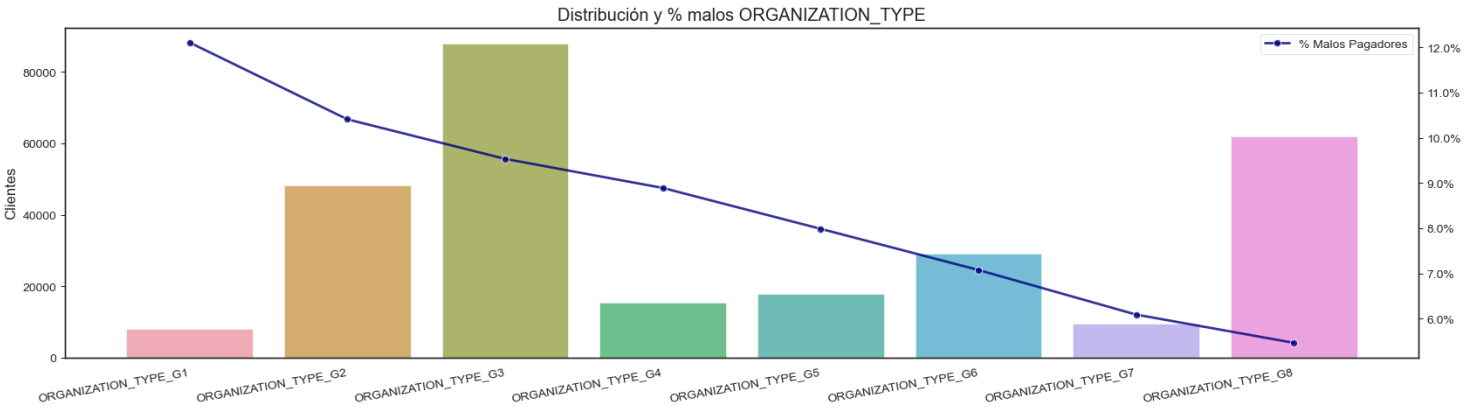

- Los clientes que trabajan en empresas del rubro Construction, Realtor, Restaurant tiene la mayor tasa de malos (Organización tipo G1) a diferencia de los que trabajan en Bank, Culture, Military, Police, Security, Ministries, University (Organización tipo G8), aunque existe un porcentaje de malos pagadores que trabaja en Business, Entity, Trade (Organización tipo G3)

Gráfico de atributo con target :

- `OCCUPATION_TYPE` : Cuál es la profesión del cliente.

In [151…
```
# Grafico OCCUPATION_TYPE con TARGET
hlp.grafico_bivariado_cat(df_train, 'OCCUPATION_TYPE','TARGET',(20,5), 10);
```

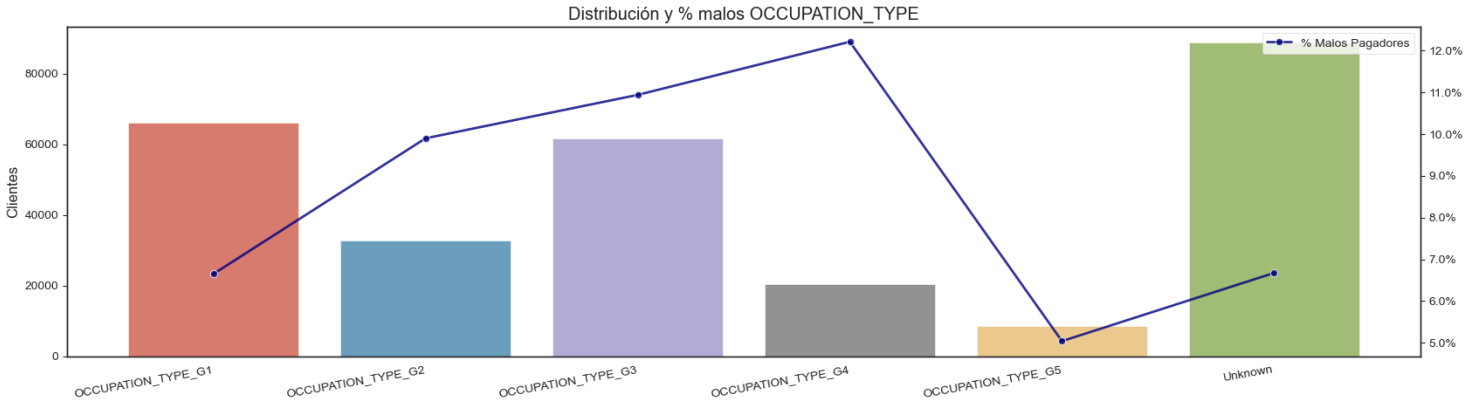

- Los clientes que realizan profesiones como Drivers, Low-skill Laborers, Waiters/barmen staff tienden a ser malos pagadores y los contadores son buenos pagadores.

2.12.2 Eliminación de atributos de análisis bivariado

In [152…
```
# Seleccion de columnas a Eliminar del analisis bivariado
#=============================================================================================
columns_biv_drop = ['FLAG_OWN_REALTY', 'REGION_RATING_CLIENT_W_CITY', 'TARGET_']
```

In [153…
```
# Eliminacion de Atributos del analisis bivariado
#=============================================================================================
df_train = df_train.drop(columns = columns_biv_drop)
```

In [154…
```
# Dimensión de la data posterior a la eliminación de atributos
df_train.shape
```

Out[154… (278232, 30)

In [155…
```
df_train.head()
```

Out[155…

	TARGET	CODE_GENDER	FLAG_OWN_CAR	CNT_CHILDREN	NAME_INCOME_TYPE	NAME_EDUCATION_TYPE	NAME_FAMILY_STATUS	NAME_HOUSING_TYPE	FLA
0	1	M	N	0	working	secondary	not_married	house_apartment	
1	0	F	N	0	government	university	married	house_apartment	
3	0	F	N	0	working	secondary	married	house_apartment	
4	0	M	N	0	working	secondary	not_married	house_apartment	
5	0	M	N	0	government	secondary	married	house_apartment	

3. Feature engineering

In [156…
```
# Cantidad de niveles por Variables categroicas
hlp.variables_categoricas(df_train)
```

```
F    182800
M     95432
Name: CODE_GENDER, dtype: int64


N    183775
Y     94457
Name: FLAG_OWN_CAR, dtype: int64


working       142719
commercial     63652
others         52025
government     19836
Name: NAME_INCOME_TYPE, dtype: int64
```

```
secondary     209157
university     65467
school          3608
Name: NAME_EDUCATION_TYPE, dtype: int64


married        205692
not_married     72540
Name: NAME_FAMILY_STATUS, dtype: int64


house_apartment           247389
with_parents_or_rented     17271
others                     13572
Name: NAME_HOUSING_TYPE, dtype: int64


Unknown               88800
OCCUPATION_TYPE_G1    65962
OCCUPATION_TYPE_G3    61746
OCCUPATION_TYPE_G2    32769
OCCUPATION_TYPE_G4    20348
OCCUPATION_TYPE_G5     8607
Name: OCCUPATION_TYPE, dtype: int64


ORGANIZATION_TYPE_G3    88023
ORGANIZATION_TYPE_G8    61851
ORGANIZATION_TYPE_G2    48189
ORGANIZATION_TYPE_G6    29131
ORGANIZATION_TYPE_G5    17988
ORGANIZATION_TYPE_G4    15485
ORGANIZATION_TYPE_G7     9538
ORGANIZATION_TYPE_G1     8027
Name: ORGANIZATION_TYPE, dtype: int64
```

3.1 Preprocesado de los datos

In [157…
```
df_train2=df_train.copy()
```

In [158…
```
df_train = hlp.preprocess_data(df_train)
```

In [159…
```
df_train.to_csv('data_train_bin.csv',index=False)
```

3.2 Lectura de archivo binarizado

In [160…
```
#df_train = pd.read_csv("data_train_bin.csv")
```

In [161…
```
# Dimension despues del preprocesado de variables categoricas binarizadas
print("n filas:", df_train.shape[0],"\nn columnas:",df_train.shape[1])
```

```
n filas: 278232
n columnas: 44
```

In [162…
```
# Visualiacion primeros registros
df_train.head()
```

Out[162…

	TARGET	CNT_CHILDREN	FLAG_WORK_PHONE	FLAG_PHONE	CNT_FAM_MEMBERS	REGION_RATING_CLIENT	REG_CITY_NOT_LIVE_CITY	REG_CITY_NOT_WORK_CI
0	1	0	0	1	1.0	2	0	
1	0	0	0	1	2.0	1	0	
3	0	0	0	0	2.0	2	0	
4	0	0	0	0	1.0	2	0	
5	0	0	1	1	2.0	2	0	

4. Pre Modelamiento

Previo a la realización de los modelos se realiza un estandarización de los datos, se divide la base en entrenamiento y validación (70% y 30%), y luego se considera realizar un balanceo de los datos de entrenamiento, debido a que la clase objetivo se encuentra desbalanceada, donde un 8.3% de los registros tienen marca de `TARGET` = 1.

Para balancear la clase se consideran distinas metodologias, optando finalmente por realizar un submuestreo, es decir, seleccionar aleatoriamente registros de la clase 0, para que la base se encuentre mejor distribuida

In [163…

```
# División Train Test Split

X_train, X_test, y_train, y_test = train_test_split(df_train.drop(['TARGET'], axis=1), df_train['TARGET'],  test_size=0.3, random_state=

# Estandarizacion
scaler = StandardScaler()
X_train_std = scaler.fit_transform(X_train)
X_test_std = scaler.transform(X_test)

# UnderSumpling
undersampler = RandomUnderSampler(random_state=42,sampling_strategy='not minority')
X_train_ss, y_train_ss = undersampler.fit_resample(X_train_std,y_train)

# para resumen
metodos = ['Original','Balanceada (Subsampling)']
lista_X_train = [X_train_std,X_train_ss]
lista_y_train = [y_train,y_train_ss]

print("Resumen Bases consideradas:")

hlp.tabla_comp_train(metodos,lista_X_train,lista_y_train)
```

```
Resumen Bases consideradas:
```

Out[163…

Base	n_registros	n_target_1	% target 1
Original	194762	16289	8.36
Balanceada (Subsampling)	32578	16289	50.00

- Una vez generadas las bases de entrenamiento se obtiene una base con 194.762 registros, correspondiente al 70% de la data original, la cual mantiene la distribución de target de la data original, y una base balanceada, con 32.578 registros, con la distribución de target balanceada (50% clase 0 y 50% clase 1).

5. Modelamiento

- Dado el vector objetivo, se considerán distintos tipos de modelos de clasificación. Como primera alternativa se realiza un modelo de `Regresión logística`, por ser un modelo que se utiliza en la industria crediticia al tener una mayor facilidad de interpretación. Además, se realizarán pruebas con otras metodologías para evaluar si existen otros modelos con mejor capacidad de predicción. Dentro de los modelos a considerar se encuentran: `Modelos aditivos generalizados GAM`, `Random Forest` y `Gradient Boosting`.
- Dentro de los indicadores a utilizar para comparar los modelos se encuentran: precision, recall, f1-score, accuracy (generados a través de un reporte de clasificación), AUC (curva ROC), y adicionalmente los indicadores KS y GINI los cuales son indicadores que se utilizan en la industria para medir capacidad predictiva de modelos de créditos.

5.1 Modelo Regresión Logística

Como primera aproximación se realiza un modelo de regresión logística. Se aplica este modelo con y sin hiperparámetros a las base original (estandarizada) y a la respectiva base balanceada. Se realiza esto para validar el uso de la muestra balanceada.

5.1.1 Modelo base estandarizada:

In [164…

```
# Modelo Regresion Logistica estandarizada
model_reg_log = LogisticRegression(class_weight='balanced',penalty='l1',solver='saga', random_state=1).fit(X_train_std, y_train)

# Predicciones
y_pred_reg_log = model_reg_log.predict(X_test_std)
y_pred_reg_log_prob = model_reg_log.predict_proba(X_test_std)[:,1]

print(classification_report(y_test, y_pred_reg_log))

print("AUC : {} %".format(round(roc_auc_score(y_test, y_pred_reg_log_prob),4)*100))
print("KS  :", round(ks_2samp(y_pred_reg_log_prob[y_test==1], y_pred_reg_log_prob[y_test!=1]).statistic,5)*100," %")
print("GINI:", round((roc_auc_score(y_test, y_pred_reg_log_prob)-0.5)*2,5)*100,"%")
```

```
              precision    recall  f1-score   support
```

```
           0       0.96      0.68      0.80     76538
           1       0.16      0.66      0.26      6932

    accuracy                           0.68     83470
   macro avg       0.56      0.67      0.53     83470
weighted avg       0.89      0.68      0.75     83470

AUC : 73.04 %
KS  : 34.648  %
GINI: 46.087 %
```

5.1.2 Modelo base estandarizada balanceada:

In [165…

```
# Modelo Regresion Logistica sin hiperparametros
model_reg_log_ss = LogisticRegression(penalty='l1',solver='saga', random_state=1).fit(X_train_ss, y_train_ss)

print('Indicadores datos entrenamiento: \n')
hlp.resumen_modelo(model_reg_log_ss,X_train_ss, y_train_ss)
```

```
Indicadores datos entrenamiento:

Reporte Clasificación:
              precision    recall  f1-score   support

           0       0.67      0.69      0.68     16289
           1       0.68      0.66      0.67     16289

    accuracy                           0.67     32578
   macro avg       0.67      0.67      0.67     32578
weighted avg       0.67      0.67      0.67     32578

Indicadores:
auc :  73.647 %
ks  :  35.153 %
gini:  47.293 %
```

In [166…

```
print('Indicadores datos validación: \n')
hlp.resumen_modelo(model_reg_log_ss,X_test_std, y_test)
```

```
Indicadores datos validación:

Reporte Clasificación:
              precision    recall  f1-score   support

           0       0.96      0.68      0.80     76538
           1       0.16      0.66      0.26      6932

    accuracy                           0.68     83470
   macro avg       0.56      0.67      0.53     83470
weighted avg       0.89      0.68      0.75     83470

Indicadores:
auc :  73.019 %
ks  :  34.677 %
gini:  46.037 %
```

- De los resultados anteriores se puede apreciar que a pesar de que los indicadores globales no aumentan de forma considerable (como el AUC), el utilizar una base balanceada mejora la capacidad de predicción de la clase 1, lo cual se refleja en el recall y f1-score.
- Con esto, se puede se puede apreciar una primera aproximación de las características que impactan en el comportamiento de pago:

In [167…

```
df_importancias = hlp.feature_importance_reg_log(model_reg_log_ss,df_train)
df_importancias = df_importancias.reset_index()
df_importancias_15 = df_importancias.loc[:14,]
df_importancias_15 = df_importancias_15.sort_values(by='Importancia_abs')
plt.barh(df_importancias_15['Variable'],df_importancias_15['Importancia'])
plt.xticks(rotation = 90);
plt.title("Variables más relevantes");
```

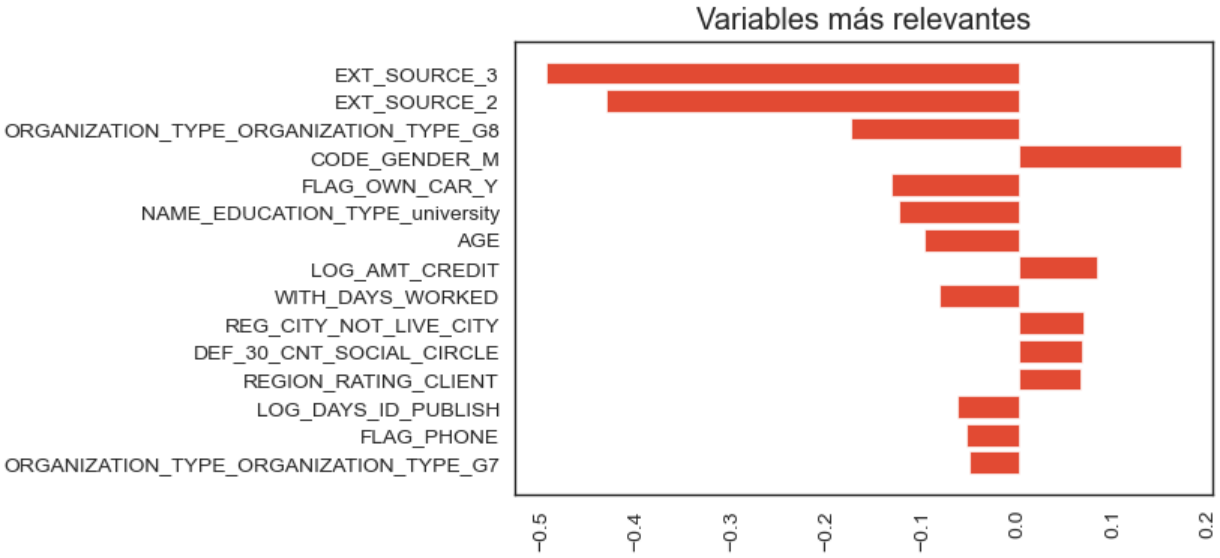

- En el gráfico anterior, donde se muestran los 15 atributos más relevantes, se puede ver que las variables con más relevancia son las `EXT_SOURCE_3` y `EXT_SOURCE_2` (puntajes de fuente externa), la cual influye negativamente en la predicción de un mal pagador (un mejor puntaje indicaria que es más probable que sea bueno). Asi también, se observa que variables como si posee auto (`FLAG_OWN_CAR_Y`), la edad (`AGE`), o si tiene educación universitaria impactan postivamente en que sea un buen pagador, mientras que el género (si es masculino), si la dirección permanente no concuerda con concuerda con la dirección de contacto (`REG_CITY_NOT_LIVE_CITY`), si ha tenido mora mayor a 30 (`DEF_30_CNT_SOCIAL_CIRCLE`), influyen en predecir al cliente como un probable mal pagador.

- Con estos resultados se puede obtiene una primera aproximación de los perfiles de los clientes. Con esto se prueban distintos modelos, los cuales se muestran a continuación. En cada modelo se presenta los resultados obtenidos mostrando los indicadores mencionados. A partir de estos resultados se selecciona el mejor modelo, para el cual posteriormente se realiza una busqueda de hiperparámetros.

5.2 Modelo Aditivo Generalizado

In [168…

```
%%time
# Desde aca solo se aplica con bases balanceadas
# Modelo GAM

model_gam = LogisticGAM().fit(X_train_ss, y_train_ss)
# Resultado
hlp.resumen_modelo(model_gam,X_test_std,y_test,gam=True)

pickle.dump(model_gam, open('respaldo_resultados/modelo_02_gam', 'wb'))
```

```
Reporte Clasificación:
              precision    recall  f1-score   support

           0       0.96      0.69      0.80     76538
           1       0.16      0.67      0.26      6932

    accuracy                           0.68     83470
   macro avg       0.56      0.68      0.53     83470
weighted avg       0.89      0.68      0.75     83470

Indicadores:
auc :  73.555 %
ks  :  35.594 %
gini:  47.111 %
Wall time: 1min 15s
```

5.3 Modelo Random Forest

In [169…

```
%%time
# Desde aca solo se aplica con bases balanceadas
# Random Forest
model_random_forest = RandomForestClassifier(class_weight='balanced',n_jobs=-1, random_state=1).fit(X_train_ss, y_train_ss)
# Resultado
hlp.resumen_modelo(model_random_forest,X_test_std,y_test)
```

```
Reporte Clasificación:
              precision    recall  f1-score   support

           0       0.96      0.68      0.79     76538
           1       0.16      0.65      0.25      6932
```

```
    accuracy                           0.68     83470
   macro avg       0.56      0.67      0.52     83470
weighted avg       0.89      0.68      0.75     83470

Indicadores:
auc :  72.133 %
ks  :  33.364 %
gini:  44.267 %
Wall time: 6.88 s
```

5.4 GradientBoosting

In [170…

```
%%time
# Desde aca solo se aplica con bases balanceadas
# GradientBoosting
#model_gradient_boosting = GradientBoostingClassifier().fit(X_train_ss, y_train_ss)
model_gradient_boosting = GradientBoostingClassifier(criterion='mse',learning_rate=0.01,n_estimators=2000,subsample=0.5,random_state=1).
```

```
Wall time: 2min 39s
```

In [171…

```
print("Indicadores data validación: \n")
hlp.resumen_modelo(model_gradient_boosting,X_test_std,y_test)
```

```
Indicadores data validación:

Reporte Clasificación:
              precision    recall  f1-score   support

           0       0.96      0.69      0.80     76538
           1       0.16      0.67      0.26      6932

    accuracy                           0.68     83470
   macro avg       0.56      0.68      0.53     83470
weighted avg       0.89      0.68      0.75     83470

Indicadores:
auc :  73.826 %
ks  :  35.923 %
gini:  47.652 %
```

```
# Serializacion
write_predict_gb =  pickle.dump(model_gradient_boosting, open('gradient_boosting_predict.sav','wb'))
```

5.5 AdaBoost

In [172…

```
%%time
# Desde aca solo se aplica con bases balanceadas
# AdaBoostClassifier
model_AdaBoostClassifier = AdaBoostClassifier(random_state=1).fit(X_train_ss, y_train_ss)
# Resultado
hlp.resumen_modelo(model_AdaBoostClassifier,X_test_std,y_test)
```

```
Reporte Clasificación:
              precision    recall  f1-score   support

           0       0.96      0.68      0.80     76538
           1       0.16      0.66      0.25      6932

    accuracy                           0.68     83470
   macro avg       0.56      0.67      0.52     83470
weighted avg       0.89      0.68      0.75     83470

Indicadores:
auc :  72.767 %
ks  :  33.869 %
gini:  45.533 %
Wall time: 6.77 s
```

5.6 LinearDiscriminantAnalysis

In [173…

```
%%time
# Desde aca solo se aplica con bases balanceadas
# LinearDiscriminantAnalysis
#from sklearn.discriminant_analysis import LinearDiscriminantAnalysis
model_LinearDiscriminantAnalysis = LinearDiscriminantAnalysis().fit(X_train_ss, y_train_ss)
# Resultado
hlp.resumen_modelo(model_LinearDiscriminantAnalysis,X_test_std,y_test)
```

```
Reporte Clasificación:
              precision    recall  f1-score   support
```

```
           0       0.96      0.69      0.80     76538
           1       0.16      0.66      0.26      6932

    accuracy                           0.68     83470
   macro avg       0.56      0.67      0.53     83470
weighted avg       0.89      0.68      0.75     83470

Indicadores:
auc :  73.012 %
ks  :  34.672 %
gini:  46.025 %
Wall time: 530 ms
```

5.7 Selección de Modelo

Para selección se comparan indicadores de los modelos tanto en data de entrenamiento como en validación:

In [174…

```
# Resumen indicadores de todos los modelos data de entrenamiento
#============================================================
# listar nombres de los modelos y modelos respectivos
# modelo GAM se tiene que llamar así para que se ejecute correctamente la función
print("Indicadores Modelos data entrenamiento:")

modelos_nombres = ['Gradient Boosting','GAM','Regresion Logística','Random Forest','AdaBoostClassifier','LinearDiscriminantAnalysis']
modelos = [model_gradient_boosting,model_gam,model_reg_log_ss,model_random_forest,model_AdaBoostClassifier,model_LinearDiscriminantAnaly
df_kpi = hlp.resumen_compara_modelos_df(modelos_nombres,modelos,X_train_ss, y_train_ss).sort_values(by='KS',ascending=False)
df_kpi
```

```
Indicadores Modelos data entrenamiento:
```

Out[174…

Modelo	accuracy	precision	recall	f1-score	AUC	KS	GINI
Random Forest	1.00	1.00	1.00	1.00	1.0000	1.0000	1.0000
Gradient Boosting	0.70	0.70	0.69	0.69	0.7679	0.3930	0.5357
GAM	0.68	0.69	0.67	0.68	0.7444	0.3646	0.4888
AdaBoostClassifier	0.68	0.68	0.66	0.67	0.7403	0.3550	0.4805
LinearDiscriminantAnalysis	0.67	0.68	0.66	0.67	0.7364	0.3523	0.4729
Regresion Logística	0.67	0.68	0.66	0.67	0.7365	0.3515	0.4729

In [175…

```
# Resumen indicadores de todos los modelos data de validación
#============================================================
print("Indicadores Modelos data validación:")
# listar nombres de los modelos y modelos respectivos
# modelo GAM se tiene que llamar así para que se ejecute correctamente la función
modelos_nombres = ['Gradient Boosting','GAM','Regresion Logística','Random Forest','AdaBoostClassifier','LinearDiscriminantAnalysis']
modelos = [model_gradient_boosting,model_gam,model_reg_log_ss,model_random_forest,model_AdaBoostClassifier,model_LinearDiscriminantAnaly
df_kpi = hlp.resumen_compara_modelos_df(modelos_nombres,modelos,X_test_std,y_test).sort_values(by='KS',ascending=False)
df_kpi
```

```
Indicadores Modelos data validación:
```

Out[175…

Modelo	accuracy	precision	recall	f1-score	AUC	KS	GINI
Gradient Boosting	0.68	0.16	0.67	0.26	0.7383	0.3592	0.4765
GAM	0.68	0.16	0.67	0.26	0.7356	0.3559	0.4711
Regresion Logística	0.68	0.16	0.66	0.26	0.7302	0.3468	0.4604
LinearDiscriminantAnalysis	0.68	0.16	0.66	0.26	0.7301	0.3467	0.4602
AdaBoostClassifier	0.68	0.16	0.66	0.25	0.7277	0.3387	0.4553
Random Forest	0.68	0.16	0.65	0.25	0.7213	0.3336	0.4427

- Se puede apreciar que con `Random Forest` se obtiene un modelo sobreajustado, perdiendo su capacidad predictiva al aplicarse en la data de validación. Modelos como `AdaBoostClassifier` y `LinearDiscriminantAnalysis` si bien tienen mejores indicadores que la `Regresión Logística` en la data de entrenamiento, al aplicarse a la data de validación tienen indicadores más leves que este último.

- Al comparar las métricas de los diferentes modelos estudiados, se obtiene que el modelo que posee el mayor poder predictivo es el algoritmo de `Gradient Boosting`. Sin embargo, los otros modelos estudiados presentan indicadores similares, por lo tanto, se sugiere trabajar con alguno de los

modelos que sean superiores en métricas de desempeño de poder predictivo respecto a la `Regresión Logistica` o esta misma en su defecto.

- Dado lo anterior, se propone evaluar e implementar el modelo **Gradient Boosting**, el cual obtuvo las mejores métricas de clasificación KS y AUC, indicando así un muy buen poder de clasificación para la evaluación de créditos.

5.7.1 Matriz de confusión de modelo seleccionado

In [176…
```
ConfusionMatrixDisplay.from_estimator(model_gradient_boosting, X_test_std, y_test)
plt.show()
```

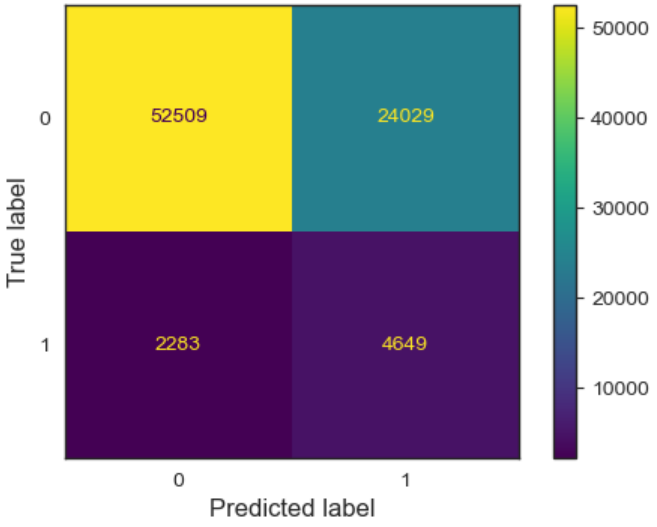

- A partir de los datos de testeo, se puede observar que el mejor modelo captura una gran cantidad de clientes que son malos pagadores (4.649 créditos) lo cual se asocia a un recall de un 0.67.

- Por otra parte, el modelo carece de buena precisión ya que un gran volumen de créditos buenos, son predichos como malos pagadores (24.029), asociado a un indicador de precision de 0.16.

- No obstante, dada la naturaleza del problema que estamos enfrentando se le dará una mayor importancia al indicador de recall, como así también la metrica KS, la cual nos muestra un muy buen poder predictivo con un 35,98%.

In [177…
```
#Serialización mejor modelo
pickle.dump(model_gradient_boosting, open('modelo_gradient_boosting.pkl','wb'))
```

In [178…
```
#Grafico features GRADIENT BOOSTING
df = hlp.feature_importance(model_gradient_boosting,df_train)
df_importancias = hlp.feature_importance(model_gradient_boosting,df_train)
df_importancias = df_importancias.reset_index()
df_importancias_15 = df_importancias.loc[:15,]
plt.barh(df_importancias_15['Variable'],df_importancias_15['Importancia'])
plt.xticks(rotation = 90);
plt.title("Variables más relevantes");
```

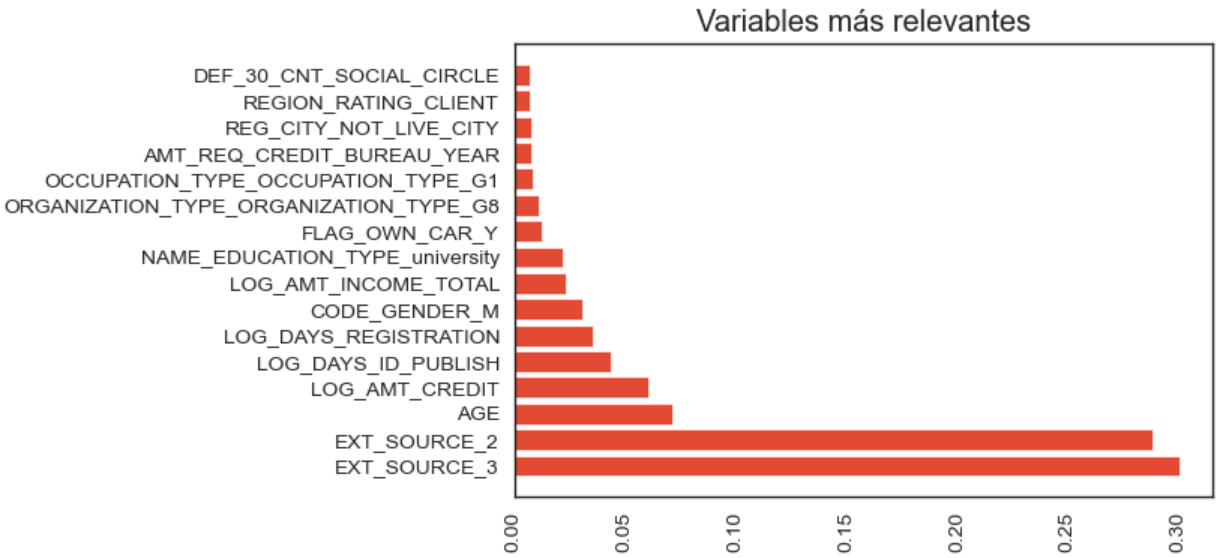

- Es importante destacar que las variables `EXT_SOURCE_3` y `EXT_SOURCE_2` son aquellas que presentan el mayor impacto en el poder predictivo del modelo, así también se pueden destacar otras como: `AGE`, `LOG_AMT_CREDIT` y `LOG_DAYS_ID_PUBLISH`.

6. Análisis Punto de Corte

- A continuación se determinarán las probabilidades de corte, para así poder generar zonas de aprobación, rechazo y evaluación exhaustiva.
- A partir de las probabilidades obtenidas de aplicar el modelo en la data de test, se realiza una tramificación de las probabilidades en 20 cortes, para analizar como la predicción discrimina entre buenos y malos pagadores, visto como la diferencia entre el porcentaje acumulado de buenos pagadores y el % acumulado de malos pagadores. Donde se aprecia que el porcentaje de malos pagadores se concentran en las probabilidades mayores.

In [179…

```
modelo_seleccionado = pickle.load(open( "gradient_boosting_predict.sav" , "rb" ))

from statistics import quantiles

y_predict_proba=modelo_seleccionado.predict_proba(X_test_std)[:,1] # prob de 0
y_predict=modelo_seleccionado.predict(X_test_std)

df_prob = pd.DataFrame({'y':list(y_test), 'y_predict': list(y_predict),'prob': list(y_predict_proba)})
quantiles = quantiles(df_prob['prob'], n = 20)

bins = [0]
for i in quantiles:
    bins.append(round(i,2))
bins.append(1)

df_prob['malo'] = df_prob['y']
df_prob['bueno'] = 1- df_prob['y']
df_prob['tramo_prob'] = pd.cut(df_prob['prob'],bins)

df_prob = df_prob.groupby('tramo_prob').agg({'y':['count'],'bueno':['sum'],'malo':['sum']}).reset_index()
df_prob.columns = ['tramo_prob','n','n_buenos','n_malos']
df_prob = df_prob.sort_values(by = 'tramo_prob', ascending = False)

df_prob['tasa_malos'] = round(df_prob['n_malos']/(df_prob['n'])*100,2)

#
df_prob['porc_buenos'] = round(df_prob['n_buenos']/df_prob['n_buenos'].sum()*100,2)
df_prob['porc_malos'] = round(df_prob['n_malos']/df_prob['n_malos'].sum()*100,2)

#
df_prob['n_buenos_acum'] = df_prob['n_buenos'].cumsum()
df_prob['n_malos_acum'] = df_prob['n_malos'].cumsum()

#
df_prob['porc_buenos_acum'] = round(df_prob['n_buenos_acum']/df_prob['n_buenos'].sum()*100,2)
df_prob['porc_malos_acum'] = round(df_prob['n_malos_acum']/df_prob['n_malos'].sum()*100,2)

df_prob['dif_porc_acum'] = abs(df_prob['porc_malos_acum']-df_prob['porc_buenos_acum'])

df_prob['tramo_prob'] = df_prob['tramo_prob'].astype('str')

ks = df_prob['dif_porc_acum'].max()
punto_ks = list(df_prob[df_prob['dif_porc_acum']==ks]['tramo_prob'].unique())[0]
```

- Para realizar un análisis de impacto económico respecto a las solicitudes de crédito es necesario determinar los beneficios y/o pérdida de determinar

uno u otro criterio de aceptación o rechazo en la evaluación.

- La proporción de ganancia y pérdida de un crédito respecto al monto otorgado es de:
  15% para los crédito buenos
  135% para los créditos malos

In [180…

```
df_original=pd.read_csv('data/training_new_credits.csv')
df_original = df_original[df_original['NAME_CONTRACT_TYPE']== 'Cash loans']

df_saldo_prom=df_original.groupby(by='TARGET').agg({'AMT_CREDIT' : ['mean']})
ganancia_bueno=round(float(df_saldo_prom.loc[0].round()*0.15))
print(f'La ganancia de un crédito bueno es: {ganancia_bueno}')
perdida_malo=round(float(df_saldo_prom.loc[1].round()*1.35))
print(f'La pérdida de un crédito malo es: {perdida_malo}')
```

```
La ganancia de un crédito bueno es: 94869
La pérdida de un crédito malo es: 781109
```

La utilidad o pérdida de otorgar un crédito es calculado de la siguiente manera:

In [181…

```
df_prob['utilidad_perdida_u'] = round((df_prob['n_buenos']*ganancia_bueno-df_prob['n_malos']*perdida_malo)/df_prob['n'],0)

df_prob_2 = df_prob.drop(columns=['porc_buenos','porc_malos','n_buenos_acum','n_malos_acum'])
df_prob_2 = df_prob_2.set_index('tramo_prob')
```

In [182…

```
df_prob_2
```

Out[182…

tramo_prob	n	n_buenos	n_malos	tasa_malos	porc_buenos_acum	porc_malos_acum	dif_porc_acum	utilidad_perdida_u
(0.78, 1.0]	4038	2790	1248	30.91	3.65	18.00	14.35	-175864.0
(0.71, 0.78]	4502	3618	884	19.64	8.37	30.76	22.39	-77136.0
(0.66, 0.71]	4004	3391	613	15.31	12.80	39.60	26.80	-39241.0
(0.61, 0.66]	4469	3853	616	13.78	17.84	48.49	30.65	-25874.0
(0.57, 0.61]	3950	3482	468	11.85	22.39	55.24	32.85	-8918.0
(0.53, 0.57]	4273	3786	487	11.40	27.33	62.26	34.93	-4967.0
(0.5, 0.53]	3442	3109	333	9.67	31.39	67.07	35.68	10122.0
(0.46, 0.5]	4935	4537	398	8.06	37.32	72.81	35.49	24223.0
(0.43, 0.46]	3918	3644	274	6.99	42.08	76.76	34.68	33609.0
(0.4, 0.43]	4202	3953	249	5.93	47.25	80.35	33.10	42961.0
(0.37, 0.4]	4520	4251	269	5.95	52.80	84.23	31.43	42737.0
(0.35, 0.37]	3204	3065	139	4.34	56.81	86.24	29.43	56866.0
(0.32, 0.35]	4914	4718	196	3.99	62.97	89.07	26.10	59930.0
(0.3, 0.32]	3376	3238	138	4.09	67.20	91.06	23.86	59062.0
(0.27, 0.3]	5057	4870	187	3.70	73.56	93.75	20.19	62477.0
(0.25, 0.27]	3360	3255	105	3.12	77.82	95.27	17.45	67495.0
(0.22, 0.25]	4714	4600	114	2.42	83.83	96.91	13.08	73685.0
(0.19, 0.22]	4254	4172	82	1.93	89.28	98.10	8.82	77984.0
(0.15, 0.19]	4494	4420	74	1.65	95.05	99.16	4.11	80445.0
(0.0, 0.15]	3844	3786	58	1.51	100.00	100.00	0.00	81652.0

- A partir de la tabla anterior se puede observar que para aquellas evaluación que presenten una probabilidad de incumplir el pago entre un 0 y un 53% está asociado a obtener un monto de beneficio economico, en cambio si la probabilidad es mayor a un 53%, se podrían obtener pérdidas al aprobar dichos créditos.

- También se puede observar que en el intervalo (0.5 - 0.53] se obtiene un beneficio pequeño en comparación con intervalos que presentan menor probabilidad de incumplir pago, dado esto podría ser discutible el resultado de este tramo (rechazo de crédito) debido a los volumenes de casos malos y buenos. así también, el tramo (0.53 - 0.57] presenta pérdida en un monto bajo en relación a otros tramos que también presentan pérdida, por lo tanto, en esta zona se podría considerar evaluar en forma mas detallada el crédito, para así poder tener una inspección experta que permita una clasificación de estos créditos.

- Por lo tanto, se propone definir una zona intermedida de evaluación manual por parte de algún ejecutivo, para aquellos casos que presenten una probabilidad entre (0.5 y 0.57], para considerar la aprobación del crédito.

- A partir de la probabilidad de evaluación, se proponen **3 zonas**:

Tramo Prob.	Descripción
(0 - 0.5]	Zona de aprobación de evaluación de crédito
(0.5 - 0.57]	Zona de evaluación manual de créditos
(0.57 - 1]	Zona de rechazo de crédito

In [183…
```
sns.lineplot(x = 'tramo_prob', y = 'porc_buenos_acum', data = df_prob, label='% buenos acum',color='green');
sns.lineplot(x = 'tramo_prob', y = 'porc_malos_acum', data = df_prob,label ='% malos acum',color='red');
plt.title('Zona de evaluación punto de corte')
plt.axvline('(0.46, 0.5]', color = 'grey', linestyle = '--', label = 'zona evaluacion')
plt.axvline('(0.53, 0.57]', color = 'grey', linestyle = '--' )
plt.ylabel('%')
plt.xlabel('Tramo probabilidad')
plt.legend()
plt.xticks(rotation = 90);
plt.tight_layout()
plt.show()
```

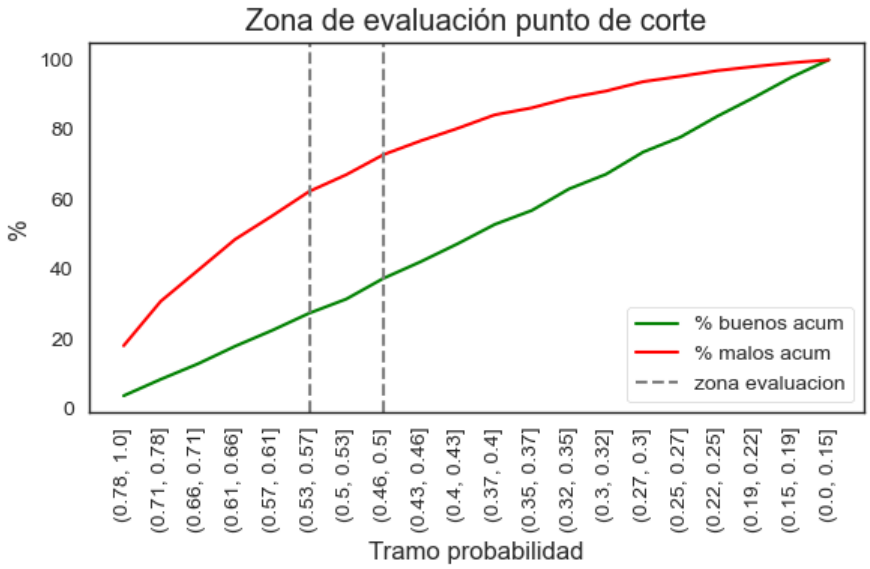

- En el gráfico anterior se pueden observar las 3 zonas descritas, en donde a partir de la probabilidad 0.57 se capturan una mayor cantidad de créditos que podrían ser entregados a clientes con un mal comportamiento de pago.

7. Implementación

Una vez definido el modelo, se importa el set de datos disponible para aplicarlo, junto al modelo serializado. Luego se realizan los ajustes necesarios para disponer de las variables necesarias que permitan aplicar el modelo en estos datos. Estos ajustes se realizan por medio de la función `procesa_data_validacion`.

In [184…
```
# Cargar modelo y data de validación
modelo_gradient_boosting = pickle.load(open( "modelo_gradient_boosting.pkl" , "rb" ))
#modelo_arresto_reglog = pickle.load(open( "ClaudiaMiguel_modelo_arresto_reglog.sav" , "rb" ))

df_aplicacion = pd.read_csv('data/testing_new_credits.csv')
print(df_aplicacion.shape)
df_aplicacion.head(3)
```

```
(48744, 121)
```

Out[184…

	SK_ID_CURR	NAME_CONTRACT_TYPE	CODE_GENDER	FLAG_OWN_CAR	FLAG_OWN_REALTY	CNT_CHILDREN	AMT_INCOME_TOTAL	AMT_CREDIT	AMT_ANNUIT
0	100001	Cash loans	F	N	Y	0	135000.0	568800.0	20560
1	100005	Cash loans	M	N	Y	0	99000.0	222768.0	17370
2	100013	Cash loans	M	Y	Y	0	202500.0	663264.0	69777

In [185…

```
# Deja data binarizada para aplicar el modelo
df_aplicacion = hlp.procesa_data_validacion(df_aplicacion)
print(df_aplicacion.shape)  # (48305, 44)
df_aplicacion.head(3)
```

```
(48305, 43)
```

Out[185…

	CNT_CHILDREN	FLAG_WORK_PHONE	FLAG_PHONE	CNT_FAM_MEMBERS	REGION_RATING_CLIENT	REG_CITY_NOT_LIVE_CITY	REG_CITY_NOT_WORK_CITY	LIVE_
0	0	0	0	2.0	2	0	0	
1	0	0	0	2.0	2	0	0	
2	0	0	0	2.0	2	0	0	

In [186…

```
# Aplicar modelo para obtener predicciones

# Estandarizar la base
scaler = StandardScaler()
X_std = scaler.fit_transform(df_aplicacion)

# Predicciones
y_predict_proba = modelo_gradient_boosting.predict_proba(X_std)[:,1]

df_predict = pd.DataFrame({'prob':list(y_predict_proba)})
df_predict['Evaluacion'] = 'Aprobado'
df_predict['Evaluacion'] = np.where(df_predict['prob'] > 0.50, 'Zona Evaluacion', df_predict['Evaluacion']  )
df_predict['Evaluacion'] = np.where(df_predict['prob'] > 0.57, 'Rechazado', df_predict['Evaluacion']  )

tmp = df_predict.groupby('Evaluacion').agg({'prob':['count','min','max']}).reset_index()
tmp.columns = ['Evaluacion','n','min','max']
tmp['%'] = round(tmp['n']/tmp['n'].sum()*100,2)
#tmp['%'] = tmp['']
tmp
```

Out[186…

	Evaluacion	n	min	max	%
0	Aprobado	32584	0.032102	0.499997	67.45
1	Rechazado	11356	0.570015	0.951261	23.51
2	Zona Evaluacion	4365	0.500029	0.569997	9.04

In [187…

```
sns.countplot(x = 'Evaluacion', data = df_predict, hue_order = ['Aprobado','Zona Evaluacion', 'Rechazado'] );
plt.title('Resultados Evaluación ');
```

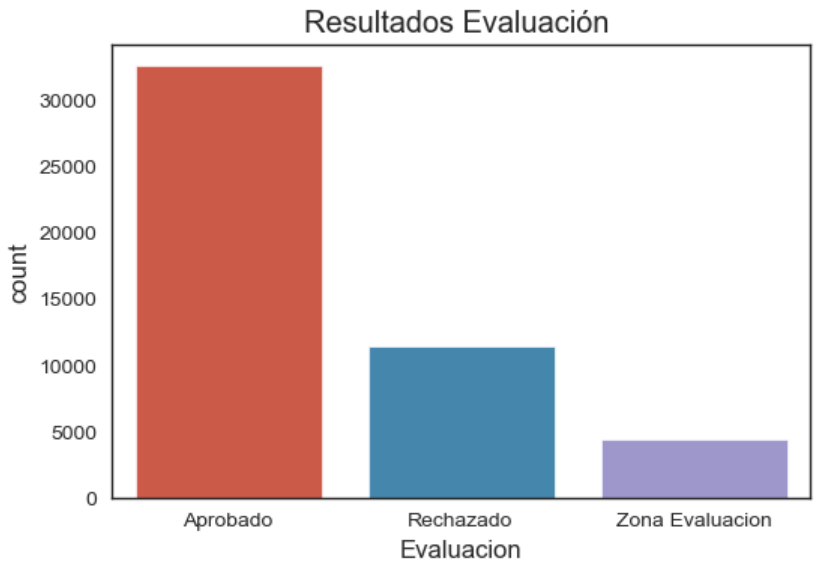

Resumen:

- La data de implementación cuenta con 48.744 observaciones, de los cuales, 48.305 corresponden a créditos de consumo para los cuales se implementa el modelo.
- Al realizar esto, se obtienen 32.584 (67.45%) donde el crédito es aprobado, 11.356 (23.51%) donde es rechazado y 4.365 casos donde se sugiere evaluar de forma exhaustiva si efectivamente el crédito debe ser rechazado.

In [ ]: